

Fundamentos Teóricos de Introducción a la Probabilidad

*Conceptos, teoremas, demostraciones
y modelos probabilísticos*

Jesús Gilberto Rodríguez Escobedo


$$(\Omega, \mathcal{F}, P)$$

$$\Omega \neq \emptyset$$

$$\mathcal{F} \subseteq 2^\Omega$$

$$\bullet \Omega \in \mathcal{F}$$

$$\bullet A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$$




$$A^c = \Omega \setminus A$$

$$A \cup B$$

$$A \cap B$$

$$A \setminus B = A \cap B^c$$

$$A \Delta B = (A \setminus B) \cup (B \setminus A)$$



Teorema de la Probabilidad Total

$$P(B) = P(A)P(B|A) + P(A^c)P(B|A^c)$$

Teorema de Bayes

$$P(A|B) = P(B|A)P(A)/P(B)$$


Independencia

$$A \perp B \Leftrightarrow P(A \cap B) = P(A)P(B)$$

$$n! = 1 \cdot 2 \cdot \dots \cdot n$$

$$C(n, k) = n! / [k!(n-k)!]$$

$$P(A) = |A|/|\Omega| \text{ (caso finito)}$$



$$E(X) = \sum x P(X=x)$$

$$E(aX+b) = aE(X) + b$$

$$\begin{aligned} \text{Var}(X) &= E[(X - E(X))^2] \\ &= E(X^2) - [E(X)]^2 \end{aligned}$$

$\mathcal{F}$ es una σ -álgebra sobre Ω si:

$$(i) \Omega \in \mathcal{F}$$

$$(ii) A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$$

$$(iii) \{A_n\} \subseteq \mathcal{F} \Rightarrow \bigcup A_n \in \mathcal{F}$$

Tabla de contenidos

Portada	11
Bienvenida	12
Presentación	13
Introducción	14
Notación general	15
1 Incertidumbre y modelos probabilísticos	16
1.1 Objetivos	16
1.2 Fenómenos deterministas y aleatorios	16
1.3 Experimento aleatorio	16
1.4 Regularidad estadística	17
1.5 Modelo probabilístico	17
1.6 Probabilidad como modelo, no como predicción exacta	18
1.7 Papel de la probabilidad en ingeniería y ciencias	18
1.8 Ideas clave	18
1.9 Ejercicios	18
1.10 Referencias del capítulo	19
2 Espacios muestrales y álgebra de eventos	20
2.1 Objetivos	20
2.2 Lenguaje de conjuntos	20
2.2.1 Inclusión e igualdad	20
2.2.2 Conjunto vacío y conjunto potencia	21
2.2.3 Producto cartesiano	21
2.3 Operaciones con conjuntos	22
2.4 Propiedades del álgebra de conjuntos	22
2.4.1 Leyes conmutativas	22
2.4.2 Leyes asociativas	23
2.4.3 Leyes distributivas	23
2.4.4 Leyes de identidad y complemento	23

2.4.5	Leyes de De Morgan	23
2.5	Demostraciones por pertenencia	24
2.5.1	Primera ley de De Morgan	24
2.5.2	Ley distributiva	24
2.6	Experimento aleatorio y espacio muestral	25
2.6.1	Ejemplo	25
2.7	Clasificación de espacios muestrales	25
2.7.1	Espacio finito	25
2.7.2	Espacio infinito numerable	26
2.7.3	Espacio no numerable	26
2.8	Eventos como subconjuntos	26
2.8.1	Ejemplo	27
2.9	Eventos disjuntos y familias exhaustivas	27
2.10	Particiones	28
2.10.1	Ejemplo	28
2.11	Familias de eventos	28
2.11.1	Definición: sigma-álgebra	29
2.12	Ejemplo integrador	29
2.13	Proposición: caracterización de la inclusión	30
2.13.1	Demostración	31
2.14	Errores conceptuales frecuentes	31
2.15	Ideas clave	31
2.16	Ejercicios	31
2.16.1	Conceptos y operaciones	31
2.16.2	Demostraciones	32
2.16.3	Modelación	32
2.16.4	Profundización	32
2.17	Referencias del capítulo	32
3	Técnicas de conteo y enumeración	33
3.1	Objetivos	33
3.2	Cardinalidad de conjuntos finitos	33
3.3	Principio aditivo	33
3.3.1	Demostración	34
3.4	Principio multiplicativo	34
3.4.1	Demostración	34
3.5	Secuencias con repetición	35
3.6	Factorial	35
3.7	Permutaciones de n objetos distintos	35
3.7.1	Teorema	36
3.7.2	Demostración	36

3.8	Arreglos de r objetos tomados de n	36
3.8.1	Teorema	36
3.8.2	Demostración	36
3.9	Combinaciones	37
3.9.1	Teorema	37
3.9.2	Demostración	37
3.10	Simetría de los coeficientes binomiales	37
3.10.1	Interpretación combinatoria	37
3.11	Identidad de Pascal	38
3.11.1	Demostración combinatoria	38
3.12	Permutaciones con repetición	38
3.12.1	Justificación	39
3.13	Coficiente multinomial	39
3.14	Ejemplo: palabras binarias	39
3.15	Ejemplo: selección de componentes	40
3.16	Relación con espacios muestrales	40
3.17	Ideas clave	41
3.18	Ejercicios	41
3.19	Referencias del capítulo	42
4	Axiomas y propiedades de la probabilidad	43
4.1	Propósitos de aprendizaje	43
4.2	Espacios de probabilidad	43
4.3	Axiomas de Kolmogórov	44
4.3.1	Axioma 1: no negatividad	44
4.3.2	Axioma 2: normalización	44
4.3.3	Axioma 3: aditividad numerable	44
4.4	Probabilidad del conjunto vacío	45
4.4.1	Proposición	45
4.4.2	Demostración	45
4.5	Aditividad finita	45
4.5.1	Proposición	45
4.5.2	Justificación	46
4.6	Regla del complemento	46
4.6.1	Proposición	46
4.6.2	Demostración	46
4.7	Monotonía	47
4.7.1	Teorema	47
4.7.2	Demostración	47
4.7.3	Corolario	47

4.8	Probabilidad de una diferencia	48
4.8.1	Proposición	48
4.8.2	Demostración	48
4.9	Fórmula de la unión de dos eventos	48
4.9.1	Teorema	48
4.9.2	Demostración	49
4.10	Cotas de Fréchet para dos eventos	49
4.11	Subaditividad	50
4.11.1	Teorema	50
4.11.2	Demostración	50
4.11.3	Generalización numerable	51
4.12	Inclusión-exclusión para tres eventos	51
4.13	Inclusión-exclusión finita	51
4.14	Continuidad de la probabilidad	51
4.14.1	Continuidad desde abajo	52
4.14.2	Continuidad desde arriba	52
4.15	Espacios finitos	53
4.16	Ejemplo formal	54
4.17	Observación conceptual: probabilidad cero e imposibilidad	55
4.18	Errores conceptuales frecuentes	55
4.19	Ejercicios	55
4.20	Referencias del capítulo	56
5	Probabilidad condicional e independencia	57
5.1	Propósitos del capítulo	57
5.2	Probabilidad condicional	57
5.2.1	Propiedad de normalización	57
5.2.2	Probabilidad condicional como medida	58
5.3	Regla del producto	58
5.4	Regla de la cadena	59
5.4.1	Demostración para tres eventos	59
5.5	Independencia de dos eventos	59
5.5.1	Equivalencia con probabilidad condicional	60
5.5.2	Demostración	60
5.6	Independencia y complementos	60
5.6.1	Demostración para A^c y B	61
5.7	Exclusión mutua e independencia	61
5.8	Independencia de varios eventos	62
5.9	Ejemplo clásico: independencia por pares sin independencia mutua	62
5.10	Dependencia inducida por muestreo sin reemplazo	63
5.11	Observación sobre eventos de probabilidad cero	64

5.12	Proposición: criterio de independencia mediante complementos	64
5.13	Ejercicios conceptuales y de demostración	64
5.14	Referencias del capítulo	65
6	Particiones, probabilidad total y teorema de Bayes	66
6.1	Objetivos	66
6.2	Particiones del espacio muestral	66
6.2.1	Propiedad fundamental	67
6.3	Ley de la probabilidad total	67
6.3.1	Teorema	67
6.3.2	Demostración	67
6.4	Caso binario	68
6.5	Teorema de Bayes	68
6.5.1	Teorema	68
6.5.2	Demostración	68
6.6	Forma proporcional	69
6.7	Normalización de las probabilidades posteriores	69
6.7.1	Demostración	70
6.8	Odds y forma de Bayes para dos hipótesis	70
6.9	Ejemplo algebraico	71
6.10	Particiones numerables	72
6.11	Actualización secuencial	72
6.12	Evidencia condicionalmente independiente	73
6.13	Tasa base y posterior	73
6.14	Relación con la probabilidad condicional	73
6.15	Ejercicios	74
6.16	Referencias del capítulo	74
7	Variable aleatoria y función de distribución acumulada	75
7.1	Objetivos	75
7.2	Variable aleatoria	75
7.3	Interpretación mediante preimágenes	75
7.4	Variables discretas	76
7.5	Variables continuas	76
7.6	Función de distribución acumulada	76
7.7	Monotonía	77
7.8	Límites en los extremos	77
7.9	Continuidad por la derecha	78
7.9.1	Teorema	78
7.9.2	Demostración	78
7.10	Límite por la izquierda y masa puntual	79

7.11	Probabilidades de intervalos	79
7.12	Distribución inducida por una variable aleatoria	80
7.13	Variables con la misma distribución	80
7.14	Ejemplo discreto	81
7.15	Caracterización de una función de distribución	81
7.16	Átomos y continuidad	81
7.17	Transformaciones y eventos	82
7.18	Materiales complementarios del capítulo	82
7.19	Ejercicios	82
7.20	Referencias del capítulo	83
8	Variables aleatorias discretas y función de masa de probabilidad	84
8.1	Objetivos	84
8.2	Variable aleatoria discreta	84
8.3	Función de masa de probabilidad	85
8.3.1	Proposición	85
8.3.2	Demostración	85
8.4	Probabilidad de eventos definidos por X	86
8.5	Distribución inducida por una variable discreta	86
8.6	Relación con la función de distribución acumulada	87
8.6.1	Proposición: saltos de la CDF	87
8.6.2	Demostración	87
8.7	Átomos y distribuciones discretas	88
8.8	Soporte y representación no única	89
8.9	Construcción mediante transformación	89
8.9.1	Ejemplo	90
8.10	PMF a partir de una CDF escalonada	90
8.11	Variables con soporte infinito numerable	91
8.12	Unicidad de la PMF	91
8.13	Distribución conjunta de valores discretos y eventos	92
8.14	Comparación conceptual con el caso continuo	92
8.15	Ejercicios	93
8.16	Referencias del capítulo	93
9	Variables aleatorias continuas y función de densidad	94
9.1	Objetivos	94
9.2	Variables aleatorias absolutamente continuas	94
9.3	Condiciones básicas de una densidad	94
9.4	Probabilidad de intervalos	95
9.5	La densidad no es una probabilidad puntual	95
9.6	Función de distribución acumulada	96

9.7	Recuperación de probabilidades desde la CDF	96
9.8	Densidad a partir de una CDF	97
9.9	Ejemplo normalizado	97
9.10	Propiedad de conjuntos de medida cero	98
9.11	Comparación formal con el caso discreto	98
9.12	Soporte de una distribución continua	99
9.13	Unicidad casi en todas partes	99
9.14	Transformaciones monótonas	99
9.15	Ejemplo de transformación	100
9.16	Ejercicios	100
9.17	Referencias del capítulo	101
Referencias		102

Listado de Figuras

Listado de Tablas

Portada

Este libro desarrolla los fundamentos matemáticos de la probabilidad con énfasis en definiciones, teoremas, demostraciones y construcción rigurosa de modelos.

La exposición avanza desde el lenguaje de conjuntos y los axiomas de probabilidad hasta los modelos probabilísticos que se estudiarán en capítulos posteriores.

Bienvenida

La teoría de la probabilidad estudia matemáticamente fenómenos en los que intervienen incertidumbre y variación.

Este libro busca construir los conceptos desde sus fundamentos: conjuntos y eventos, axiomas de probabilidad, independencia, variables aleatorias, esperanza, distribuciones y resultados límite.

La intención es que cada fórmula aparezca acompañada de su significado, condiciones de validez y relación con otros resultados.

Presentación

La obra sigue el recorrido de un primer curso universitario de probabilidad: conjuntos, espacios muestrales, eventos, axiomas, probabilidad condicional, Bayes, variables aleatorias, esperanza, distribuciones conjuntas y distribuciones discretas y continuas importantes.

A diferencia del libro aplicado, aquí se desarrollarán con mayor detalle las definiciones, propiedades y demostraciones, procurando mantener un nivel accesible para estudiantes de ingeniería y ciencias con formación en cálculo.

Introducción

La probabilidad transforma la incertidumbre en un objeto matemático susceptible de análisis. Su punto de partida es describir los resultados posibles de un experimento y representar mediante conjuntos los sucesos de interés. A partir de ahí se construye una medida de probabilidad y se estudian sus consecuencias.

El desarrollo será progresivo. Primero estableceremos el lenguaje de experimentos, espacios muestrales y eventos; después formularemos los axiomas y sus propiedades; más adelante introduciremos variables aleatorias, funciones de distribución, esperanza, momentos y distribuciones conjuntas.

El objetivo no será únicamente aplicar fórmulas, sino comprender por qué funcionan y bajo qué hipótesis pueden utilizarse.

Notación general

- Ω : espacio muestral.
- $\mathcal{F}$: colección de eventos.
- A, B, C : eventos.
- A^c : complemento de A .
- P : medida de probabilidad.
- $P(A | B)$: probabilidad condicional.
- X, Y : variables aleatorias.
- F_X : función de distribución de X .
- $E(X)$: esperanza matemática.
- $\text{Var}(X)$: varianza.
- $\text{Cov}(X, Y)$: covarianza.
- ρ_{XY} : coeficiente de correlación.

1 Incertidumbre y modelos probabilísticos

1.1. Objetivos

Al finalizar este capítulo, el estudiante podrá distinguir fenómenos deterministas y aleatorios, identificar los elementos básicos de un experimento aleatorio y explicar el papel de un modelo probabilístico.

1.2. Fenómenos deterministas y aleatorios

Un fenómeno se denomina **determinista** cuando, dentro del modelo adoptado, unas mismas condiciones iniciales producen el mismo resultado. En contraste, un fenómeno **aleatorio** puede producir resultados distintos aun cuando el procedimiento se repita bajo condiciones esencialmente iguales.

La aleatoriedad puede originarse en variaciones no controladas, incertidumbre de medición, complejidad del sistema o información incompleta.

1.3. Experimento aleatorio

Un **experimento aleatorio** es un procedimiento cuyo resultado específico no puede predecirse con certeza antes de realizarlo, aunque sí es posible describir el conjunto de resultados que pueden ocurrir.

Más adelante llamaremos **espacio muestral** a ese conjunto de resultados posibles.

1.4. Regularidad estadística

Aunque una repetición individual sea impredecible, las repeticiones numerosas de un experimento suelen mostrar regularidades. Esta observación constituye una de las motivaciones fundamentales para introducir probabilidades numéricas.

Si A es un evento y después de n repeticiones ocurre n_A veces, definimos la frecuencia relativa

$$f_n(A) = \frac{n_A}{n}.$$

El comportamiento de $f_n(A)$ cuando n aumenta será estudiado posteriormente mediante resultados límite.

1.5. Modelo probabilístico

Un modelo probabilístico elemental consta de dos componentes:

1. una descripción de los resultados posibles;
2. una regla que asigna probabilidades a los eventos.

En una formulación más avanzada, un espacio de probabilidad se representa mediante la terna

$$(\Omega, \mathcal{F}, P),$$

donde Ω es el espacio muestral, $\mathcal{F}$ es una colección adecuada de eventos y P es una medida de probabilidad.

En este libro introduciremos primero estas ideas de manera elemental y más adelante precisaremos las propiedades que debe satisfacer P .

1.6. Probabilidad como modelo, no como predicción exacta

Asignar una probabilidad a un evento no significa predecir el resultado de una realización particular. La probabilidad describe la incertidumbre dentro de un modelo.

Por ejemplo, si una moneda ideal se modela con

$$P(\text{cara}) = \frac{1}{2},$$

esto no implica que en diez lanzamientos aparezcan exactamente cinco caras. La afirmación se refiere al modelo y a su comportamiento probabilístico, no a una secuencia concreta.

1.7. Papel de la probabilidad en ingeniería y ciencias

Los modelos probabilísticos aparecen cuando se estudian confiabilidad de componentes, errores de transmisión, tiempos de espera, defectos de fabricación, mediciones ambientales, ruido en señales y muchos otros fenómenos con variabilidad.

La utilidad de la teoría radica en que permite pasar de una descripción cualitativa de la incertidumbre a cálculos y resultados matemáticos verificables.

1.8. Ideas clave

- Aleatoriedad no significa ausencia de leyes matemáticas.
- Un experimento aleatorio puede tener resultados individuales impredecibles y, al mismo tiempo, presentar regularidad colectiva.
- La probabilidad se construye sobre eventos asociados a un espacio muestral.
- El modelo probabilístico abstrae los rasgos relevantes del fenómeno real.

1.9. Ejercicios

1. Da dos ejemplos de fenómenos deterministas y dos de fenómenos aleatorios.
2. Explica por qué la medición repetida de una misma magnitud física puede modelarse probabilísticamente.
3. Describe los resultados posibles de lanzar dos monedas.
4. ¿Por qué $P(A) = 0.7$ no significa que el evento A ocurrirá siete veces en cada bloque de diez repeticiones?

5. Explica con tus palabras la diferencia entre un sistema físico y su modelo probabilístico.

1.10. Referencias del capítulo

La organización conceptual se apoya principalmente en Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

2 Espacios muestrales y álgebra de eventos

2.1. Objetivos

Al finalizar este capítulo, el estudiante podrá:

- formular con precisión un espacio muestral;
- representar eventos como subconjuntos del espacio muestral;
- distinguir puntos muestrales, eventos y familias de eventos;
- demostrar identidades del álgebra de conjuntos mediante argumentos de pertenencia;
- reconocer particiones y eventos mutuamente excluyentes;
- relacionar el enfoque elemental de eventos con la terna $(\Omega, \mathcal{F}, P)$.

2.2. Lenguaje de conjuntos

La teoría de probabilidad utiliza el lenguaje de conjuntos para separar dos niveles:

- el **resultado individual** de un experimento;
- las **afirmaciones** acerca de ese resultado.

Un conjunto es una colección bien definida de objetos. Si x es elemento de A , escribimos $x \in A$. La negación se expresa como $x \notin A$.

2.2.1. Inclusión e igualdad

Sean A y B conjuntos. Definimos

$$A \subseteq B \iff \forall x (x \in A \Rightarrow x \in B).$$

La igualdad queda caracterizada por doble inclusión:

$$A = B \iff A \subseteq B \text{ y } B \subseteq A.$$

Esta caracterización será nuestra herramienta principal para demostrar identidades entre eventos.

2.2.2. Conjunto vacío y conjunto potencia

El **conjunto vacío**, $\emptyset$, no contiene elementos. Es subconjunto de cualquier conjunto.

El **conjunto potencia** de Ω , denotado por $\mathcal{P}(\Omega)$, es la colección de todos sus subconjuntos:

$$\mathcal{P}(\Omega) = \{A : A \subseteq \Omega\}.$$

Si Ω tiene n elementos, entonces

$$|\mathcal{P}(\Omega)| = 2^n.$$

En efecto, para formar un subconjunto decidimos, para cada uno de los n elementos, incluirlo o no incluirlo. Existen dos decisiones independientes por elemento, lo que produce 2^n subconjuntos.

2.2.3. Producto cartesiano

El producto cartesiano de A y B es

$$A \times B = \{(a, b) : a \in A, b \in B\}.$$

Si A y B son finitos,

$$|A \times B| = |A| |B|.$$

Los productos cartesianos permiten describir experimentos compuestos. Dos lanzamientos de un dado tienen como espacio muestral

$$\{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\}.$$

2.3. Operaciones con conjuntos

Para $A, B \subseteq \Omega$, definimos:

$$A \cup B = \{x \in \Omega : x \in A \text{ o } x \in B\},$$

$$A \cap B = \{x \in \Omega : x \in A \text{ y } x \in B\},$$

$$A \setminus B = \{x \in \Omega : x \in A \text{ y } x \notin B\},$$

$$A^c = \Omega \setminus A.$$

La diferencia simétrica es

$$A \triangle B = (A \setminus B) \cup (B \setminus A).$$

También puede escribirse como

$$A \triangle B = (A \cup B) \setminus (A \cap B).$$

2.4. Propiedades del álgebra de conjuntos

Para cualesquiera $A, B, C \subseteq \Omega$ se cumplen:

2.4.1. Leyes conmutativas

$$A \cup B = B \cup A, \quad A \cap B = B \cap A.$$

2.4.2. Leyes asociativas

$$(A \cup B) \cup C = A \cup (B \cup C),$$

$$(A \cap B) \cap C = A \cap (B \cap C).$$

2.4.3. Leyes distributivas

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C),$$

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C).$$

2.4.4. Leyes de identidad y complemento

$$A \cup \emptyset = A, \quad A \cap \Omega = A,$$

$$A \cup \Omega = \Omega, \quad A \cap \emptyset = \emptyset,$$

$$A \cup A^c = \Omega, \quad A \cap A^c = \emptyset,$$

$$(A^c)^c = A.$$

2.4.5. Leyes de De Morgan

$$(A \cup B)^c = A^c \cap B^c,$$

$$(A \cap B)^c = A^c \cup B^c.$$

2.5. Demostraciones por pertenencia

2.5.1. Primera ley de De Morgan

Demostraremos

$$(A \cup B)^c = A^c \cap B^c.$$

Sea $x \in \Omega$. Entonces

$$\begin{aligned} x \in (A \cup B)^c &\iff x \notin A \cup B \\ &\iff (x \notin A) \text{ y } (x \notin B) \\ &\iff (x \in A^c) \text{ y } (x \in B^c) \\ &\iff x \in A^c \cap B^c. \end{aligned}$$

Como la equivalencia se cumple para todo $x \in \Omega$, los conjuntos son iguales.

2.5.2. Ley distributiva

Demostremos

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

Para cualquier $x \in \Omega$,

$$\begin{aligned} x \in A \cap (B \cup C) &\iff x \in A \text{ y } (x \in B \text{ o } x \in C) \\ &\iff (x \in A \text{ y } x \in B) \text{ o } (x \in A \text{ y } x \in C) \\ &\iff x \in (A \cap B) \cup (A \cap C). \end{aligned}$$

La demostración reproduce una ley distributiva de la lógica proposicional. Esta correspondencia entre lógica y conjuntos será constante en probabilidad.

2.6. Experimento aleatorio y espacio muestral

Un **experimento aleatorio** es un procedimiento cuyo resultado concreto no se conoce antes de realizarlo, aunque el conjunto de resultados posibles pueda especificarse.

El **espacio muestral** Ω es el conjunto de todos los resultados posibles que distingue el modelo. Sus elementos $\omega \in \Omega$ reciben el nombre de **puntos muestrales**.

La frase “que distingue el modelo” es importante. Un mismo procedimiento admite diferentes espacios muestrales según la información que se registre.

2.6.1. Ejemplo

Al lanzar un dado y registrar el número de puntos,

$$\Omega_1 = \{1, 2, 3, 4, 5, 6\}.$$

Si sólo se registra la paridad,

$$\Omega_2 = \{\text{par}, \text{impar}\}.$$

Existe una función $g : \Omega_1 \rightarrow \Omega_2$ que asigna a cada número su paridad. El segundo modelo es una descripción menos fina del primero.

2.7. Clasificación de espacios muestrales

2.7.1. Espacio finito

Ω contiene un número finito de puntos. Por ejemplo, para dos bits transmitidos,

$$\Omega = \{00, 01, 10, 11\}.$$

2.7.2. Espacio infinito numerable

Sus puntos pueden ponerse en correspondencia con un subconjunto de los números naturales. El número de intentos hasta obtener el primer éxito tiene espacio muestral

$$\Omega = \{1, 2, 3, \dots\}.$$

2.7.3. Espacio no numerable

Contiene un continuo de resultados. El tiempo de vida de un dispositivo puede modelarse mediante

$$\Omega = [0, \infty).$$

La distinción entre espacios discretos y continuos determinará posteriormente cómo se asignan probabilidades y cómo se definen las variables aleatorias.

2.8. Eventos como subconjuntos

Un **evento** A es un subconjunto de Ω . Decimos que A ocurre si el resultado observado ω pertenece a A .

Esta definición distingue correctamente:

- punto muestral: $\omega \in \Omega$;
- evento elemental: $\{\omega\} \subseteq \Omega$;
- evento general: $A \subseteq \Omega$.

El evento seguro es Ω y el evento imposible es $\emptyset$.

2.8.1. Ejemplo

Para $\Omega = \{1, 2, 3, 4, 5, 6\}$, definamos

$$A = \{2, 4, 6\}, \quad B = \{4, 5, 6\}.$$

A es el evento “resultado par” y B es “resultado mayor que 3”. De aquí,

$$A \cap B = \{4, 6\},$$

$$A \cup B = \{2, 4, 5, 6\},$$

$$A^c = \{1, 3, 5\}.$$

2.9. Eventos disjuntos y familias exhaustivas

Dos eventos A y B son **mutuamente excluyentes** o **disjuntos** si

$$A \cap B = \emptyset.$$

Una familia $A_1, \dots, A_n$ es **exhaustiva** si

$$\bigcup_{i=1}^n A_i = \Omega.$$

La exhaustividad no implica disjunción. Los eventos pueden cubrir todo Ω y superponerse.

2.10. Particiones

Una colección no vacía $\{A_i : i \in I\}$ es una **partición** de Ω si:

1. $A_i \neq \emptyset$ para todo i ;
2. $A_i \cap A_j = \emptyset$ cuando $i \neq j$;
3. $\bigcup_{i \in I} A_i = \Omega$.

Cada punto muestral pertenece exactamente a un bloque de la partición.

2.10.1. Ejemplo

En $\Omega = \{1, 2, 3, 4, 5, 6\}$,

$$A_1 = \{1, 3, 5\}, \quad A_2 = \{2, 4, 6\}$$

forman una partición. En cambio,

$$B_1 = \{1, 2, 3\}, \quad B_2 = \{3, 4, 5, 6\}$$

son exhaustivos, pero no forman una partición porque $B_1 \cap B_2 = \{3\}$.

Las particiones serán esenciales para la regla de probabilidad total y el teorema de Bayes.

2.11. Familias de eventos

En un espacio muestral finito suele tomarse como colección de eventos todo el conjunto potencia:

$$\mathcal{F} = \mathcal{P}(\Omega).$$

En espacios infinitos, especialmente no numerables, no siempre se asigna probabilidad a cada subconjunto. Se selecciona una colección $\mathcal{F}$ que cumpla propiedades de cierre.

2.11.1. Definición: sigma-álgebra

Una colección $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ es una **sigma-álgebra** si:

1. $\Omega \in \mathcal{F}$;
2. si $A \in \mathcal{F}$, entonces $A^c \in \mathcal{F}$;
3. si $A_1, A_2, \dots \in \mathcal{F}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$.

Los elementos de $\mathcal{F}$ son los eventos a los que podrá asignarse probabilidad.

De estas condiciones se deduce que $\emptyset \in \mathcal{F}$ y que $\mathcal{F}$ es cerrada bajo intersecciones numerables. En efecto,

$$\bigcap_{i=1}^{\infty} A_i = \left(\bigcup_{i=1}^{\infty} A_i^c \right)^c.$$

Para el curso elemental bastará, en la mayoría de los ejemplos finitos, trabajar con $\mathcal{P}(\Omega)$. La sigma-álgebra explica por qué la terna formal es

$$(\Omega, \mathcal{F}, P)$$

y no solamente (Ω, P) .

2.12. Ejemplo integrador

Se inspeccionan dos componentes. Cada uno se clasifica como conforme (C), reparable (R) o desecho (D). Como el orden identifica la posición del componente,

$$\Omega = \{CC, CR, CD, RC, RR, RD, DC, DR, DD\}.$$

Sea

$$A = \{\omega \in \Omega : \text{al menos un componente es } D\}$$

y

$$B = \{\omega \in \Omega : \text{ambos componentes tienen la misma clasificación}\}.$$

Entonces

$$A = \{CD, RD, DC, DR, DD\},$$

$$B = \{CC, RR, DD\}.$$

Por tanto,

$$A \cap B = \{DD\},$$

$$A \setminus B = \{CD, RD, DC, DR\},$$

$$(A \cup B)^c = \{CR, RC\}.$$

Los eventos

$$C_0 = \{CC, CR, RC, RR\},$$

$$C_1 = \{CD, RD, DC, DR\},$$

$$C_2 = \{DD\}$$

forman una partición de Ω de acuerdo con el número de componentes clasificados como desecho.

2.13. Proposición: caracterización de la inclusión

Para $A, B \subseteq \Omega$, son equivalentes:

1. $A \subseteq B$;
2. $A \cap B = A$;
3. $A \cup B = B$.

2.13.1. Demostración

Supongamos $A \subseteq B$. Si $x \in A \cap B$, entonces $x \in A$; por tanto, $A \cap B \subseteq A$. La inclusión contraria se obtiene porque $x \in A$ implica $x \in B$, de modo que $x \in A \cap B$. Así, $A \cap B = A$.

Ahora supongamos $A \cap B = A$. Si $x \in A$, entonces $x \in A \cap B$, y por ello $x \in B$. Luego $A \subseteq B$.

La equivalencia entre $A \subseteq B$ y $A \cap B = A$ se demuestra de manera análoga. $\square$

2.14. Errores conceptuales frecuentes

1. Escribir $\omega \subseteq \Omega$ cuando ω es un punto muestral; debe escribirse $\omega \in \Omega$.
2. Confundir $\emptyset$ con $\{\emptyset\}$. El primero no tiene elementos; el segundo contiene un elemento.
3. Afirmar que eventos disjuntos son independientes. La independencia requiere una definición probabilística posterior.
4. Calcular A^c sin especificar el espacio muestral.
5. Omitir resultados en experimentos por etapas o tratar pares ordenados como si el orden no importara.

2.15. Ideas clave

- El espacio muestral reúne los resultados que distingue el modelo.
- Los eventos son subconjuntos, no resultados individuales.
- El álgebra de eventos hereda las leyes del álgebra de conjuntos.
- Las identidades se demuestran rigurosamente mediante pertenencia o doble inclusión.
- Una partición divide Ω en bloques no vacíos, disjuntos y exhaustivos.
- La sigma-álgebra $\mathcal{F}$ especifica qué subconjuntos se consideran eventos medibles.

2.16. Ejercicios

2.16.1. Conceptos y operaciones

1. Sea $\Omega = \{1, 2, \dots, 12\}$, A el conjunto de múltiplos de 2 y B el conjunto de múltiplos de 3. Obtén $A \cap B$, $A \cup B$, A^c , B^c y $A \triangle B$.
2. Calcula $\mathcal{P}(\{a, b, c\})$ y verifica que contiene 2^3 elementos.
3. Construye el espacio muestral de tres lanzamientos de una moneda mediante un producto cartesiano.

4. Da un ejemplo de una familia exhaustiva que no sea una partición.

2.16.2. Demostraciones

5. Demuestra la segunda ley de De Morgan por pertenencia.
6. Demuestra $A \setminus (B \cup C) = (A \setminus B) \cap (A \setminus C)$.
7. Demuestra $A \triangle B = (A \cup B) \setminus (A \cap B)$.
8. Prueba que $A \subseteq B$ implica $B^c \subseteq A^c$.
9. Demuestra que una partición finita $A_1, \dots, A_n$ satisface que cada $\omega \in \Omega$ pertenece a un único A_i .

2.16.3. Modelación

10. Un experimento registra el estado de tres interruptores, cada uno encendido o apagado. Define Ω y los eventos “exactamente dos están encendidos” y “el primero está apagado”.
11. Se mide el tiempo hasta la primera falla de un sistema. Propón un espacio muestral continuo y tres eventos expresados mediante intervalos.
12. Se extraen dos piezas sin reemplazo de un lote con piezas identificadas. Explica cuándo el orden debe formar parte del punto muestral.

2.16.4. Profundización

13. Sea $\Omega = \{1, 2, 3, 4\}$. Encuentra una sigma-álgebra que contenga $\{1, 2\}$ pero que no sea $\mathcal{P}(\Omega)$.
14. Comprueba que $\{\emptyset, \Omega\}$ y $\mathcal{P}(\Omega)$ siempre son sigma-álgebras.
15. Si $\mathcal{F}$ es una sigma-álgebra y $A, B \in \mathcal{F}$, demuestra que $A \setminus B \in \mathcal{F}$.

2.17. Referencias del capítulo

La secuencia de espacios muestrales y eventos se apoya principalmente en Walpole et al. (2012) y en el programa oficial del curso. La formalización se complementa con Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

3 Técnicas de conteo y enumeración

3.1. Objetivos

Al finalizar este capítulo, el estudiante será capaz de formular y demostrar reglas elementales de conteo, distinguir entre procesos ordenados y no ordenados, obtener fórmulas para permutaciones, arreglos y combinaciones, y utilizar estas herramientas para determinar cardinalidades de espacios muestrales finitos.

3.2. Cardinalidad de conjuntos finitos

Si A es un conjunto finito, denotamos por

$$|A|$$

el número de elementos de A .

Las técnicas de conteo buscan determinar cardinalidades sin necesidad de enumerar explícitamente cada elemento.

3.3. Principio aditivo

Sean $A_1, A_2, \dots, A_k$ conjuntos finitos y mutuamente disjuntos. Entonces

$$\left| \bigcup_{i=1}^k A_i \right| = \sum_{i=1}^k |A_i|.$$

3.3.1. Demostración

Como los conjuntos son disjuntos, ningún elemento pertenece simultáneamente a dos de ellos. Por tanto, al sumar sus cardinalidades cada elemento de la unión se cuenta exactamente una vez.

El requisito de disjunción es esencial. Si dos conjuntos se superponen, la suma simple cuenta varias veces los elementos comunes.

3.4. Principio multiplicativo

Sean $A_1, A_2, \dots, A_k$ conjuntos finitos. El número de elementos del producto cartesiano

$$A_1 \times A_2 \times \dots \times A_k$$

es

$$|A_1||A_2| \dots |A_k|.$$

3.4.1. Demostración

Cada elemento del producto cartesiano es una k -tupla

$$(a_1, a_2, \dots, a_k),$$

con $a_i \in A_i$. Para cada elección de a_1 existen $|A_2|$ posibilidades para a_2 , y así sucesivamente. La aplicación sucesiva del principio multiplicativo produce el resultado.

Este principio proporciona la formulación matemática de los diagramas de árbol y de los experimentos por etapas.

3.5. Secuencias con repetición

Sea un conjunto de n símbolos. El número de secuencias ordenadas de longitud r que pueden formarse permitiendo repetición es

$$n^r.$$

En efecto, el espacio de secuencias es el producto cartesiano

$$A^r = A \times A \times \cdots \times A,$$

y por el principio multiplicativo

$$|A^r| = |A|^r = n^r.$$

3.6. Factorial

Para $n \in \mathbb{N}$,

$$n! = n(n-1) \cdots 2 \cdot 1,$$

con el convenio

$$0! = 1.$$

El factorial aparece al contar biyecciones y ordenamientos de conjuntos finitos.

3.7. Permutaciones de n objetos distintos

Una permutación de un conjunto de n elementos es una ordenación de todos sus elementos.

3.7.1. Teorema

El número de permutaciones de n objetos distintos es

$$n!.$$

3.7.2. Demostración

La primera posición puede ocuparse de n maneras. Una vez elegida, la segunda dispone de $n-1$ posibilidades; la tercera, de $n-2$, y así sucesivamente. Por el principio multiplicativo,

$$n(n-1)(n-2)\cdots 2\cdot 1 = n!.$$

3.8. Arreglos de r objetos tomados de n

Un arreglo sin repetición de longitud r es una secuencia ordenada formada por r elementos distintos elegidos de un conjunto de n elementos.

3.8.1. Teorema

El número de arreglos es

$$P(n, r) = \frac{n!}{(n-r)!}, \quad 0 \leq r \leq n.$$

3.8.2. Demostración

Existen n opciones para la primera posición, $n-1$ para la segunda y, finalmente, $n-r+1$ para la posición r . Por tanto,

$$P(n, r) = n(n-1)\cdots(n-r+1) = \frac{n!}{(n-r)!}.$$

3.9. Combinaciones

Una combinación de tamaño r es un subconjunto de r elementos de un conjunto de n elementos.

3.9.1. Teorema

El número de combinaciones de n elementos tomados de r en r es

$$\binom{n}{r} = \frac{n!}{r!(n-r)!}.$$

3.9.2. Demostración

Primero contamos arreglos de longitud r :

$$P(n, r) = \frac{n!}{(n-r)!}.$$

Cada subconjunto de r elementos produce exactamente $r!$ ordenamientos. Por tanto, al dividir entre $r!$ obtenemos

$$\binom{n}{r} = \frac{P(n, r)}{r!} = \frac{n!}{r!(n-r)!}.$$

3.10. Simetría de los coeficientes binomiales

Para $0 \leq r \leq n$,

$$\binom{n}{r} = \binom{n}{n-r}.$$

3.10.1. Interpretación combinatoria

Elegir los r elementos que pertenecen a un subconjunto equivale a elegir los $n-r$ elementos que quedan fuera. Ambas decisiones determinan exactamente el mismo subconjunto.

3.11. Identidad de Pascal

Para $1 \leq r \leq n - 1$,

$$\binom{n}{r} = \binom{n-1}{r-1} + \binom{n-1}{r}.$$

3.11.1. Demostración combinatoria

Fijemos un elemento particular x de un conjunto de n elementos. Todo subconjunto de tamaño r pertenece exactamente a una de dos clases:

1. contiene a x ;
2. no contiene a x .

Si contiene a x , faltan por elegir $r - 1$ elementos de los $n - 1$ restantes, lo que puede hacerse de

$$\binom{n-1}{r-1}$$

formas. Si no contiene a x , deben elegirse los r elementos entre los $n - 1$ restantes, lo que puede hacerse de

$$\binom{n-1}{r}$$

formas. Como las dos clases son disjuntas, el principio aditivo completa la demostración.

3.12. Permutaciones con repetición

Supongamos que se tienen n objetos, de los cuales n_1 son indistinguibles de un primer tipo, n_2 de un segundo tipo, ..., n_k de un último tipo, con

$$n_1 + n_2 + \cdots + n_k = n.$$

El número de ordenamientos distintos es

$$\frac{n!}{n_1!n_2!\cdots n_k!}.$$

3.12.1. Justificación

Si todos los objetos fueran distintos existirían $n!$ ordenamientos. Sin embargo, permutar entre sí los n_i objetos indistinguibles de cada clase no produce un nuevo ordenamiento. Por ello se divide entre

$$n_1!n_2!\cdots n_k!.$$

3.13. Coeficiente multinomial

Una generalización natural del coeficiente binomial es

$$\binom{n}{n_1, n_2, \dots, n_k} = \frac{n!}{n_1!n_2!\cdots n_k!},$$

con

$$n_1 + n_2 + \cdots + n_k = n.$$

Este coeficiente cuenta el número de maneras de dividir n objetos distintos en k grupos etiquetados de tamaños $n_1, n_2, \dots, n_k$.

3.14. Ejemplo: palabras binarias

Consideremos cadenas de longitud 8 formadas por ceros y unos.

El número total de cadenas es

$$2^8 = 256.$$

El número de cadenas con exactamente tres unos es

$$\binom{8}{3} = 56,$$

porque basta elegir las tres posiciones ocupadas por unos.

Esta interpretación será útil posteriormente al estudiar la distribución binomial.

3.15. Ejemplo: selección de componentes

De 12 componentes se seleccionan 3.

Si la selección es un subconjunto sin orden,

$$\binom{12}{3} = 220.$$

Si las tres posiciones representan pruebas diferentes y el orden importa,

$$P(12, 3) = \frac{12!}{9!} = 1320.$$

Por tanto, el mismo conjunto físico de objetos puede inducir distintos problemas combinatorios según la definición del resultado.

3.16. Relación con espacios muestrales

Las técnicas de conteo permiten calcular cardinalidades como

$$|S|$$

y

$$|A|,$$

sin enumerar explícitamente los resultados. En el capítulo siguiente, al introducir formalmente la probabilidad en espacios finitos equiprobables, estas cardinalidades permitirán expresar

$$P(A) = \frac{|A|}{|S|}.$$

Por ahora, lo importante es separar dos cuestiones:

1. cuántos resultados existen;
2. qué probabilidad se asignará a esos resultados.

El conteo responde la primera pregunta, no la segunda.

3.17. Ideas clave

- La cardinalidad mide el tamaño de un conjunto finito.
- El principio aditivo se aplica a alternativas disjuntas.
- El principio multiplicativo se aplica a elecciones sucesivas.
- Las permutaciones ordenan todos los objetos.
- Los arreglos seleccionan y ordenan una parte de los objetos.
- Las combinaciones seleccionan sin considerar el orden.
- Los coeficientes binomiales satisfacen identidades con interpretaciones combinatorias.
- Las técnicas de conteo preparan el cálculo de probabilidades en espacios finitos.

3.18. Ejercicios

1. Demuestra el principio multiplicativo para tres conjuntos finitos utilizando productos cartesianos.
2. Calcula el número de cadenas de longitud 6 formadas por cuatro símbolos cuando se permite repetición.
3. ¿Cuántas permutaciones existen de 9 objetos distintos?
4. ¿Cuántos arreglos de longitud 4 pueden formarse a partir de 10 objetos distintos?
5. Demuestra algebraicamente la identidad $\binom{n}{r} = \binom{n}{n-r}$.
6. Demuestra la identidad de Pascal mediante manipulación algebraica de factoriales.
7. ¿Cuántas cadenas binarias de longitud 12 contienen exactamente cinco unos?
8. Obtén el número de permutaciones distintas de las letras de la palabra PROBABILIDAD.
9. Explica por qué el conteo de comités utiliza combinaciones mientras que la asignación de cargos utiliza arreglos.
10. Demuestra que

$$\sum_{r=0}^n \binom{n}{r} = 2^n$$

interpretando ambos lados como el número de subconjuntos de un conjunto de n elementos.

3.19. Referencias del capítulo

El desarrollo teórico de los principios de conteo y los coeficientes combinatorios se apoya en Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

4 Axiomas y propiedades de la probabilidad

4.1. Propósitos de aprendizaje

Al finalizar este capítulo, el lector será capaz de:

- describir formalmente una medida de probabilidad sobre un espacio medible;
- interpretar los axiomas de Kolmogórov;
- deducir propiedades fundamentales de una medida de probabilidad;
- demostrar monotonía, subaditividad e inclusión-exclusión para eventos finitos;
- distinguir entre propiedades primitivas y resultados derivados;
- analizar restricciones de coherencia entre probabilidades marginales e intersecciones.

4.2. Espacios de probabilidad

Un **espacio de probabilidad** es una terna

$$(\Omega, \mathcal{F}, P),$$

donde:

1. Ω es un conjunto no vacío llamado espacio muestral;
2. $\mathcal{F}$ es una σ -álgebra de subconjuntos de Ω ;
3. $P : \mathcal{F} \rightarrow [0, 1]$ es una medida de probabilidad.

La familia $\mathcal{F}$ determina cuáles subconjuntos de Ω son considerados eventos medibles. La función P asigna a cada evento un número real que satisface los axiomas que se presentan a continuación.

4.3. Axiomas de Kolmogórov

Sea $(\Omega, \mathcal{F})$ un espacio medible. Una función

$$P : \mathcal{F} \rightarrow [0, 1]$$

es una medida de probabilidad si satisface:

4.3.1. Axioma 1: no negatividad

Para todo $A \in \mathcal{F}$,

$$P(A) \geq 0.$$

4.3.2. Axioma 2: normalización

$$P(\Omega) = 1.$$

4.3.3. Axioma 3: aditividad numerable

Si $A_1, A_2, \dots \in \mathcal{F}$ son mutuamente excluyentes, es decir,

$$A_i \cap A_j = \emptyset \quad (i \neq j),$$

entonces

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n).$$

La aditividad numerable es la condición estructural central. Muchas fórmulas elementales de probabilidad se deducen de ella.

4.4. Probabilidad del conjunto vacío

4.4.1. Proposición

$$P(\emptyset) = 0.$$

4.4.2. Demostración

Como

$$\Omega = \Omega \cup \emptyset$$

y los dos conjuntos son disjuntos, por aditividad,

$$P(\Omega) = P(\Omega) + P(\emptyset).$$

Restando $P(\Omega)$ en ambos lados obtenemos

$$P(\emptyset) = 0. \quad \square$$

4.5. Aditividad finita

4.5.1. Proposición

Si $A_1, \dots, A_n \in \mathcal{F}$ son mutuamente excluyentes, entonces

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i).$$

4.5.2. Justificación

Puede aplicarse la aditividad numerable a la sucesión

$$A_1, \dots, A_n, \emptyset, \emptyset, \dots$$

y utilizar $P(\emptyset) = 0$.

4.6. Regla del complemento

4.6.1. Proposición

Para todo evento $A \in \mathcal{F}$,

$$P(A^c) = 1 - P(A).$$

4.6.2. Demostración

Como

$$A \cap A^c = \emptyset$$

y

$$A \cup A^c = \Omega,$$

por aditividad finita,

$$1 = P(\Omega) = P(A) + P(A^c).$$

Por tanto,

$$P(A^c) = 1 - P(A). \quad \square$$

4.7. Monotonía

4.7.1. Teorema

Si $A, B \in \mathcal{F}$ y

$$A \subseteq B,$$

entonces

$$P(A) \leq P(B).$$

4.7.2. Demostración

Como

$$B = A \cup (B \setminus A)$$

y los conjuntos son disjuntos,

$$P(B) = P(A) + P(B \setminus A).$$

Por no negatividad,

$$P(B \setminus A) \geq 0.$$

Luego

$$P(B) \geq P(A). \quad \square$$

4.7.3. Corolario

Para todo $A \in \mathcal{F}$,

$$0 \leq P(A) \leq 1.$$

La cota inferior procede de la no negatividad y la superior de $A \subseteq \Omega$.

4.8. Probabilidad de una diferencia

4.8.1. Proposición

Para $A, B \in \mathcal{F}$,

$$P(A \setminus B) = P(A) - P(A \cap B).$$

4.8.2. Demostración

La descomposición

$$A = (A \setminus B) \cup (A \cap B)$$

es disjunta. Por tanto,

$$P(A) = P(A \setminus B) + P(A \cap B),$$

de donde se obtiene la identidad.

4.9. Fórmula de la unión de dos eventos

4.9.1. Teorema

Para cualesquiera $A, B \in \mathcal{F}$,

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

4.9.2. Demostración

Podemos escribir

$$A \cup B = A \cup (B \setminus A),$$

donde los dos eventos son disjuntos. Luego

$$P(A \cup B) = P(A) + P(B \setminus A).$$

Además,

$$P(B \setminus A) = P(B) - P(A \cap B).$$

Sustituyendo,

$$P(A \cup B) = P(A) + P(B) - P(A \cap B). \quad \square$$

4.10. Cotas de Fréchet para dos eventos

A partir de

$$P(A \cup B) \leq 1$$

y de la fórmula de la unión,

$$P(A) + P(B) - P(A \cap B) \leq 1.$$

Por tanto,

$$P(A \cap B) \geq P(A) + P(B) - 1.$$

Como además

$$A \cap B \subseteq A$$

y

$$A \cap B \subseteq B,$$

se obtiene

$$P(A \cap B) \leq \min\{P(A), P(B)\}.$$

En consecuencia,

$$\boxed{\max\{0, P(A) + P(B) - 1\} \leq P(A \cap B) \leq \min\{P(A), P(B)\}}.$$

Estas desigualdades caracterizan las restricciones básicas que debe satisfacer una intersección dada la probabilidad marginal de cada evento.

4.11. Subaditividad

4.11.1. Teorema

Para $A, B \in \mathcal{F}$,

$$P(A \cup B) \leq P(A) + P(B).$$

4.11.2. Demostración

La fórmula de la unión da

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Como

$$P(A \cap B) \geq 0,$$

se sigue la desigualdad.

4.11.3. Generalización numerable

Para cualquier sucesión $A_1, A_2, \dots \in \mathcal{F}$,

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} P(A_n).$$

Esta propiedad se denomina **subaditividad numerable**.

4.12. Inclusión-exclusión para tres eventos

Para $A, B, C \in \mathcal{F}$,

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) \\ &\quad - P(A \cap B) - P(A \cap C) - P(B \cap C) \\ &\quad + P(A \cap B \cap C). \end{aligned}$$

La fórmula puede demostrarse aplicando dos veces la regla de la unión y usando identidades de conjuntos.

4.13. Inclusión-exclusión finita

Para eventos $A_1, \dots, A_n$,

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_i P(A_i) - \sum_{i < j} P(A_i \cap A_j) + \sum_{i < j < k} P(A_i \cap A_j \cap A_k) - \dots + (-1)^{n+1} P\left(\bigcap_{i=1}^n A_i\right).$$

El principio de inclusión-exclusión es una conexión directa entre combinatoria y probabilidad.

4.14. Continuidad de la probabilidad

La aditividad numerable implica propiedades de continuidad que serán importantes al estudiar variables aleatorias y sucesiones de eventos.

4.14.1. Continuidad desde abajo

Si

$$A_1 \subseteq A_2 \subseteq \dots$$

y

$$A = \bigcup_{n=1}^{\infty} A_n,$$

entonces

$$P(A_n) \longrightarrow P(A).$$

4.14.2. Continuidad desde arriba

Si

$$A_1 \supseteq A_2 \supseteq \dots$$

y

$$A = \bigcap_{n=1}^{\infty} A_n,$$

entonces

$$P(A_n) \longrightarrow P(A).$$

En espacios de probabilidad, la condición $P(A_1) < \infty$ necesaria para medidas generales se satisface automáticamente porque $P(A_1) \leq 1$.

4.15. Espacios finitos

Sea

$$\Omega = \{\omega_1, \dots, \omega_N\}.$$

Si asignamos masas

$$p_i = P(\{\omega_i\}),$$

con

$$p_i \geq 0, \quad \sum_{i=1}^N p_i = 1,$$

entonces para cualquier evento $A \subseteq \Omega$,

$$P(A) = \sum_{\omega_i \in A} p_i.$$

Si todos los resultados elementales son equiprobables,

$$p_i = \frac{1}{N},$$

y se obtiene

$$P(A) = \frac{|A|}{|\Omega|}.$$

La equiprobabilidad es una hipótesis adicional del modelo, no un axioma de probabilidad.

4.16. Ejemplo formal

Sea

$$\Omega = \{1, 2, 3, 4\}$$

y supongamos

$$P(\{1\}) = 0.1, \quad P(\{2\}) = 0.2, \quad P(\{3\}) = 0.3, \quad P(\{4\}) = 0.4.$$

Definimos

$$A = \{1, 2, 4\}, \quad B = \{3, 4\}.$$

Entonces

$$P(A) = 0.7,$$

$$P(B) = 0.7,$$

$$P(A \cap B) = 0.4,$$

y

$$P(A \cup B) = 0.7 + 0.7 - 0.4 = 1.$$

En efecto,

$$A \cup B = \Omega.$$

4.17. Observación conceptual: probabilidad cero e imposibilidad

El axioma establece

$$P(\emptyset) = 0,$$

pero el recíproco no es válido en general. Puede existir un evento no vacío con probabilidad cero.

En modelos continuos, por ejemplo, un resultado individual puede tener probabilidad cero aunque pertenezca al espacio muestral. Esta distinción será esencial cuando estudiemos distribuciones continuas.

4.18. Errores conceptuales frecuentes

- Tratar $P(A) = |A|/|\Omega|$ como una definición universal de probabilidad.
- Confundir aditividad para eventos disjuntos con la regla general de la unión.
- Suponer que $P(A) = 0$ implica necesariamente $A = \emptyset$.
- Utilizar propiedades derivadas como si fueran axiomas independientes.
- Proponer probabilidades marginales e intersecciones que violan las cotas de Fréchet.

4.19. Ejercicios

1. Demuestre que si $A \subseteq B$, entonces

$$P(B \setminus A) = P(B) - P(A).$$

2. Demuestre que

$$P(A \triangle B) = P(A) + P(B) - 2P(A \cap B).$$

3. Si $P(A) = 0.65$ y $P(B) = 0.50$, determine todos los valores posibles de $P(A \cap B)$.
4. Demuestre que

$$P(A \cap B) \geq P(A) + P(B) - 1.$$

5. Pruebe la desigualdad

$$P(A \cap B) \leq \min\{P(A), P(B)\}.$$

6. Derive la fórmula de inclusión-exclusión para tres eventos a partir de la fórmula de dos eventos.

7. Pruebe que

$$P(A \cup B \cup C) \leq P(A) + P(B) + P(C).$$

8. Sea $A_1 \subseteq A_2 \subseteq \dots$. Demuestre la continuidad desde abajo descomponiendo la unión en eventos disjuntos.

9. Explique por qué la equiprobabilidad no puede deducirse únicamente del hecho de que Ω sea finito.

10. **Reto** . Sea (A_n) una sucesión de eventos. Demuestre la desigualdad de Boole:

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} P(A_n).$$

4.20. Referencias del capítulo

La formulación axiomática y las propiedades derivadas siguen el tratamiento estándar de probabilidad matemática y de textos para ingeniería y ciencias, con apoyo en Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). La presentación se ha reescrito de forma original para esta obra.

5 Probabilidad condicional e independencia

5.1. Propósitos del capítulo

Este capítulo formaliza dos ideas centrales de la teoría de la probabilidad: la actualización de probabilidades ante información adicional y la independencia entre eventos. Se desarrollan la definición de probabilidad condicional, la regla del producto, la regla de la cadena y criterios equivalentes de independencia.

5.2. Probabilidad condicional

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sean $A, B \in \mathcal{F}$ con $P(B) > 0$. La probabilidad condicional de A dado B se define por

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

Esta definición puede interpretarse como una renormalización de la medida de probabilidad al restringir el espacio al evento B .

5.2.1. Propiedad de normalización

Para $P(B) > 0$,

$$P(B | B) = 1.$$

En efecto,

$$P(B | B) = \frac{P(B \cap B)}{P(B)} = 1.$$

5.2.2. Probabilidad condicional como medida

Fijado un evento B con $P(B) > 0$, la aplicación

$$P_B(A) = P(A \mid B)$$

define una nueva medida de probabilidad sobre $(\Omega, \mathcal{F})$.

Se verifica:

1. $P_B(A) \geq 0$;
2. $P_B(\Omega) = 1$;
3. si $A_1, A_2, \dots$ son disjuntos,

$$P_B\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P_B(A_i).$$

Por tanto, al condicionar por B no abandonamos la estructura axiomática de la probabilidad.

5.3. Regla del producto

A partir de la definición de probabilidad condicional,

$$P(A \cap B) = P(B)P(A \mid B).$$

Si además $P(A) > 0$,

$$P(A \cap B) = P(A)P(B \mid A).$$

Por tanto,

$$P(A)P(B \mid A) = P(B)P(A \mid B).$$

Esta igualdad es la identidad algebraica que posteriormente conduce al teorema de Bayes.

5.4. Regla de la cadena

Para eventos $A_1, \dots, A_n$ tales que las probabilidades condicionales involucradas estén definidas,

$$P\left(\bigcap_{i=1}^n A_i\right) = P(A_1) \prod_{k=2}^n P\left(A_k \mid \bigcap_{j=1}^{k-1} A_j\right).$$

Para $n = 3$,

$$P(A \cap B \cap C) = P(A)P(B \mid A)P(C \mid A \cap B).$$

5.4.1. Demostración para tres eventos

Por la regla del producto,

$$P(A \cap B \cap C) = P(A \cap B)P(C \mid A \cap B).$$

Además,

$$P(A \cap B) = P(A)P(B \mid A).$$

Sustituyendo se obtiene el resultado.

5.5. Independencia de dos eventos

Dos eventos A y B son independientes si

$$\boxed{P(A \cap B) = P(A)P(B)}.$$

Esta definición no requiere que $P(A)$ ni $P(B)$ sean positivas.

5.5.1. Equivalencia con probabilidad condicional

Si $P(B) > 0$, entonces A y B son independientes si y sólo si

$$P(A \mid B) = P(A).$$

De manera análoga, si $P(A) > 0$,

$$P(B \mid A) = P(B).$$

5.5.2. Demostración

Si A y B son independientes,

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B)}{P(B)} = P(A).$$

El recíproco se obtiene multiplicando por $P(B)$.

5.6. Independencia y complementos

Si A y B son independientes, también lo son:

$$A^c \text{ y } B,$$

$$A \text{ y } B^c,$$

y

$$A^c \text{ y } B^c.$$

5.6.1. Demostración para A^c y B

Como

$$B = (A \cap B) \cup (A^c \cap B)$$

y la unión es disjunta,

$$P(A^c \cap B) = P(B) - P(A \cap B).$$

Usando independencia,

$$P(A^c \cap B) = P(B) - P(A)P(B) = (1 - P(A))P(B) = P(A^c)P(B).$$

5.7. Exclusión mutua e independencia

Si A y B son mutuamente excluyentes,

$$P(A \cap B) = 0.$$

Si además $P(A) > 0$ y $P(B) > 0$, entonces

$$P(A)P(B) > 0,$$

por lo que no pueden ser independientes.

Así, para eventos de probabilidad positiva, exclusión mutua e independencia son conceptos incompatibles.

5.8. Independencia de varios eventos

Para tres eventos A, B, C , la independencia por pares significa

$$P(A \cap B) = P(A)P(B),$$

$$P(A \cap C) = P(A)P(C),$$

$$P(B \cap C) = P(B)P(C).$$

Sin embargo, esto no basta para garantizar independencia conjunta. Para independencia mutua se requiere además

$$P(A \cap B \cap C) = P(A)P(B)P(C).$$

En general, una familia $A_1, \dots, A_n$ es mutuamente independiente si para todo subconjunto no vacío de índices $I \subseteq \{1, \dots, n\}$,

$$P\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} P(A_i).$$

5.9. Ejemplo clásico: independencia por pares sin independencia mutua

Considérese el espacio equiprobable

$$\Omega = \{1, 2, 3, 4\}$$

y los eventos

$$A = \{1, 2\}, \quad B = \{1, 3\}, \quad C = \{1, 4\}.$$

Cada evento tiene probabilidad $1/2$. Además,

$$P(A \cap B) = P(A \cap C) = P(B \cap C) = \frac{1}{4},$$

por lo que son independientes por pares.

Sin embargo,

$$A \cap B \cap C = \{1\},$$

de modo que

$$P(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = P(A)P(B)P(C).$$

Por tanto, no son mutuamente independientes.

5.10. Dependencia inducida por muestreo sin reemplazo

Sea una urna con N objetos, de los cuales K poseen cierta propiedad. Si se extraen dos objetos sin reemplazo y definimos

- A = “el primero posee la propiedad”;
- B = “el segundo posee la propiedad”,

entonces

$$P(A) = \frac{K}{N},$$

pero

$$P(B \mid A) = \frac{K-1}{N-1}.$$

En general,

$$\frac{K-1}{N-1} \neq \frac{K}{N},$$

por lo que A y B no son independientes.

5.11. Observación sobre eventos de probabilidad cero

La igualdad

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

sólo está definida mediante esta fórmula cuando $P(B) > 0$.

En cursos más avanzados se introduce la probabilidad condicional respecto de sigma-álgebras y variables aleatorias mediante esperanza condicional, lo que permite tratar situaciones más generales. Ese desarrollo queda fuera del alcance de este volumen introductorio.

5.12. Proposición: criterio de independencia mediante complementos

Sean A y B eventos. Son equivalentes:

1. A y B son independientes;
2. A^c y B son independientes;
3. A y B^c son independientes;
4. A^c y B^c son independientes.

La demostración se obtiene aplicando repetidamente las identidades del complemento y la aditividad.

5.13. Ejercicios conceptuales y de demostración

1. Demuestra que, para $P(B) > 0$, la aplicación $P_B(A) = P(A | B)$ satisface los axiomas de probabilidad.
2. Prueba la regla de la cadena para cuatro eventos.
3. Sean A y B independientes. Demuestra que A^c y B^c son independientes.
4. Demuestra que si $A \subseteq B$, $P(A) > 0$ y A es independiente de B , entonces $P(B) = 1$.
5. Sean A y B mutuamente excluyentes. Determina todas las condiciones bajo las cuales también pueden ser independientes.
6. Construye un ejemplo de tres eventos independientes por pares que no sean mutuamente independientes.

7. Si A y B son independientes y $P(A) = 0.4$, $P(B) = 0.7$, calcula la probabilidad de cada una de las cuatro regiones $A \cap B$, $A \cap B^c$, $A^c \cap B$ y $A^c \cap B^c$.
8. Demuestra que si A y B son independientes, entonces

$$P(A \cup B) = P(A) + P(B) - P(A)P(B).$$

9. **Reto** . Sea $A_1, \dots, A_n$ una familia mutuamente independiente. Demuestra que sustituir cualquiera de los eventos por su complemento conserva la independencia mutua.

5.14. Referencias del capítulo

La presentación de probabilidad condicional, regla del producto e independencia sigue la formulación estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018), adaptada a la organización formal de este libro.

6 Particiones, probabilidad total y teorema de Bayes

6.1. Objetivos

En este capítulo se formalizan las particiones del espacio muestral, la ley de la probabilidad total y el teorema de Bayes. Se estudian sus demostraciones, su interpretación y sus consecuencias algebraicas.

6.2. Particiones del espacio muestral

Una familia finita de eventos

$$\{B_1, \dots, B_k\} \subseteq \mathcal{F}$$

es una **partición** de Ω si

$$B_i \cap B_j = \emptyset \quad (i \neq j),$$

y

$$\bigcup_{i=1}^k B_i = \Omega.$$

Si además $P(B_i) > 0$ para todo i , entonces cada B_i puede utilizarse como evento condicional.

6.2.1. Propiedad fundamental

Para cualquier evento $A \in \mathcal{F}$,

$$A = A \cap \Omega = A \cap \left(\bigcup_{i=1}^k B_i \right) = \bigcup_{i=1}^k (A \cap B_i).$$

Las intersecciones $A \cap B_i$ son mutuamente excluyentes.

6.3. Ley de la probabilidad total

6.3.1. Teorema

Sea $B_1, \dots, B_k$ una partición de Ω con $P(B_i) > 0$. Entonces para todo evento A ,

$$P(A) = \sum_{i=1}^k P(B_i)P(A \mid B_i).$$

6.3.2. Demostración

Como

$$A = \bigcup_{i=1}^k (A \cap B_i)$$

y las uniones son disjuntas,

$$P(A) = \sum_{i=1}^k P(A \cap B_i).$$

Por la definición de probabilidad condicional,

$$P(A \cap B_i) = P(B_i)P(A \mid B_i).$$

Sustituyendo,

$$P(A) = \sum_{i=1}^k P(B_i)P(A | B_i).$$

Queda demostrado.

6.4. Caso binario

Si B y B^c forman una partición y $0 < P(B) < 1$, entonces

$$P(A) = P(B)P(A | B) + P(B^c)P(A | B^c).$$

Esta forma aparece constantemente en confiabilidad, diagnóstico y clasificación.

6.5. Teorema de Bayes

6.5.1. Teorema

Sea $B_1, \dots, B_k$ una partición con $P(B_i) > 0$ y sea A un evento con $P(A) > 0$. Entonces

$$P(B_i | A) = \frac{P(B_i)P(A | B_i)}{\sum_{j=1}^k P(B_j)P(A | B_j)}.$$

6.5.2. Demostración

Por definición,

$$P(B_i | A) = \frac{P(B_i \cap A)}{P(A)}.$$

La regla del producto da

$$P(B_i \cap A) = P(B_i)P(A | B_i).$$

La ley de la probabilidad total produce

$$P(A) = \sum_{j=1}^k P(B_j)P(A | B_j).$$

Al sustituir ambas expresiones se obtiene la fórmula de Bayes.

6.6. Forma proporcional

La identidad anterior puede escribirse como

$$P(B_i | A) \propto P(B_i)P(A | B_i).$$

El denominador

$$P(A)$$

actúa como constante de normalización común a todas las hipótesis B_i .

Esta forma permite separar tres componentes conceptuales:

- $P(B_i)$: probabilidad previa;
- $P(A | B_i)$: verosimilitud de la evidencia bajo B_i ;
- $P(B_i | A)$: probabilidad posterior.

6.7. Normalización de las probabilidades posteriores

Como los B_i forman una partición,

$$\sum_{i=1}^k P(B_i | A) = 1.$$

6.7.1. Demostración

Usando Bayes,

$$\sum_{i=1}^k P(B_i | A) = \frac{\sum_{i=1}^k P(B_i)P(A | B_i)}{P(A)}.$$

El numerador es precisamente $P(A)$ por la ley de probabilidad total, de modo que la razón vale 1.

6.8. Odds y forma de Bayes para dos hipótesis

Para una hipótesis H y su complemento H^c , Bayes puede expresarse mediante **odds**.

Las odds previas son

$$\frac{P(H)}{P(H^c)}.$$

Después de observar evidencia E ,

$$\frac{P(H | E)}{P(H^c | E)} = \frac{P(H)}{P(H^c)} \cdot \frac{P(E | H)}{P(E | H^c)}.$$

La razón

$$\frac{P(E | H)}{P(E | H^c)}$$

se denomina **razón de verosimilitudes**.

Esta formulación muestra que Bayes actualiza multiplicativamente las odds previas.

6.9. Ejemplo algebraico

Sea

$$P(H) = 0.10,$$

$$P(E \mid H) = 0.80,$$

y

$$P(E \mid H^c) = 0.20.$$

Entonces

$$P(E) = 0.10(0.80) + 0.90(0.20) = 0.26.$$

Por Bayes,

$$P(H \mid E) = \frac{0.10(0.80)}{0.26} = \frac{4}{13} \approx 0.3077.$$

En términos de odds:

$$\frac{P(H)}{P(H^c)} = \frac{1}{9},$$

mientras que la razón de verosimilitudes es

$$\frac{0.80}{0.20} = 4.$$

Por tanto, las odds posteriores son

$$\frac{4}{9}.$$

De ahí se recupera

$$P(H \mid E) = \frac{4/9}{1 + 4/9} = \frac{4}{13}.$$

6.10. Particiones numerables

La formulación se extiende a una partición numerable $B_1, B_2, \dots$ siempre que las sumas estén bien definidas.

Si

$$\Omega = \bigcup_{i=1}^{\infty} B_i$$

con eventos dos a dos disjuntos y $P(B_i) > 0$, entonces

$$P(A) = \sum_{i=1}^{\infty} P(B_i)P(A | B_i).$$

Y, si $P(A) > 0$,

$$P(B_i | A) = \frac{P(B_i)P(A | B_i)}{\sum_{j=1}^{\infty} P(B_j)P(A | B_j)}.$$

6.11. Actualización secuencial

Sean E_1 y E_2 dos evidencias. Entonces

$$P(H | E_1, E_2) = \frac{P(H | E_1)P(E_2 | H, E_1)}{P(E_2 | E_1)}.$$

La distribución posterior tras observar E_1 puede utilizarse como distribución previa en la actualización con E_2 .

Esto formaliza la idea de aprendizaje secuencial.

6.12. Evidencia condicionalmente independiente

Si E_1 y E_2 son condicionalmente independientes dado H , entonces

$$P(E_1 \cap E_2 \mid H) = P(E_1 \mid H)P(E_2 \mid H).$$

Bajo esta hipótesis, la actualización con múltiples evidencias se simplifica.

No debe confundirse independencia ordinaria con independencia condicional.

6.13. Tasa base y posterior

El teorema de Bayes muestra que una gran verosimilitud no garantiza una gran probabilidad posterior. El valor de $P(B_i)$ influye necesariamente en la respuesta.

Por ello, en problemas de clasificación o diagnóstico, ignorar las probabilidades previas puede producir inferencias seriamente engañosas.

6.14. Relación con la probabilidad condicional

Bayes no introduce una nueva noción de probabilidad. Es una consecuencia algebraica directa de

$$P(A \cap B) = P(A)P(B \mid A) = P(B)P(A \mid B).$$

Siempre que $P(A) > 0$ y $P(B) > 0$,

$$P(B \mid A) = \frac{P(B)P(A \mid B)}{P(A)}.$$

La ley de la probabilidad total aparece cuando el denominador $P(A)$ debe expresarse en términos de una partición.

6.15. Ejercicios

1. Demuestra la ley de la probabilidad total para una partición de cuatro eventos.
2. Prueba el teorema de Bayes a partir de la definición de probabilidad condicional y la ley de probabilidad total.
3. Si B_1, B_2, B_3 forman una partición con probabilidades 0.2, 0.5, 0.3 y $P(A | B_i) = 0.1, 0.4, 0.7$, calcula $P(A)$ y las tres probabilidades posteriores.
4. Demuestra que las probabilidades posteriores obtenidas en el ejercicio anterior suman 1.
5. Deriva la forma de Bayes en términos de odds para dos hipótesis complementarias.
6. Sea $P(H) = p$, $P(E | H) = s$ y $P(E | H^c) = f$. Demuestra que

$$P(H | E) = \frac{ps}{ps + (1 - p)f}.$$

7. Analiza el límite de la expresión anterior cuando $p \rightarrow 0$ y cuando $p \rightarrow 1$.
8. Si $P(E | H) = P(E | H^c)$, demuestra que $P(H | E) = P(H)$.
9. Si una evidencia tiene razón de verosimilitudes igual a 1, interpreta su efecto sobre las odds previas.
10. **Reto** . Supón que E_1 y E_2 son condicionalmente independientes dado H y dado H^c . Deriva una expresión para las odds posteriores tras observar ambas evidencias.

6.16. Referencias del capítulo

El desarrollo teórico de particiones, ley de probabilidad total y teorema de Bayes sigue la formulación estándar de Devore (2016), Montgomery y Runger (2018), Walpole et al. (2012) y Johnson (2018). La notación se adapta al enfoque formal adoptado en este libro.

7 Variable aleatoria y función de distribución acumulada

7.1. Objetivos

En este capítulo se formaliza el concepto de variable aleatoria como función medible y se estudia la función de distribución acumulada como objeto fundamental asociado a cualquier variable aleatoria real.

7.2. Variable aleatoria

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Una **variable aleatoria real** es una función

$$X : \Omega \longrightarrow \mathbb{R}$$

tal que, para todo $x \in \mathbb{R}$,

$$\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F}.$$

Esta condición garantiza que los eventos definidos mediante desigualdades de X tienen probabilidad bien definida.

7.3. Interpretación mediante preimágenes

Para un conjunto $B \subseteq \mathbb{R}$, el evento asociado es la preimagen

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}.$$

Por ejemplo,

$$\{X \leq x\} = X^{-1}((-\infty, x]).$$

La aleatoriedad reside en el resultado ω ; la función X es determinista una vez definida.

7.4. Variables discretas

Una variable aleatoria es discreta cuando su imagen

$$X(\Omega)$$

es finita o numerable. Si sus valores son $x_1, x_2, \dots$, entonces

$$P(X = x_i)$$

determina su distribución.

7.5. Variables continuas

Una variable aleatoria se denomina continua cuando su distribución puede describirse mediante una densidad respecto de la medida de Lebesgue. Este concepto se formalizará posteriormente. Por ahora basta señalar que para variables continuas típicas,

$$P(X = x) = 0$$

para cada punto individual x .

7.6. Función de distribución acumulada

La **función de distribución acumulada** de X es

$$\boxed{F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.}$$

Toda variable aleatoria real induce una CDF y, recíprocamente, toda función que satisfaga las propiedades características de una CDF determina una distribución de probabilidad sobre $\mathbb{R}$.

7.7. Monotonía

Si $x < y$, entonces

$$\{X \leq x\} \subseteq \{X \leq y\}.$$

Por monotonía de la probabilidad,

$$F_X(x) \leq F_X(y).$$

Por tanto, F_X es no decreciente.

7.8. Límites en los extremos

Como los eventos

$$\{X \leq x\}$$

disminuyen hacia el evento vacío cuando $x \rightarrow -\infty$,

$$\lim_{x \rightarrow -\infty} F_X(x) = 0.$$

Análogamente, al crecer x los eventos $\{X \leq x\}$ aumentan hacia Ω , por lo que

$$\lim_{x \rightarrow \infty} F_X(x) = 1.$$

Estas conclusiones se apoyan en la continuidad de la medida de probabilidad demostrada en capítulos anteriores.

7.9. Continuidad por la derecha

7.9.1. Teorema

Toda función de distribución acumulada es continua por la derecha:

$$\lim_{h \downarrow 0} F_X(x+h) = F_X(x).$$

7.9.2. Demostración

Sea $x_n \downarrow x$. Los eventos

$$A_n = \{X \leq x_n\}$$

forman una sucesión decreciente y

$$\bigcap_{n=1}^{\infty} A_n = \{X \leq x\}.$$

Por continuidad desde arriba de la probabilidad,

$$P(A_n) \rightarrow P(X \leq x).$$

Por tanto,

$$F_X(x_n) \rightarrow F_X(x).$$

7.10. Límite por la izquierda y masa puntual

Definimos

$$F_X(x^-) = \lim_{t \uparrow x} F_X(t).$$

Entonces

$$P(X < x) = F_X(x^-).$$

Además,

$$P(X = x) = F_X(x) - F_X(x^-).$$

Por ello, los saltos de la CDF corresponden exactamente a masas puntuales de probabilidad.

7.11. Probabilidades de intervalos

Para $a < b$,

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

También,

$$P(X > b) = 1 - F_X(b),$$

$$P(a \leq X \leq b) = F_X(b) - F_X(a^-),$$

y

$$P(a < X < b) = F_X(b^-) - F_X(a).$$

Estas identidades muestran que la CDF contiene toda la información de la distribución.

7.12. Distribución inducida por una variable aleatoria

La variable X induce una medida de probabilidad P_X sobre $\mathbb{R}$ definida por

$$P_X(B) = P(X \in B)$$

para conjuntos borelianos B .

Esta medida se denomina **distribución** o **ley** de X .

La CDF puede escribirse como

$$F_X(x) = P_X((-\infty, x]).$$

7.13. Variables con la misma distribución

Dos variables aleatorias X y Y , incluso definidas sobre espacios muestrales diferentes, tienen la misma distribución si

$$F_X(x) = F_Y(x)$$

para todo $x \in \mathbb{R}$.

Se escribe habitualmente

$$X \stackrel{d}{=} Y.$$

Tener la misma distribución no significa que $X(\omega) = Y(\omega)$ punto por punto.

7.14. Ejemplo discreto

Sea

$$P(X = 0) = \frac{1}{4}, \quad P(X = 1) = \frac{1}{2}, \quad P(X = 2) = \frac{1}{4}.$$

Entonces

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1/4, & 0 \leq x < 1, \\ 3/4, & 1 \leq x < 2, \\ 1, & x \geq 2. \end{cases}$$

Los saltos en 0, 1, 2 tienen magnitudes $1/4, 1/2, 1/4$, respectivamente.

7.15. Caracterización de una función de distribución

Una función $F : \mathbb{R} \rightarrow [0, 1]$ es una función de distribución si satisface:

1. F es no decreciente;
2. F es continua por la derecha;
3. $\lim_{x \rightarrow -\infty} F(x) = 0$;
4. $\lim_{x \rightarrow \infty} F(x) = 1$.

Estas condiciones constituyen una caracterización fundamental de las distribuciones sobre la recta real.

7.16. Átomos y continuidad

Un punto x se denomina átomo de la distribución si

$$P(X = x) > 0.$$

Equivalente:

$$F_X(x) > F_X(x^-).$$

Una distribución sin átomos tiene una CDF continua. No toda CDF continua posee necesariamente una densidad, aunque las distribuciones continuas elementales que estudiaremos más adelante sí la tendrán.

7.17. Transformaciones y eventos

Para una función $g : \mathbb{R} \rightarrow \mathbb{R}$, podemos definir

$$Y = g(X).$$

Entonces

$$\{Y \leq y\} = \{g(X) \leq y\}.$$

El cálculo de la distribución de Y mediante preimágenes será el tema central del capítulo sobre funciones de una variable aleatoria.

7.18. Materiales complementarios del capítulo

Este libro teórico se acompaña de materiales computacionales en el volumen **Introducción a la Probabilidad con R y GeoGebra**. Para este capítulo se dispone de un cuaderno de Google Colab y de un cuaderno reproducible en R, en los que se visualizan transformaciones y funciones de distribución acumulada. Las presentaciones, videos e infografías se incorporarán conforme se proporcionen sus enlaces.

7.19. Ejercicios

1. Sea X el número de caras en dos lanzamientos de moneda. Escribe explícitamente la función $X : \Omega \rightarrow \mathbb{R}$.
2. Construye F_X para la variable anterior y verifica sus cuatro propiedades características.
3. Demuestra que F_X es no decreciente a partir de inclusión de eventos.
4. Demuestra que $P(X = x) = F_X(x) - F_X(x^-)$.
5. Prueba que $P(a < X \leq b) = F_X(b) - F_X(a)$.
6. Sea

$$F(x) = \begin{cases} 0, & x < 0, \\ 1 - e^{-x}, & x \geq 0. \end{cases}$$

Verifica que satisface las propiedades de una CDF. 7. Determina si

$$G(x) = \frac{1}{1 + e^{-x}}$$

puede ser una CDF y justifica. 8. Da un ejemplo de dos variables distintas con la misma distribución. 9. Si F_X es continua en x , demuestra que $P(X = x) = 0$. 10. **Reto** . Utiliza continuidad desde arriba para demostrar rigurosamente la continuidad por la derecha de una CDF.

7.20. Referencias del capítulo

El desarrollo formal de variables aleatorias, distribuciones inducidas y funciones de distribución acumulada sigue la formulación estándar de Devore (2016), Montgomery y Runger (2018), Walpole et al. (2012) y Johnson (2018).

8 Variables aleatorias discretas y función de masa de probabilidad

8.1. Objetivos

En este capítulo se formaliza el concepto de variable aleatoria discreta, su función de masa de probabilidad, el soporte de la distribución y la relación exacta entre la PMF y la función de distribución acumulada.

8.2. Variable aleatoria discreta

Sea

$$X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$$

una variable aleatoria. Diremos que X es **discreta** si existe un conjunto finito o numerable

$$S_X = \{x_1, x_2, \dots\} \subseteq \mathbb{R}$$

tal que

$$P(X \in S_X) = 1.$$

El conjunto

$$\mathcal{S}_X = \{x \in \mathbb{R} : P(X = x) > 0\}$$

se denomina **soporte efectivo** de la distribución.

8.3. Función de masa de probabilidad

La función de masa de probabilidad de X es

$$p_X(x) = P(X = x).$$

8.3.1. Proposición

Una función $p : \mathbb{R} \rightarrow [0, 1]$ es la PMF de alguna variable aleatoria discreta con soporte numerable S si y sólo si

$$p(x) \geq 0$$

para todo x y

$$\sum_{x \in S} p(x) = 1,$$

con $p(x) = 0$ fuera de S .

8.3.2. Demostración

Si $p = p_X$, la no negatividad se sigue de los axiomas de probabilidad. Como los eventos

$$\{X = x\}, \quad x \in S,$$

son mutuamente excluyentes y su unión tiene probabilidad 1,

$$1 = P(X \in S) = \sum_{x \in S} P(X = x) = \sum_{x \in S} p_X(x).$$

Recíprocamente, dada una sucesión de masas no negativas que suma 1, puede construirse un espacio muestral discreto con probabilidades puntuales iguales a esas masas y definir X como la aplicación identidad sobre el soporte.

8.4. Probabilidad de eventos definidos por X

Sea $A \subseteq \mathbb{R}$. Entonces

$$P(X \in A) = \sum_{x \in A \cap \mathcal{S}_X} p_X(x).$$

En particular,

$$P(a < X \leq b) = \sum_{a < x \leq b} p_X(x).$$

Esta identidad es la versión discreta de la regla de integración que aparecerá en variables continuas.

8.5. Distribución inducida por una variable discreta

La variable X induce una medida de probabilidad sobre $\mathbb{R}$ dada por

$$\mu_X(A) = P(X \in A).$$

En el caso discreto,

$$\mu_X(A) = \sum_{x \in A \cap \mathcal{S}_X} p_X(x).$$

Por tanto, la distribución completa queda determinada por las masas puntuales $p_X(x)$.

8.6. Relación con la función de distribución acumulada

La CDF es

$$F_X(t) = P(X \leq t).$$

Para una variable discreta,

$$F_X(t) = \sum_{x \leq t} p_X(x).$$

8.6.1. Proposición: saltos de la CDF

Para todo $x \in \mathbb{R}$,

$$P(X = x) = F_X(x) - F_X(x^-),$$

donde

$$F_X(x^-) = \lim_{t \uparrow x} F_X(t).$$

8.6.2. Demostración

Como

$$\{X \leq x\} = \{X < x\} \cup \{X = x\},$$

y los dos eventos son disjuntos,

$$F_X(x) = P(X < x) + P(X = x).$$

Además,

$$P(X < x) = F_X(x^-).$$

Por tanto,

$$P(X = x) = F_X(x) - F_X(x^-).$$

Así, los átomos de la distribución coinciden exactamente con los puntos de salto de la CDF.

8.7. Átomos y distribuciones discretas

Un punto x es un **átomo** de la distribución de X si

$$P(X = x) > 0.$$

Una distribución discreta está concentrada en un conjunto numerable de átomos.

Si el soporte es finito,

$$\mathcal{S}_X = \{x_1, \dots, x_n\},$$

entonces

$$\sum_{i=1}^n p_X(x_i) = 1.$$

Si el soporte es infinito numerable,

$$\sum_{i=1}^{\infty} p_X(x_i) = 1.$$

La convergencia de esta serie es parte esencial de la definición de la distribución.

8.8. Soporte y representación no única

Puede ocurrir que una función se describa sobre un conjunto más grande que el soporte efectivo. Por ejemplo, si se declara

$$p(0) = 0, \quad p(1) = 0.4, \quad p(2) = 0.6,$$

el soporte efectivo es

$$\{1, 2\},$$

no $\{0, 1, 2\}$.

Esta distinción resulta útil en formulaciones paramétricas.

8.9. Construcción mediante transformación

Sea Y una variable aleatoria discreta con PMF p_Y y sea

$$X = g(Y).$$

Entonces

$$P(X = x) = P(g(Y) = x)$$

y, por tanto,

$$p_X(x) = \sum_{y:g(y)=x} p_Y(y).$$

Esta fórmula agrega las masas de todos los valores de Y que son enviados al mismo valor x .

8.9.1. Ejemplo

Sea Y uniforme sobre

$$\{-2, -1, 0, 1, 2\}$$

y defina

$$X = Y^2.$$

Entonces

$$\mathcal{S}_X = \{0, 1, 4\}$$

y

$$p_X(0) = \frac{1}{5},$$

$$p_X(1) = \frac{2}{5},$$

$$p_X(4) = \frac{2}{5}.$$

Las probabilidades de $Y = 1$ y $Y = -1$ se suman porque ambas preimágenes producen $X = 1$.

8.10. PMF a partir de una CDF escalonada

Si una CDF tiene saltos en puntos

$$x_1 < x_2 < \cdots,$$

entonces

$$p_X(x_i) = F_X(x_i) - F_X(x_i^-).$$

Por tanto, para distribuciones discretas, PMF y CDF contienen exactamente la misma información.

8.11. Variables con soporte infinito numerable

Considere

$$p_X(k) = \frac{1}{2^k}, \quad k = 1, 2, 3, \dots$$

Como

$$\sum_{k=1}^{\infty} \frac{1}{2^k} = 1,$$

la función define una PMF válida.

La CDF para $n \in \mathbb{N}$ es

$$F_X(n) = \sum_{k=1}^n \frac{1}{2^k} = 1 - \frac{1}{2^n}.$$

Y para t no entero,

$$F_X(t) = F_X(\lfloor t \rfloor)$$

si $t \geq 1$.

8.12. Unicidad de la PMF

Si dos variables aleatorias discretas X y Y tienen la misma PMF,

$$p_X(x) = p_Y(x)$$

para todo x , entonces tienen la misma distribución:

$$P(X \in A) = P(Y \in A)$$

para todo conjunto boreliano A .

No es necesario que X y Y estén definidas sobre el mismo espacio muestral ni que sean la misma función.

8.13. Distribución conjunta de valores discretos y eventos

Para cualquier subconjunto A del soporte,

$$P(X \in A) = \sum_{x \in A} p_X(x).$$

Esta propiedad expresa que la medida inducida por X es completamente atómica.

8.14. Comparación conceptual con el caso continuo

En el caso discreto puede existir

$$P(X = x) > 0.$$

En el caso continuo típico,

$$P(X = x) = 0$$

para todo x .

Por ello, una PMF asigna masa a puntos, mientras que una densidad continua asignará probabilidad a intervalos mediante integrales.

8.15. Ejercicios

1. Sea $p(0) = 0.2$, $p(1) = 0.5$ y $p(2) = 0.3$. Verifica que define una PMF y construye la CDF completa.
2. Sea $p_X(k) = c/3^k$ para $k = 1, 2, \dots$. Determina c .
3. Demuestra que si X es discreta, entonces el conjunto de puntos x tales que $P(X = x) > 0$ es a lo sumo numerable.
4. Sea X con soporte $\{-1, 0, 1\}$ y masas $0.25, 0.5, 0.25$. Define $Y = X^2$ y determina la PMF de Y .
5. Prueba la fórmula

$$p_X(x) = F_X(x) - F_X(x^-).$$

6. Si una CDF tiene saltos de tamaño $0.1, 0.2, 0.3$ y 0.4 en $x = 0, 1, 3, 7$, determina la PMF.
7. Construye una variable aleatoria discreta con soporte infinito numerable cuya PMF sea proporcional a $1/k^2$.
8. Explica por qué no puede existir una variable discreta con un número no numerable de puntos con masa estrictamente positiva.
9. Si X y Y tienen la misma PMF, demuestra que tienen la misma CDF.
10. **Reto** . Sea X discreta y g una función cualquiera. Demuestra que

$$p_{g(X)}(y) = \sum_{x:g(x)=y} p_X(x).$$

8.16. Referencias del capítulo

El desarrollo formal de variables aleatorias discretas, distribuciones atómicas, PMF y su relación con la CDF sigue la formulación estándar de Devore (2016), Montgomery y Runger (2018), Walpole et al. (2012) y Johnson (2018), adaptada al nivel teórico de este volumen.

9 Variables aleatorias continuas y función de densidad

9.1. Objetivos

En este capítulo se formalizan las variables aleatorias absolutamente continuas, sus funciones de densidad y su relación con la función de distribución acumulada. Se enfatizan las propiedades analíticas que distinguen el caso continuo del discreto.

9.2. Variables aleatorias absolutamente continuas

Sea X una variable aleatoria definida sobre $(\Omega, \mathcal{F}, P)$. Decimos que X es **absolutamente continua** si existe una función integrable

$$f_X : \mathbb{R} \rightarrow [0, \infty)$$

tal que, para todo conjunto boreliano $A \subseteq \mathbb{R}$,

$$P(X \in A) = \int_A f_X(x) dx.$$

La función f_X se denomina **densidad de probabilidad** de X .

9.3. Condiciones básicas de una densidad

Toda densidad satisface

$$f_X(x) \geq 0$$

para casi todo x , y

$$\int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Recíprocamente, toda función medible no negativa con integral total 1 define una distribución absolutamente continua.

9.4. Probabilidad de intervalos

Para $a < b$,

$$P(a < X \leq b) = \int_a^b f_X(x) dx.$$

Como los conjuntos de un solo punto tienen medida de Lebesgue cero,

$$P(X = x) = 0$$

para todo $x \in \mathbb{R}$.

Por ello,

$$P(a < X < b) = P(a \leq X \leq b) = P(a < X \leq b).$$

9.5. La densidad no es una probabilidad puntual

En general,

$$f_X(x) \neq P(X = x).$$

La densidad describe cómo se distribuye localmente la probabilidad respecto de la medida de Lebesgue. Su valor puntual puede ser mayor que 1 sin contradicción, siempre que la integral total permanezca igual a 1.

9.6. Función de distribución acumulada

La CDF de X es

$$F_X(x) = P(X \leq x).$$

Si X es absolutamente continua,

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

En consecuencia, F_X es absolutamente continua y

$$F'_X(x) = f_X(x)$$

para casi todo x .

9.7. Recuperación de probabilidades desde la CDF

Para $a < b$,

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

Como $P(X = a) = 0$,

$$P(a < X < b) = F_X(b) - F_X(a).$$

También

$$P(X > x) = 1 - F_X(x).$$

9.8. Densidad a partir de una CDF

Si una CDF F es absolutamente continua, entonces existe una función integrable f tal que

$$F(x) = \int_{-\infty}^x f(t) dt.$$

Además,

$$f(x) = F'(x)$$

casi en todas partes.

No toda CDF continua posee necesariamente una densidad; la continuidad por sí sola es una condición más débil que la absoluta continuidad.

9.9. Ejemplo normalizado

Sea

$$f(x) = \begin{cases} cx, & 0 \leq x \leq 2, \\ 0, & \text{en otro caso.} \end{cases}$$

La condición

$$\int_0^2 cx \, dx = 1$$

produce

$$c = \frac{1}{2}.$$

Por tanto,

$$f(x) = \frac{x}{2}, \quad 0 \leq x \leq 2.$$

La CDF es

$$F(x) = \begin{cases} 0, & x < 0, \\ \frac{x^2}{4}, & 0 \leq x \leq 2, \\ 1, & x > 2. \end{cases}$$

9.10. Propiedad de conjuntos de medida cero

Si $N \subseteq \mathbb{R}$ tiene medida de Lebesgue cero y X es absolutamente continua, entonces

$$P(X \in N) = 0.$$

Esto incluye todos los conjuntos finitos y numerables. Así, una variable absolutamente continua asigna probabilidad cero a cualquier conjunto numerable de valores.

9.11. Comparación formal con el caso discreto

En el caso discreto,

$$P(X = x) = p_X(x)$$

puede ser positivo.

En el caso absolutamente continuo,

$$P(X = x) = 0$$

para todo x .

La suma

$$\sum_x p_X(x)$$

del caso discreto es reemplazada por la integral

$$\int f_X(x) dx.$$

9.12. Soporte de una distribución continua

Una noción útil de soporte es el cierre del conjunto donde la densidad es positiva. Si

$$f_X(x) > 0$$

sólo para $x \in (a, b)$, entonces el soporte puede identificarse con $[a, b]$ bajo condiciones regulares.

9.13. Unicidad casi en todas partes

Si dos densidades f y g generan la misma distribución, entonces

$$f(x) = g(x)$$

para casi todo x .

Es decir, pueden diferir en un conjunto de medida cero sin alterar ninguna probabilidad.

9.14. Transformaciones monótonas

Sea $Y = g(X)$, donde g es estrictamente monótona, diferenciable y con inversa diferenciable. Si X tiene densidad f_X , entonces

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|.$$

Esta fórmula se estudiará con mayor detalle al abordar funciones de variables aleatorias.

9.15. Ejemplo de transformación

Si X tiene densidad

$$f_X(x) = 2x, \quad 0 < x < 1,$$

y definimos

$$Y = X^2,$$

entonces

$$g^{-1}(y) = \sqrt{y},$$

y

$$\frac{d}{dy}g^{-1}(y) = \frac{1}{2\sqrt{y}}.$$

Por tanto,

$$f_Y(y) = 2\sqrt{y} \cdot \frac{1}{2\sqrt{y}} = 1,$$

para $0 < y < 1$.

Así, Y tiene densidad uniforme sobre $(0, 1)$.

9.16. Ejercicios

1. Demuestra que si $f \geq 0$ y $\int_{-\infty}^{\infty} f(x)dx = 1$, entonces $P(A) = \int_A f(x)dx$ define una medida de probabilidad sobre los borelianos.
2. Prueba que una variable absolutamente continua satisface $P(X = x) = 0$ para todo x .
3. Sea $f(x) = c(1 + x)$ para $0 \leq x \leq 1$. Determina c y la CDF correspondiente.
4. Demuestra que, para una variable absolutamente continua, incluir o excluir los extremos de un intervalo no cambia su probabilidad.

5. Sea $F(x) = x^3$ para $0 \leq x \leq 1$, con las extensiones usuales fuera del intervalo. Determina la densidad.
6. Explica por qué modificar una densidad en un solo punto no cambia la distribución.
7. Si X tiene densidad $2x$ en $(0, 1)$ y $Y = X^2$, deriva formalmente la densidad de Y .
8. Prueba que si N es numerable y X es absolutamente continua, entonces $P(X \in N) = 0$.
9. Da un ejemplo de una CDF continua que no sea absolutamente continua y explica por qué no admite una densidad ordinaria.
10. **Reto** . Demuestra que dos densidades que generan la misma CDF son iguales casi en todas partes.

9.17. Referencias del capítulo

El desarrollo teórico de variables absolutamente continuas, densidades y funciones de distribución sigue la formulación estándar de Devore (2016), Montgomery y Runger (2018), Walpole et al. (2012) y Johnson (2018), adaptada al nivel formal de este volumen.

Referencias

Devore, Jay L. 2016. *Probability and Statistics for Engineering and the Sciences*. 9.^a ed. Cengage Learning.

Johnson, Richard A. 2018. *Miller & Freund's Probability and Statistics for Engineers*. 9.^a ed. Pearson.

Montgomery, Douglas C., y George C. Runger. 2018. *Applied Statistics and Probability for Engineers*. 7.^a ed. Wiley.

Walpole, Ronald E., Raymond H. Myers, Sharon L. Myers, y Keying Ye. 2012. *Probabilidad y estadística para ingeniería y ciencias*. 9.^a ed. Pearson.