

Fundamentos Teóricos de Introducción a la Probabilidad

*Conceptos, teoremas, demostraciones
y modelos probabilísticos*

Jesús Gilberto Rodríguez Escobedo


$$(\Omega, \mathcal{F}, P)$$

$$\Omega \neq \emptyset$$

$$\mathcal{F} \subseteq 2^\Omega$$

$$\bullet \Omega \in \mathcal{F}$$

$$\bullet A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$$




$$A^c = \Omega \setminus A$$

$$A \cup B$$

$$A \cap B$$

$$A \setminus B = A \cap B^c$$

$$A \Delta B = (A \setminus B) \cup (B \setminus A)$$



Teorema de la Probabilidad Total

$$P(B) = P(A)P(B|A) + P(A^c)P(B|A^c)$$

Teorema de Bayes

$$P(A|B) = P(B|A)P(A)/P(B)$$


Independencia

$$A \perp B \Leftrightarrow P(A \cap B) = P(A)P(B)$$

$$n! = 1 \cdot 2 \cdot \dots \cdot n$$

$$C(n, k) = n! / [k!(n-k)!]$$

$$P(A) = |A|/|\Omega| \text{ (caso finito)}$$



$$E(X) = \sum x P(X=x)$$

$$E(aX+b) = aE(X) + b$$

$$\begin{aligned} \text{Var}(X) &= E[(X - E(X))^2] \\ &= E(X^2) - [E(X)]^2 \end{aligned}$$

$\mathcal{F}$ es una σ -álgebra sobre Ω si:

$$(i) \Omega \in \mathcal{F}$$

$$(ii) A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$$

$$(iii) \{A_n\} \subseteq \mathcal{F} \Rightarrow \bigcup A_n \in \mathcal{F}$$

Tabla de contenidos

Portada	16
Bienvenida	17
Presentación	18
Introducción	19
Notación general	20
1 Incertidumbre y modelos probabilísticos	21
1.1 Objetivos	21
1.2 Fenómenos deterministas y aleatorios	21
1.3 Experimento aleatorio	21
1.4 Regularidad estadística	22
1.5 Modelo probabilístico	22
1.6 Probabilidad como modelo, no como predicción exacta	23
1.7 Papel de la probabilidad en ingeniería y ciencias	23
1.8 Ideas clave	23
1.9 Ejercicios	23
1.10 Referencias del capítulo	24
2 Espacios muestrales y álgebra de eventos	25
2.1 Objetivos	25
2.2 Lenguaje de conjuntos	25
2.2.1 Inclusión e igualdad	25
2.2.2 Conjunto vacío y conjunto potencia	26
2.2.3 Producto cartesiano	26
2.3 Operaciones con conjuntos	27
2.4 Propiedades del álgebra de conjuntos	27
2.4.1 Leyes conmutativas	27
2.4.2 Leyes asociativas	28
2.4.3 Leyes distributivas	28
2.4.4 Leyes de identidad y complemento	28

2.4.5	Leyes de De Morgan	28
2.5	Demostraciones por pertenencia	29
2.5.1	Primera ley de De Morgan	29
2.5.2	Ley distributiva	29
2.6	Experimento aleatorio y espacio muestral	30
2.6.1	Ejemplo	30
2.7	Clasificación de espacios muestrales	30
2.7.1	Espacio finito	30
2.7.2	Espacio infinito numerable	31
2.7.3	Espacio no numerable	31
2.8	Eventos como subconjuntos	31
2.8.1	Ejemplo	32
2.9	Eventos disjuntos y familias exhaustivas	32
2.10	Particiones	33
2.10.1	Ejemplo	33
2.11	Familias de eventos	33
2.11.1	Definición: sigma-álgebra	34
2.12	Ejemplo integrador	34
2.13	Proposición: caracterización de la inclusión	35
2.13.1	Demostración	36
2.14	Errores conceptuales frecuentes	36
2.15	Ideas clave	36
2.16	Ejercicios	36
2.16.1	Conceptos y operaciones	36
2.16.2	Demostraciones	37
2.16.3	Modelación	37
2.16.4	Profundización	37
2.17	Referencias del capítulo	37
3	Técnicas de conteo y enumeración	38
3.1	Objetivos	38
3.2	Cardinalidad de conjuntos finitos	38
3.3	Principio aditivo	38
3.3.1	Demostración	39
3.4	Principio multiplicativo	39
3.4.1	Demostración	39
3.5	Secuencias con repetición	40
3.6	Factorial	40
3.7	Permutaciones de n objetos distintos	40
3.7.1	Teorema	41
3.7.2	Demostración	41

3.8	Arreglos de r objetos tomados de n	41
3.8.1	Teorema	41
3.8.2	Demostración	41
3.9	Combinaciones	42
3.9.1	Teorema	42
3.9.2	Demostración	42
3.10	Simetría de los coeficientes binomiales	42
3.10.1	Interpretación combinatoria	42
3.11	Identidad de Pascal	43
3.11.1	Demostración combinatoria	43
3.12	Permutaciones con repetición	43
3.12.1	Justificación	44
3.13	Coficiente multinomial	44
3.14	Ejemplo: palabras binarias	44
3.15	Ejemplo: selección de componentes	45
3.16	Relación con espacios muestrales	45
3.17	Ideas clave	46
3.18	Ejercicios	46
3.19	Referencias del capítulo	47
4	Axiomas y propiedades de la probabilidad	48
4.1	Propósitos de aprendizaje	48
4.2	Espacios de probabilidad	48
4.3	Axiomas de Kolmogórov	49
4.3.1	Axioma 1: no negatividad	49
4.3.2	Axioma 2: normalización	49
4.3.3	Axioma 3: aditividad numerable	49
4.4	Probabilidad del conjunto vacío	50
4.4.1	Proposición	50
4.4.2	Demostración	50
4.5	Aditividad finita	50
4.5.1	Proposición	50
4.5.2	Justificación	51
4.6	Regla del complemento	51
4.6.1	Proposición	51
4.6.2	Demostración	51
4.7	Monotonía	52
4.7.1	Teorema	52
4.7.2	Demostración	52
4.7.3	Corolario	52

4.8	Probabilidad de una diferencia	53
4.8.1	Proposición	53
4.8.2	Demostración	53
4.9	Fórmula de la unión de dos eventos	53
4.9.1	Teorema	53
4.9.2	Demostración	54
4.10	Cotas de Fréchet para dos eventos	54
4.11	Subaditividad	55
4.11.1	Teorema	55
4.11.2	Demostración	55
4.11.3	Generalización numerable	56
4.12	Inclusión-exclusión para tres eventos	56
4.13	Inclusión-exclusión finita	56
4.14	Continuidad de la probabilidad	56
4.14.1	Continuidad desde abajo	57
4.14.2	Continuidad desde arriba	57
4.15	Espacios finitos	58
4.16	Ejemplo formal	59
4.17	Observación conceptual: probabilidad cero e imposibilidad	60
4.18	Errores conceptuales frecuentes	60
4.19	Ejercicios	60
4.20	Referencias del capítulo	61
5	Probabilidad condicional e independencia	62
5.1	Propósitos del capítulo	62
5.2	Probabilidad condicional	62
5.2.1	Propiedad de normalización	62
5.2.2	Probabilidad condicional como medida	63
5.3	Regla del producto	63
5.4	Regla de la cadena	64
5.4.1	Demostración para tres eventos	64
5.5	Independencia de dos eventos	64
5.5.1	Equivalencia con probabilidad condicional	65
5.5.2	Demostración	65
5.6	Independencia y complementos	65
5.6.1	Demostración para A^c y B	66
5.7	Exclusión mutua e independencia	66
5.8	Independencia de varios eventos	67
5.9	Ejemplo clásico: independencia por pares sin independencia mutua	67
5.10	Dependencia inducida por muestreo sin reemplazo	68
5.11	Observación sobre eventos de probabilidad cero	69

5.12	Proposición: criterio de independencia mediante complementos	69
5.13	Ejercicios conceptuales y de demostración	69
5.14	Referencias del capítulo	70
6	Particiones, probabilidad total y teorema de Bayes	71
6.1	Objetivos	71
6.2	Particiones del espacio muestral	71
6.2.1	Propiedad fundamental	72
6.3	Ley de la probabilidad total	72
6.3.1	Teorema	72
6.3.2	Demostración	72
6.4	Caso binario	73
6.5	Teorema de Bayes	73
6.5.1	Teorema	73
6.5.2	Demostración	73
6.6	Forma proporcional	74
6.7	Normalización de las probabilidades posteriores	74
6.7.1	Demostración	75
6.8	Odds y forma de Bayes para dos hipótesis	75
6.9	Ejemplo algebraico	76
6.10	Particiones numerables	77
6.11	Actualización secuencial	77
6.12	Evidencia condicionalmente independiente	78
6.13	Tasa base y posterior	78
6.14	Relación con la probabilidad condicional	78
6.15	Ejercicios	79
6.16	Referencias del capítulo	79
7	Variable aleatoria y función de distribución acumulada	80
7.1	Objetivos	80
7.2	Variable aleatoria	80
7.3	Interpretación mediante preimágenes	80
7.4	Variables discretas	81
7.5	Variables continuas	81
7.6	Función de distribución acumulada	81
7.7	Monotonía	82
7.8	Límites en los extremos	82
7.9	Continuidad por la derecha	83
7.9.1	Teorema	83
7.9.2	Demostración	83
7.10	Límite por la izquierda y masa puntual	84

7.11	Probabilidades de intervalos	84
7.12	Distribución inducida por una variable aleatoria	85
7.13	Variables con la misma distribución	85
7.14	Ejemplo discreto	86
7.15	Caracterización de una función de distribución	86
7.16	Átomos y continuidad	86
7.17	Transformaciones y eventos	87
7.18	Referencias del capítulo	87
8	Variables aleatorias discretas y función de masa de probabilidad	88
8.1	Objetivos	88
8.2	Variable aleatoria discreta	88
8.3	Función de masa de probabilidad	89
8.3.1	Proposición	89
8.3.2	Demostración	89
8.4	Probabilidad de eventos definidos por X	90
8.5	Distribución inducida por una variable discreta	90
8.6	Relación con la función de distribución acumulada	91
8.6.1	Proposición: saltos de la CDF	91
8.6.2	Demostración	91
8.7	Átomos y distribuciones discretas	92
8.8	Soporte y representación no única	93
8.9	Construcción mediante transformación	93
8.9.1	Ejemplo	94
8.10	PMF a partir de una CDF escalonada	94
8.11	Variables con soporte infinito numerable	95
8.12	Unicidad de la PMF	95
8.13	Distribución conjunta de valores discretos y eventos	96
8.14	Comparación conceptual con el caso continuo	96
8.15	Ejercicios	97
8.16	Referencias del capítulo	97
9	Variables aleatorias continuas y función de densidad	98
9.1	Objetivos	98
9.2	Variables aleatorias absolutamente continuas	98
9.3	Condiciones básicas de una densidad	98
9.4	Probabilidad de intervalos	99
9.5	La densidad no es una probabilidad puntual	99
9.6	Función de distribución acumulada	100
9.7	Recuperación de probabilidades desde la CDF	100
9.8	Densidad a partir de una CDF	101

9.9	Ejemplo normalizado	101
9.10	Propiedad de conjuntos de medida cero	102
9.11	Comparación formal con el caso discreto	102
9.12	Soporte de una distribución continua	103
9.13	Unicidad casi en todas partes	103
9.14	Transformaciones monótonas	103
9.15	Ejemplo de transformación	104
9.16	Ejercicios	104
9.17	Referencias del capítulo	105
10	Esperanza matemática, momentos, varianza y desigualdades probabilísticas	106
10.1	Objetivos	106
10.2	Esperanza de una variable aleatoria	106
10.2.1	Caso discreto	106
10.2.2	Caso absolutamente continuo	107
10.3	Esperanza de funciones de una variable	107
10.4	Linealidad de la esperanza	107
10.4.1	Demostración	108
10.5	Variables indicadoras	108
10.5.1	Demostración	108
10.6	Momentos	109
10.7	Varianza	109
10.8	Fórmula alternativa de la varianza	110
10.8.1	Demostración	110
10.9	Caracterización de varianza nula	110
10.10	Transformaciones afines	111
10.10.1	Demostración	111
10.11	Covarianza y varianza de una suma	111
10.12	Desigualdad de Markov	112
10.12.1	Demostración	112
10.13	Desigualdad de Chebyshev	113
10.13.1	Demostración a partir de Markov	113
10.14	Consecuencia: concentración alrededor de la media	114
10.15	Relación entre Markov y Chebyshev	114
10.16	Ejemplo teórico: variable de Bernoulli	115
10.17	Ejemplo teórico: variable uniforme continua	115
10.18	Existencia de momentos	116
10.19	Momentos y forma de una distribución	116
10.20	Referencias del capítulo	116

11 Distribuciones discretas especiales I: Bernoulli, binomial, geométrica y binomial negativa	117
11.1 Objetivos	117
11.2 Variable de Bernoulli	117
11.3 La binomial como suma de Bernoulli	118
11.4 Momentos de la binomial	119
11.5 Cociente entre masas consecutivas	119
11.6 Distribución geométrica	119
11.7 Función de supervivencia geométrica	120
11.8 Propiedad sin memoria	120
11.9 Esperanza de la geométrica	121
11.10 Distribución binomial negativa	121
11.11 Derivación de la PMF binomial negativa	122
11.12 Representación como suma de geométricas	122
11.13 Relación con el conteo de fracasos	123
11.14 Relaciones entre las cuatro familias	123
11.15 Selección estructural del modelo	123
11.16 Ejercicios teóricos	124
11.17 Referencias del capítulo	124
12 Distribuciones discretas especiales II: hipergeométrica y Poisson	125
12.1 Objetivos	125
12.2 Distribución hipergeométrica	125
12.2.1 Normalización	125
12.3 Media de la hipergeométrica	126
12.4 Varianza de la hipergeométrica	126
12.5 Aproximación binomial de la hipergeométrica	127
12.6 Distribución de Poisson	127
12.7 Normalización	128
12.8 Media y varianza de Poisson	128
12.9 Función generadora de probabilidades	129
12.10 Suma de Poisson independientes	129
12.11 Límite de Poisson de la binomial	130
12.12 Interpretación de λ	131
12.13 Diferencias estructurales	131
12.14 Ejercicios	131
12.15 Referencias del capítulo	132
13 Distribuciones continuas especiales I: uniforme, exponencial y normal	133
13.1 Objetivos	133
13.2 Distribución uniforme	133

13.3	Transformación afín de una uniforme	134
13.4	Distribución exponencial	134
13.5	Propiedad sin memoria	135
13.6	Distribución normal	136
13.7	Normal estándar	136
13.8	Estandarización	137
13.9	Media y varianza de la normal	137
13.10	Transformaciones afines	138
13.11	Cuantiles	138
13.12	Simetría de la CDF normal	139
13.13	Comparación estructural	139
13.14	Ejercicios	139
13.15	Referencias del capítulo	140
14	Distribuciones continuas especiales II: Gamma, Weibull y Beta	141
14.1	Objetivos	141
15	Distribución Gamma	142
15.1	Función Gamma	142
15.2	Normalización	142
15.3	Momentos	143
15.4	Caso exponencial	143
15.5	Suma de variables Gamma	144
16	Distribución Weibull	145
16.1	Función de distribución	145
16.2	Tasa de riesgo	145
16.3	Relación con la exponencial	146
16.4	Momentos de Weibull	146
16.5	Transformación exponencial	146
17	Distribución Beta	147
17.1	Relación Beta-Gamma	147
17.2	Normalización	147
17.3	Momentos	148
17.4	Simetría	148
17.5	Caso uniforme	149
17.6	Construcción Beta mediante variables Gamma	149
17.7	Comparación estructural	149
17.8	Ejercicios teóricos	150
17.9	Referencias del capítulo	150

18 Variables aleatorias conjuntas, distribuciones marginales y condicionales	151
18.1 Objetivos	151
18.2 Vectores aleatorios	151
18.3 Función de distribución conjunta	152
18.4 Distribuciones marginales	152
19 Caso discreto	154
19.1 Probabilidades sobre subconjuntos	154
19.2 Distribución condicional discreta	155
20 Caso absolutamente continuo	156
20.1 Densidades marginales	156
20.2 Densidades condicionales	157
21 Ejemplo triangular	158
22 Independencia	159
22.1 Caso discreto	159
22.2 Caso continuo	159
22.3 Demostración de la factorización condicional	160
23 El soporte conjunto y la independencia	161
24 Teorema de Tonelli y Fubini	162
25 Una misma pareja de marginales, distintas conjuntas	163
26 Probabilidades condicionales como familia de leyes	164
27 Extensión a más dimensiones	165
28 Resumen teórico	166
29 Ejercicios teóricos	167
29.1 Referencias del capítulo	167
30 Esperanza conjunta, covarianza y correlación	168
30.1 Planteamiento	168
30.2 Esperanza de funciones de dos variables	168
30.3 Teorema de linealidad	169
30.3.1 Demostración	169
30.4 El momento mixto $E[XY]$	169
30.4.1 Demostración en el caso con densidades	170

30.5	Definición de covarianza	170
30.6	Propiedades de la covarianza	170
30.7	Varianza de una suma	171
30.7.1	Demostración	171
30.8	Sumas de muchas variables	172
30.9	Independencia e incorrelación	172
30.9.1	Teorema	172
30.9.2	Demostración	172
30.10	Contraejemplo: incorrelación sin independencia	173
30.11	Coefficiente de correlación	173
30.12	Cota de correlación	174
30.12.1	Demostración mediante Cauchy–Schwarz	174
30.13	Caso de igualdad	174
30.14	Invariancia frente a transformaciones afines	175
30.15	Matriz de covarianzas	175
30.16	Positividad semidefinida	176
30.17	Ejemplo continuo triangular	176
30.18	Mapa conceptual	177
30.19	Ejercicios teóricos	177
30.20	Referencias del capítulo	177
31	Transformaciones de variables aleatorias	178
31.1	Planteamiento general	178
31.2	Ley inducida	178
31.3	Caso discreto	178
31.4	Método de la función de distribución	179
31.5	Transformación monótona creciente	179
31.6	Transformación monótona decreciente	179
31.7	Transformación afín	180
31.8	Transformación no inyectiva	180
31.9	Ejemplo: cuadrado de una variable uniforme simétrica	181
31.10	Transformada inversa	181
31.10.1	Demostración	182
31.11	Ejemplo exponencial	182
31.12	Convolución discreta	182
31.13	Convolución continua	183
31.13.1	Derivación mediante transformación	183
31.14	Transformaciones bidimensionales	184
31.15	El Jacobiano	184
31.16	Transformación del soporte	184
31.17	Caso de transformaciones múltiples	185

31.18	Convolución y normalización	185
31.19	Momentos bajo transformaciones	185
31.20	Mapa conceptual	186
31.21	Ejercicios teóricos	186
31.22	Referencias del capítulo	187
Referencias		188

Listado de Figuras

Listado de Tablas

Portada

Este libro desarrolla los fundamentos matemáticos de la probabilidad con énfasis en definiciones, teoremas, demostraciones y construcción rigurosa de modelos.

La exposición avanza desde el lenguaje de conjuntos y los axiomas de probabilidad hasta los modelos probabilísticos que se estudiarán en capítulos posteriores.

Bienvenida

La teoría de la probabilidad estudia matemáticamente fenómenos en los que intervienen incertidumbre y variación.

Este libro busca construir los conceptos desde sus fundamentos: conjuntos y eventos, axiomas de probabilidad, independencia, variables aleatorias, esperanza, distribuciones y resultados límite.

La intención es que cada fórmula aparezca acompañada de su significado, condiciones de validez y relación con otros resultados.

Presentación

La obra sigue el recorrido de un primer curso universitario de probabilidad: conjuntos, espacios muestrales, eventos, axiomas, probabilidad condicional, Bayes, variables aleatorias, esperanza, distribuciones conjuntas y distribuciones discretas y continuas importantes.

A diferencia del libro aplicado, aquí se desarrollarán con mayor detalle las definiciones, propiedades y demostraciones, procurando mantener un nivel accesible para estudiantes de ingeniería y ciencias con formación en cálculo.

Introducción

La probabilidad transforma la incertidumbre en un objeto matemático susceptible de análisis. Su punto de partida es describir los resultados posibles de un experimento y representar mediante conjuntos los sucesos de interés. A partir de ahí se construye una medida de probabilidad y se estudian sus consecuencias.

El desarrollo será progresivo. Primero estableceremos el lenguaje de experimentos, espacios muestrales y eventos; después formularemos los axiomas y sus propiedades; más adelante introduciremos variables aleatorias, funciones de distribución, esperanza, momentos y distribuciones conjuntas.

El objetivo no será únicamente aplicar fórmulas, sino comprender por qué funcionan y bajo qué hipótesis pueden utilizarse.

Notación general

- Ω : espacio muestral.
- $\mathcal{F}$: colección de eventos.
- A, B, C : eventos.
- A^c : complemento de A .
- P : medida de probabilidad.
- $P(A | B)$: probabilidad condicional.
- X, Y : variables aleatorias.
- F_X : función de distribución de X .
- $E(X)$: esperanza matemática.
- $\text{Var}(X)$: varianza.
- $\text{Cov}(X, Y)$: covarianza.
- ρ_{XY} : coeficiente de correlación.

1 Incertidumbre y modelos probabilísticos

1.1. Objetivos

Al finalizar este capítulo, el estudiante podrá distinguir fenómenos deterministas y aleatorios, identificar los elementos básicos de un experimento aleatorio y explicar el papel de un modelo probabilístico.

1.2. Fenómenos deterministas y aleatorios

Un fenómeno se denomina **determinista** cuando, dentro del modelo adoptado, unas mismas condiciones iniciales producen el mismo resultado. En contraste, un fenómeno **aleatorio** puede producir resultados distintos aun cuando el procedimiento se repita bajo condiciones esencialmente iguales.

La aleatoriedad puede originarse en variaciones no controladas, incertidumbre de medición, complejidad del sistema o información incompleta.

1.3. Experimento aleatorio

Un **experimento aleatorio** es un procedimiento cuyo resultado específico no puede predecirse con certeza antes de realizarlo, aunque sí es posible describir el conjunto de resultados que pueden ocurrir.

Más adelante llamaremos **espacio muestral** a ese conjunto de resultados posibles.

1.4. Regularidad estadística

Aunque una repetición individual sea impredecible, las repeticiones numerosas de un experimento suelen mostrar regularidades. Esta observación constituye una de las motivaciones fundamentales para introducir probabilidades numéricas.

Si A es un evento y después de n repeticiones ocurre n_A veces, definimos la frecuencia relativa

$$f_n(A) = \frac{n_A}{n}.$$

El comportamiento de $f_n(A)$ cuando n aumenta será estudiado posteriormente mediante resultados límite.

1.5. Modelo probabilístico

Un modelo probabilístico elemental consta de dos componentes:

1. una descripción de los resultados posibles;
2. una regla que asigna probabilidades a los eventos.

En una formulación más avanzada, un espacio de probabilidad se representa mediante la terna

$$(\Omega, \mathcal{F}, P),$$

donde Ω es el espacio muestral, $\mathcal{F}$ es una colección adecuada de eventos y P es una medida de probabilidad.

En este libro introduciremos primero estas ideas de manera elemental y más adelante precisaremos las propiedades que debe satisfacer P .

1.6. Probabilidad como modelo, no como predicción exacta

Asignar una probabilidad a un evento no significa predecir el resultado de una realización particular. La probabilidad describe la incertidumbre dentro de un modelo.

Por ejemplo, si una moneda ideal se modela con

$$P(\text{cara}) = \frac{1}{2},$$

esto no implica que en diez lanzamientos aparezcan exactamente cinco caras. La afirmación se refiere al modelo y a su comportamiento probabilístico, no a una secuencia concreta.

1.7. Papel de la probabilidad en ingeniería y ciencias

Los modelos probabilísticos aparecen cuando se estudian confiabilidad de componentes, errores de transmisión, tiempos de espera, defectos de fabricación, mediciones ambientales, ruido en señales y muchos otros fenómenos con variabilidad.

La utilidad de la teoría radica en que permite pasar de una descripción cualitativa de la incertidumbre a cálculos y resultados matemáticos verificables.

1.8. Ideas clave

- Aleatoriedad no significa ausencia de leyes matemáticas.
- Un experimento aleatorio puede tener resultados individuales impredecibles y, al mismo tiempo, presentar regularidad colectiva.
- La probabilidad se construye sobre eventos asociados a un espacio muestral.
- El modelo probabilístico abstrae los rasgos relevantes del fenómeno real.

1.9. Ejercicios

1. Da dos ejemplos de fenómenos deterministas y dos de fenómenos aleatorios.
2. Explica por qué la medición repetida de una misma magnitud física puede modelarse probabilísticamente.
3. Describe los resultados posibles de lanzar dos monedas.
4. ¿Por qué $P(A) = 0.7$ no significa que el evento A ocurrirá siete veces en cada bloque de diez repeticiones?

5. Explica con tus palabras la diferencia entre un sistema físico y su modelo probabilístico.

1.10. Referencias del capítulo

La organización conceptual se apoya principalmente en Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

2 Espacios muestrales y álgebra de eventos

2.1. Objetivos

Al finalizar este capítulo, el estudiante podrá:

- formular con precisión un espacio muestral;
- representar eventos como subconjuntos del espacio muestral;
- distinguir puntos muestrales, eventos y familias de eventos;
- demostrar identidades del álgebra de conjuntos mediante argumentos de pertenencia;
- reconocer particiones y eventos mutuamente excluyentes;
- relacionar el enfoque elemental de eventos con la terna $(\Omega, \mathcal{F}, P)$.

2.2. Lenguaje de conjuntos

La teoría de probabilidad utiliza el lenguaje de conjuntos para separar dos niveles:

- el **resultado individual** de un experimento;
- las **afirmaciones** acerca de ese resultado.

Un conjunto es una colección bien definida de objetos. Si x es elemento de A , escribimos $x \in A$. La negación se expresa como $x \notin A$.

2.2.1. Inclusión e igualdad

Sean A y B conjuntos. Definimos

$$A \subseteq B \iff \forall x (x \in A \Rightarrow x \in B).$$

La igualdad queda caracterizada por doble inclusión:

$$A = B \iff A \subseteq B \text{ y } B \subseteq A.$$

Esta caracterización será nuestra herramienta principal para demostrar identidades entre eventos.

2.2.2. Conjunto vacío y conjunto potencia

El **conjunto vacío**, $\emptyset$, no contiene elementos. Es subconjunto de cualquier conjunto.

El **conjunto potencia** de Ω , denotado por $\mathcal{P}(\Omega)$, es la colección de todos sus subconjuntos:

$$\mathcal{P}(\Omega) = \{A : A \subseteq \Omega\}.$$

Si Ω tiene n elementos, entonces

$$|\mathcal{P}(\Omega)| = 2^n.$$

En efecto, para formar un subconjunto decidimos, para cada uno de los n elementos, incluirlo o no incluirlo. Existen dos decisiones independientes por elemento, lo que produce 2^n subconjuntos.

2.2.3. Producto cartesiano

El producto cartesiano de A y B es

$$A \times B = \{(a, b) : a \in A, b \in B\}.$$

Si A y B son finitos,

$$|A \times B| = |A| |B|.$$

Los productos cartesianos permiten describir experimentos compuestos. Dos lanzamientos de un dado tienen como espacio muestral

$$\{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\}.$$

2.3. Operaciones con conjuntos

Para $A, B \subseteq \Omega$, definimos:

$$A \cup B = \{x \in \Omega : x \in A \text{ o } x \in B\},$$

$$A \cap B = \{x \in \Omega : x \in A \text{ y } x \in B\},$$

$$A \setminus B = \{x \in \Omega : x \in A \text{ y } x \notin B\},$$

$$A^c = \Omega \setminus A.$$

La diferencia simétrica es

$$A \triangle B = (A \setminus B) \cup (B \setminus A).$$

También puede escribirse como

$$A \triangle B = (A \cup B) \setminus (A \cap B).$$

2.4. Propiedades del álgebra de conjuntos

Para cualesquiera $A, B, C \subseteq \Omega$ se cumplen:

2.4.1. Leyes conmutativas

$$A \cup B = B \cup A, \quad A \cap B = B \cap A.$$

2.4.2. Leyes asociativas

$$(A \cup B) \cup C = A \cup (B \cup C),$$

$$(A \cap B) \cap C = A \cap (B \cap C).$$

2.4.3. Leyes distributivas

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C),$$

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C).$$

2.4.4. Leyes de identidad y complemento

$$A \cup \emptyset = A, \quad A \cap \Omega = A,$$

$$A \cup \Omega = \Omega, \quad A \cap \emptyset = \emptyset,$$

$$A \cup A^c = \Omega, \quad A \cap A^c = \emptyset,$$

$$(A^c)^c = A.$$

2.4.5. Leyes de De Morgan

$$(A \cup B)^c = A^c \cap B^c,$$

$$(A \cap B)^c = A^c \cup B^c.$$

2.5. Demostraciones por pertenencia

2.5.1. Primera ley de De Morgan

Demostraremos

$$(A \cup B)^c = A^c \cap B^c.$$

Sea $x \in \Omega$. Entonces

$$\begin{aligned} x \in (A \cup B)^c &\iff x \notin A \cup B \\ &\iff (x \notin A) \text{ y } (x \notin B) \\ &\iff (x \in A^c) \text{ y } (x \in B^c) \\ &\iff x \in A^c \cap B^c. \end{aligned}$$

Como la equivalencia se cumple para todo $x \in \Omega$, los conjuntos son iguales.

2.5.2. Ley distributiva

Demostremos

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

Para cualquier $x \in \Omega$,

$$\begin{aligned} x \in A \cap (B \cup C) &\iff x \in A \text{ y } (x \in B \text{ o } x \in C) \\ &\iff (x \in A \text{ y } x \in B) \text{ o } (x \in A \text{ y } x \in C) \\ &\iff x \in (A \cap B) \cup (A \cap C). \end{aligned}$$

La demostración reproduce una ley distributiva de la lógica proposicional. Esta correspondencia entre lógica y conjuntos será constante en probabilidad.

2.6. Experimento aleatorio y espacio muestral

Un **experimento aleatorio** es un procedimiento cuyo resultado concreto no se conoce antes de realizarlo, aunque el conjunto de resultados posibles pueda especificarse.

El **espacio muestral** Ω es el conjunto de todos los resultados posibles que distingue el modelo. Sus elementos $\omega \in \Omega$ reciben el nombre de **puntos muestrales**.

La frase “que distingue el modelo” es importante. Un mismo procedimiento admite diferentes espacios muestrales según la información que se registre.

2.6.1. Ejemplo

Al lanzar un dado y registrar el número de puntos,

$$\Omega_1 = \{1, 2, 3, 4, 5, 6\}.$$

Si sólo se registra la paridad,

$$\Omega_2 = \{\text{par}, \text{impar}\}.$$

Existe una función $g : \Omega_1 \rightarrow \Omega_2$ que asigna a cada número su paridad. El segundo modelo es una descripción menos fina del primero.

2.7. Clasificación de espacios muestrales

2.7.1. Espacio finito

Ω contiene un número finito de puntos. Por ejemplo, para dos bits transmitidos,

$$\Omega = \{00, 01, 10, 11\}.$$

2.7.2. Espacio infinito numerable

Sus puntos pueden ponerse en correspondencia con un subconjunto de los números naturales. El número de intentos hasta obtener el primer éxito tiene espacio muestral

$$\Omega = \{1, 2, 3, \dots\}.$$

2.7.3. Espacio no numerable

Contiene un continuo de resultados. El tiempo de vida de un dispositivo puede modelarse mediante

$$\Omega = [0, \infty).$$

La distinción entre espacios discretos y continuos determinará posteriormente cómo se asignan probabilidades y cómo se definen las variables aleatorias.

2.8. Eventos como subconjuntos

Un **evento** A es un subconjunto de Ω . Decimos que A ocurre si el resultado observado ω pertenece a A .

Esta definición distingue correctamente:

- punto muestral: $\omega \in \Omega$;
- evento elemental: $\{\omega\} \subseteq \Omega$;
- evento general: $A \subseteq \Omega$.

El evento seguro es Ω y el evento imposible es $\emptyset$.

2.8.1. Ejemplo

Para $\Omega = \{1, 2, 3, 4, 5, 6\}$, definamos

$$A = \{2, 4, 6\}, \quad B = \{4, 5, 6\}.$$

A es el evento “resultado par” y B es “resultado mayor que 3”. De aquí,

$$A \cap B = \{4, 6\},$$

$$A \cup B = \{2, 4, 5, 6\},$$

$$A^c = \{1, 3, 5\}.$$

2.9. Eventos disjuntos y familias exhaustivas

Dos eventos A y B son **mutuamente excluyentes** o **disjuntos** si

$$A \cap B = \emptyset.$$

Una familia $A_1, \dots, A_n$ es **exhaustiva** si

$$\bigcup_{i=1}^n A_i = \Omega.$$

La exhaustividad no implica disjunción. Los eventos pueden cubrir todo Ω y superponerse.

2.10. Particiones

Una colección no vacía $\{A_i : i \in I\}$ es una **partición** de Ω si:

1. $A_i \neq \emptyset$ para todo i ;
2. $A_i \cap A_j = \emptyset$ cuando $i \neq j$;
3. $\bigcup_{i \in I} A_i = \Omega$.

Cada punto muestral pertenece exactamente a un bloque de la partición.

2.10.1. Ejemplo

En $\Omega = \{1, 2, 3, 4, 5, 6\}$,

$$A_1 = \{1, 3, 5\}, \quad A_2 = \{2, 4, 6\}$$

forman una partición. En cambio,

$$B_1 = \{1, 2, 3\}, \quad B_2 = \{3, 4, 5, 6\}$$

son exhaustivos, pero no forman una partición porque $B_1 \cap B_2 = \{3\}$.

Las particiones serán esenciales para la regla de probabilidad total y el teorema de Bayes.

2.11. Familias de eventos

En un espacio muestral finito suele tomarse como colección de eventos todo el conjunto potencia:

$$\mathcal{F} = \mathcal{P}(\Omega).$$

En espacios infinitos, especialmente no numerables, no siempre se asigna probabilidad a cada subconjunto. Se selecciona una colección $\mathcal{F}$ que cumpla propiedades de cierre.

2.11.1. Definición: sigma-álgebra

Una colección $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ es una **sigma-álgebra** si:

1. $\Omega \in \mathcal{F}$;
2. si $A \in \mathcal{F}$, entonces $A^c \in \mathcal{F}$;
3. si $A_1, A_2, \dots \in \mathcal{F}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$.

Los elementos de $\mathcal{F}$ son los eventos a los que podrá asignarse probabilidad.

De estas condiciones se deduce que $\emptyset \in \mathcal{F}$ y que $\mathcal{F}$ es cerrada bajo intersecciones numerables. En efecto,

$$\bigcap_{i=1}^{\infty} A_i = \left(\bigcup_{i=1}^{\infty} A_i^c \right)^c.$$

Para el curso elemental bastará, en la mayoría de los ejemplos finitos, trabajar con $\mathcal{P}(\Omega)$. La sigma-álgebra explica por qué la terna formal es

$$(\Omega, \mathcal{F}, P)$$

y no solamente (Ω, P) .

2.12. Ejemplo integrador

Se inspeccionan dos componentes. Cada uno se clasifica como conforme (C), reparable (R) o desecho (D). Como el orden identifica la posición del componente,

$$\Omega = \{CC, CR, CD, RC, RR, RD, DC, DR, DD\}.$$

Sea

$$A = \{\omega \in \Omega : \text{al menos un componente es } D\}$$

y

$$B = \{\omega \in \Omega : \text{ambos componentes tienen la misma clasificación}\}.$$

Entonces

$$A = \{CD, RD, DC, DR, DD\},$$

$$B = \{CC, RR, DD\}.$$

Por tanto,

$$A \cap B = \{DD\},$$

$$A \setminus B = \{CD, RD, DC, DR\},$$

$$(A \cup B)^c = \{CR, RC\}.$$

Los eventos

$$C_0 = \{CC, CR, RC, RR\},$$

$$C_1 = \{CD, RD, DC, DR\},$$

$$C_2 = \{DD\}$$

forman una partición de Ω de acuerdo con el número de componentes clasificados como desecho.

2.13. Proposición: caracterización de la inclusión

Para $A, B \subseteq \Omega$, son equivalentes:

1. $A \subseteq B$;
2. $A \cap B = A$;
3. $A \cup B = B$.

2.13.1. Demostración

Supongamos $A \subseteq B$. Si $x \in A \cap B$, entonces $x \in A$; por tanto, $A \cap B \subseteq A$. La inclusión contraria se obtiene porque $x \in A$ implica $x \in B$, de modo que $x \in A \cap B$. Así, $A \cap B = A$.

Ahora supongamos $A \cap B = A$. Si $x \in A$, entonces $x \in A \cap B$, y por ello $x \in B$. Luego $A \subseteq B$.

La equivalencia entre $A \subseteq B$ y $A \cap B = A$ se demuestra de manera análoga. $\square$

2.14. Errores conceptuales frecuentes

1. Escribir $\omega \subseteq \Omega$ cuando ω es un punto muestral; debe escribirse $\omega \in \Omega$.
2. Confundir $\emptyset$ con $\{\emptyset\}$. El primero no tiene elementos; el segundo contiene un elemento.
3. Afirmar que eventos disjuntos son independientes. La independencia requiere una definición probabilística posterior.
4. Calcular A^c sin especificar el espacio muestral.
5. Omitir resultados en experimentos por etapas o tratar pares ordenados como si el orden no importara.

2.15. Ideas clave

- El espacio muestral reúne los resultados que distingue el modelo.
- Los eventos son subconjuntos, no resultados individuales.
- El álgebra de eventos hereda las leyes del álgebra de conjuntos.
- Las identidades se demuestran rigurosamente mediante pertenencia o doble inclusión.
- Una partición divide Ω en bloques no vacíos, disjuntos y exhaustivos.
- La sigma-álgebra $\mathcal{F}$ especifica qué subconjuntos se consideran eventos medibles.

2.16. Ejercicios

2.16.1. Conceptos y operaciones

1. Sea $\Omega = \{1, 2, \dots, 12\}$, A el conjunto de múltiplos de 2 y B el conjunto de múltiplos de 3. Obtén $A \cap B$, $A \cup B$, A^c , B^c y $A \triangle B$.
2. Calcula $\mathcal{P}(\{a, b, c\})$ y verifica que contiene 2^3 elementos.
3. Construye el espacio muestral de tres lanzamientos de una moneda mediante un producto cartesiano.

4. Da un ejemplo de una familia exhaustiva que no sea una partición.

2.16.2. Demostraciones

5. Demuestra la segunda ley de De Morgan por pertenencia.
6. Demuestra $A \setminus (B \cup C) = (A \setminus B) \cap (A \setminus C)$.
7. Demuestra $A \triangle B = (A \cup B) \setminus (A \cap B)$.
8. Prueba que $A \subseteq B$ implica $B^c \subseteq A^c$.
9. Demuestra que una partición finita $A_1, \dots, A_n$ satisface que cada $\omega \in \Omega$ pertenece a un único A_i .

2.16.3. Modelación

10. Un experimento registra el estado de tres interruptores, cada uno encendido o apagado. Define Ω y los eventos “exactamente dos están encendidos” y “el primero está apagado”.
11. Se mide el tiempo hasta la primera falla de un sistema. Propón un espacio muestral continuo y tres eventos expresados mediante intervalos.
12. Se extraen dos piezas sin reemplazo de un lote con piezas identificadas. Explica cuándo el orden debe formar parte del punto muestral.

2.16.4. Profundización

13. Sea $\Omega = \{1, 2, 3, 4\}$. Encuentra una sigma-álgebra que contenga $\{1, 2\}$ pero que no sea $\mathcal{P}(\Omega)$.
14. Comprueba que $\{\emptyset, \Omega\}$ y $\mathcal{P}(\Omega)$ siempre son sigma-álgebras.
15. Si $\mathcal{F}$ es una sigma-álgebra y $A, B \in \mathcal{F}$, demuestra que $A \setminus B \in \mathcal{F}$.

2.17. Referencias del capítulo

La secuencia de espacios muestrales y eventos se apoya principalmente en Walpole et al. (2012) y en el programa oficial del curso. La formalización se complementa con Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

3 Técnicas de conteo y enumeración

3.1. Objetivos

Al finalizar este capítulo, el estudiante será capaz de formular y demostrar reglas elementales de conteo, distinguir entre procesos ordenados y no ordenados, obtener fórmulas para permutaciones, arreglos y combinaciones, y utilizar estas herramientas para determinar cardinalidades de espacios muestrales finitos.

3.2. Cardinalidad de conjuntos finitos

Si A es un conjunto finito, denotamos por

$$|A|$$

el número de elementos de A .

Las técnicas de conteo buscan determinar cardinalidades sin necesidad de enumerar explícitamente cada elemento.

3.3. Principio aditivo

Sean $A_1, A_2, \dots, A_k$ conjuntos finitos y mutuamente disjuntos. Entonces

$$\left| \bigcup_{i=1}^k A_i \right| = \sum_{i=1}^k |A_i|.$$

3.3.1. Demostración

Como los conjuntos son disjuntos, ningún elemento pertenece simultáneamente a dos de ellos. Por tanto, al sumar sus cardinalidades cada elemento de la unión se cuenta exactamente una vez.

El requisito de disjunción es esencial. Si dos conjuntos se superponen, la suma simple cuenta varias veces los elementos comunes.

3.4. Principio multiplicativo

Sean $A_1, A_2, \dots, A_k$ conjuntos finitos. El número de elementos del producto cartesiano

$$A_1 \times A_2 \times \dots \times A_k$$

es

$$|A_1||A_2| \dots |A_k|.$$

3.4.1. Demostración

Cada elemento del producto cartesiano es una k -tupla

$$(a_1, a_2, \dots, a_k),$$

con $a_i \in A_i$. Para cada elección de a_1 existen $|A_2|$ posibilidades para a_2 , y así sucesivamente. La aplicación sucesiva del principio multiplicativo produce el resultado.

Este principio proporciona la formulación matemática de los diagramas de árbol y de los experimentos por etapas.

3.5. Secuencias con repetición

Sea un conjunto de n símbolos. El número de secuencias ordenadas de longitud r que pueden formarse permitiendo repetición es

$$n^r.$$

En efecto, el espacio de secuencias es el producto cartesiano

$$A^r = A \times A \times \cdots \times A,$$

y por el principio multiplicativo

$$|A^r| = |A|^r = n^r.$$

3.6. Factorial

Para $n \in \mathbb{N}$,

$$n! = n(n-1) \cdots 2 \cdot 1,$$

con el convenio

$$0! = 1.$$

El factorial aparece al contar biyecciones y ordenamientos de conjuntos finitos.

3.7. Permutaciones de n objetos distintos

Una permutación de un conjunto de n elementos es una ordenación de todos sus elementos.

3.7.1. Teorema

El número de permutaciones de n objetos distintos es

$$n!.$$

3.7.2. Demostración

La primera posición puede ocuparse de n maneras. Una vez elegida, la segunda dispone de $n-1$ posibilidades; la tercera, de $n-2$, y así sucesivamente. Por el principio multiplicativo,

$$n(n-1)(n-2)\cdots 2\cdot 1 = n!.$$

3.8. Arreglos de r objetos tomados de n

Un arreglo sin repetición de longitud r es una secuencia ordenada formada por r elementos distintos elegidos de un conjunto de n elementos.

3.8.1. Teorema

El número de arreglos es

$$P(n, r) = \frac{n!}{(n-r)!}, \quad 0 \leq r \leq n.$$

3.8.2. Demostración

Existen n opciones para la primera posición, $n-1$ para la segunda y, finalmente, $n-r+1$ para la posición r . Por tanto,

$$P(n, r) = n(n-1)\cdots(n-r+1) = \frac{n!}{(n-r)!}.$$

3.9. Combinaciones

Una combinación de tamaño r es un subconjunto de r elementos de un conjunto de n elementos.

3.9.1. Teorema

El número de combinaciones de n elementos tomados de r en r es

$$\binom{n}{r} = \frac{n!}{r!(n-r)!}.$$

3.9.2. Demostración

Primero contamos arreglos de longitud r :

$$P(n, r) = \frac{n!}{(n-r)!}.$$

Cada subconjunto de r elementos produce exactamente $r!$ ordenamientos. Por tanto, al dividir entre $r!$ obtenemos

$$\binom{n}{r} = \frac{P(n, r)}{r!} = \frac{n!}{r!(n-r)!}.$$

3.10. Simetría de los coeficientes binomiales

Para $0 \leq r \leq n$,

$$\binom{n}{r} = \binom{n}{n-r}.$$

3.10.1. Interpretación combinatoria

Elegir los r elementos que pertenecen a un subconjunto equivale a elegir los $n-r$ elementos que quedan fuera. Ambas decisiones determinan exactamente el mismo subconjunto.

3.11. Identidad de Pascal

Para $1 \leq r \leq n - 1$,

$$\binom{n}{r} = \binom{n-1}{r-1} + \binom{n-1}{r}.$$

3.11.1. Demostración combinatoria

Fijemos un elemento particular x de un conjunto de n elementos. Todo subconjunto de tamaño r pertenece exactamente a una de dos clases:

1. contiene a x ;
2. no contiene a x .

Si contiene a x , faltan por elegir $r - 1$ elementos de los $n - 1$ restantes, lo que puede hacerse de

$$\binom{n-1}{r-1}$$

formas. Si no contiene a x , deben elegirse los r elementos entre los $n - 1$ restantes, lo que puede hacerse de

$$\binom{n-1}{r}$$

formas. Como las dos clases son disjuntas, el principio aditivo completa la demostración.

3.12. Permutaciones con repetición

Supongamos que se tienen n objetos, de los cuales n_1 son indistinguibles de un primer tipo, n_2 de un segundo tipo, ..., n_k de un último tipo, con

$$n_1 + n_2 + \cdots + n_k = n.$$

El número de ordenamientos distintos es

$$\frac{n!}{n_1!n_2!\cdots n_k!}.$$

3.12.1. Justificación

Si todos los objetos fueran distintos existirían $n!$ ordenamientos. Sin embargo, permutar entre sí los n_i objetos indistinguibles de cada clase no produce un nuevo ordenamiento. Por ello se divide entre

$$n_1!n_2!\cdots n_k!.$$

3.13. Coeficiente multinomial

Una generalización natural del coeficiente binomial es

$$\binom{n}{n_1, n_2, \dots, n_k} = \frac{n!}{n_1!n_2!\cdots n_k!},$$

con

$$n_1 + n_2 + \cdots + n_k = n.$$

Este coeficiente cuenta el número de maneras de dividir n objetos distintos en k grupos etiquetados de tamaños $n_1, n_2, \dots, n_k$.

3.14. Ejemplo: palabras binarias

Consideremos cadenas de longitud 8 formadas por ceros y unos.

El número total de cadenas es

$$2^8 = 256.$$

El número de cadenas con exactamente tres unos es

$$\binom{8}{3} = 56,$$

porque basta elegir las tres posiciones ocupadas por unos.

Esta interpretación será útil posteriormente al estudiar la distribución binomial.

3.15. Ejemplo: selección de componentes

De 12 componentes se seleccionan 3.

Si la selección es un subconjunto sin orden,

$$\binom{12}{3} = 220.$$

Si las tres posiciones representan pruebas diferentes y el orden importa,

$$P(12, 3) = \frac{12!}{9!} = 1320.$$

Por tanto, el mismo conjunto físico de objetos puede inducir distintos problemas combinatorios según la definición del resultado.

3.16. Relación con espacios muestrales

Las técnicas de conteo permiten calcular cardinalidades como

$$|S|$$

y

$$|A|,$$

sin enumerar explícitamente los resultados. En el capítulo siguiente, al introducir formalmente la probabilidad en espacios finitos equiprobables, estas cardinalidades permitirán expresar

$$P(A) = \frac{|A|}{|S|}.$$

Por ahora, lo importante es separar dos cuestiones:

1. cuántos resultados existen;
2. qué probabilidad se asignará a esos resultados.

El conteo responde la primera pregunta, no la segunda.

3.17. Ideas clave

- La cardinalidad mide el tamaño de un conjunto finito.
- El principio aditivo se aplica a alternativas disjuntas.
- El principio multiplicativo se aplica a elecciones sucesivas.
- Las permutaciones ordenan todos los objetos.
- Los arreglos seleccionan y ordenan una parte de los objetos.
- Las combinaciones seleccionan sin considerar el orden.
- Los coeficientes binomiales satisfacen identidades con interpretaciones combinatorias.
- Las técnicas de conteo preparan el cálculo de probabilidades en espacios finitos.

3.18. Ejercicios

1. Demuestra el principio multiplicativo para tres conjuntos finitos utilizando productos cartesianos.
2. Calcula el número de cadenas de longitud 6 formadas por cuatro símbolos cuando se permite repetición.
3. ¿Cuántas permutaciones existen de 9 objetos distintos?
4. ¿Cuántos arreglos de longitud 4 pueden formarse a partir de 10 objetos distintos?
5. Demuestra algebraicamente la identidad $\binom{n}{r} = \binom{n}{n-r}$.
6. Demuestra la identidad de Pascal mediante manipulación algebraica de factoriales.
7. ¿Cuántas cadenas binarias de longitud 12 contienen exactamente cinco unos?
8. Obtén el número de permutaciones distintas de las letras de la palabra PROBABILIDAD.
9. Explica por qué el conteo de comités utiliza combinaciones mientras que la asignación de cargos utiliza arreglos.
10. Demuestra que

$$\sum_{r=0}^n \binom{n}{r} = 2^n$$

interpretando ambos lados como el número de subconjuntos de un conjunto de n elementos.

3.19. Referencias del capítulo

El desarrollo teórico de los principios de conteo y los coeficientes combinatorios se apoya en Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

4 Axiomas y propiedades de la probabilidad

4.1. Propósitos de aprendizaje

Al finalizar este capítulo, el lector será capaz de:

- describir formalmente una medida de probabilidad sobre un espacio medible;
- interpretar los axiomas de Kolmogórov;
- deducir propiedades fundamentales de una medida de probabilidad;
- demostrar monotonía, subaditividad e inclusión-exclusión para eventos finitos;
- distinguir entre propiedades primitivas y resultados derivados;
- analizar restricciones de coherencia entre probabilidades marginales e intersecciones.

4.2. Espacios de probabilidad

Un **espacio de probabilidad** es una terna

$$(\Omega, \mathcal{F}, P),$$

donde:

1. Ω es un conjunto no vacío llamado espacio muestral;
2. $\mathcal{F}$ es una σ -álgebra de subconjuntos de Ω ;
3. $P : \mathcal{F} \rightarrow [0, 1]$ es una medida de probabilidad.

La familia $\mathcal{F}$ determina cuáles subconjuntos de Ω son considerados eventos medibles. La función P asigna a cada evento un número real que satisface los axiomas que se presentan a continuación.

4.3. Axiomas de Kolmogórov

Sea $(\Omega, \mathcal{F})$ un espacio medible. Una función

$$P : \mathcal{F} \rightarrow [0, 1]$$

es una medida de probabilidad si satisface:

4.3.1. Axioma 1: no negatividad

Para todo $A \in \mathcal{F}$,

$$P(A) \geq 0.$$

4.3.2. Axioma 2: normalización

$$P(\Omega) = 1.$$

4.3.3. Axioma 3: aditividad numerable

Si $A_1, A_2, \dots \in \mathcal{F}$ son mutuamente excluyentes, es decir,

$$A_i \cap A_j = \emptyset \quad (i \neq j),$$

entonces

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n).$$

La aditividad numerable es la condición estructural central. Muchas fórmulas elementales de probabilidad se deducen de ella.

4.4. Probabilidad del conjunto vacío

4.4.1. Proposición

$$P(\emptyset) = 0.$$

4.4.2. Demostración

Como

$$\Omega = \Omega \cup \emptyset$$

y los dos conjuntos son disjuntos, por aditividad,

$$P(\Omega) = P(\Omega) + P(\emptyset).$$

Restando $P(\Omega)$ en ambos lados obtenemos

$$P(\emptyset) = 0. \quad \square$$

4.5. Aditividad finita

4.5.1. Proposición

Si $A_1, \dots, A_n \in \mathcal{F}$ son mutuamente excluyentes, entonces

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i).$$

4.5.2. Justificación

Puede aplicarse la aditividad numerable a la sucesión

$$A_1, \dots, A_n, \emptyset, \emptyset, \dots$$

y utilizar $P(\emptyset) = 0$.

4.6. Regla del complemento

4.6.1. Proposición

Para todo evento $A \in \mathcal{F}$,

$$P(A^c) = 1 - P(A).$$

4.6.2. Demostración

Como

$$A \cap A^c = \emptyset$$

y

$$A \cup A^c = \Omega,$$

por aditividad finita,

$$1 = P(\Omega) = P(A) + P(A^c).$$

Por tanto,

$$P(A^c) = 1 - P(A). \quad \square$$

4.7. Monotonía

4.7.1. Teorema

Si $A, B \in \mathcal{F}$ y

$$A \subseteq B,$$

entonces

$$P(A) \leq P(B).$$

4.7.2. Demostración

Como

$$B = A \cup (B \setminus A)$$

y los conjuntos son disjuntos,

$$P(B) = P(A) + P(B \setminus A).$$

Por no negatividad,

$$P(B \setminus A) \geq 0.$$

Luego

$$P(B) \geq P(A). \quad \square$$

4.7.3. Corolario

Para todo $A \in \mathcal{F}$,

$$0 \leq P(A) \leq 1.$$

La cota inferior procede de la no negatividad y la superior de $A \subseteq \Omega$.

4.8. Probabilidad de una diferencia

4.8.1. Proposición

Para $A, B \in \mathcal{F}$,

$$P(A \setminus B) = P(A) - P(A \cap B).$$

4.8.2. Demostración

La descomposición

$$A = (A \setminus B) \cup (A \cap B)$$

es disjunta. Por tanto,

$$P(A) = P(A \setminus B) + P(A \cap B),$$

de donde se obtiene la identidad.

4.9. Fórmula de la unión de dos eventos

4.9.1. Teorema

Para cualesquiera $A, B \in \mathcal{F}$,

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

4.9.2. Demostración

Podemos escribir

$$A \cup B = A \cup (B \setminus A),$$

donde los dos eventos son disjuntos. Luego

$$P(A \cup B) = P(A) + P(B \setminus A).$$

Además,

$$P(B \setminus A) = P(B) - P(A \cap B).$$

Sustituyendo,

$$P(A \cup B) = P(A) + P(B) - P(A \cap B). \quad \square$$

4.10. Cotas de Fréchet para dos eventos

A partir de

$$P(A \cup B) \leq 1$$

y de la fórmula de la unión,

$$P(A) + P(B) - P(A \cap B) \leq 1.$$

Por tanto,

$$P(A \cap B) \geq P(A) + P(B) - 1.$$

Como además

$$A \cap B \subseteq A$$

y

$$A \cap B \subseteq B,$$

se obtiene

$$P(A \cap B) \leq \min\{P(A), P(B)\}.$$

En consecuencia,

$$\boxed{\max\{0, P(A) + P(B) - 1\} \leq P(A \cap B) \leq \min\{P(A), P(B)\}}.$$

Estas desigualdades caracterizan las restricciones básicas que debe satisfacer una intersección dada la probabilidad marginal de cada evento.

4.11. Subaditividad

4.11.1. Teorema

Para $A, B \in \mathcal{F}$,

$$P(A \cup B) \leq P(A) + P(B).$$

4.11.2. Demostración

La fórmula de la unión da

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Como

$$P(A \cap B) \geq 0,$$

se sigue la desigualdad.

4.11.3. Generalización numerable

Para cualquier sucesión $A_1, A_2, \dots \in \mathcal{F}$,

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} P(A_n).$$

Esta propiedad se denomina **subaditividad numerable**.

4.12. Inclusión-exclusión para tres eventos

Para $A, B, C \in \mathcal{F}$,

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) \\ &\quad - P(A \cap B) - P(A \cap C) - P(B \cap C) \\ &\quad + P(A \cap B \cap C). \end{aligned}$$

La fórmula puede demostrarse aplicando dos veces la regla de la unión y usando identidades de conjuntos.

4.13. Inclusión-exclusión finita

Para eventos $A_1, \dots, A_n$,

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_i P(A_i) - \sum_{i < j} P(A_i \cap A_j) + \sum_{i < j < k} P(A_i \cap A_j \cap A_k) - \dots + (-1)^{n+1} P\left(\bigcap_{i=1}^n A_i\right).$$

El principio de inclusión-exclusión es una conexión directa entre combinatoria y probabilidad.

4.14. Continuidad de la probabilidad

La aditividad numerable implica propiedades de continuidad que serán importantes al estudiar variables aleatorias y sucesiones de eventos.

4.14.1. Continuidad desde abajo

Si

$$A_1 \subseteq A_2 \subseteq \dots$$

y

$$A = \bigcup_{n=1}^{\infty} A_n,$$

entonces

$$P(A_n) \longrightarrow P(A).$$

4.14.2. Continuidad desde arriba

Si

$$A_1 \supseteq A_2 \supseteq \dots$$

y

$$A = \bigcap_{n=1}^{\infty} A_n,$$

entonces

$$P(A_n) \longrightarrow P(A).$$

En espacios de probabilidad, la condición $P(A_1) < \infty$ necesaria para medidas generales se satisface automáticamente porque $P(A_1) \leq 1$.

4.15. Espacios finitos

Sea

$$\Omega = \{\omega_1, \dots, \omega_N\}.$$

Si asignamos masas

$$p_i = P(\{\omega_i\}),$$

con

$$p_i \geq 0, \quad \sum_{i=1}^N p_i = 1,$$

entonces para cualquier evento $A \subseteq \Omega$,

$$P(A) = \sum_{\omega_i \in A} p_i.$$

Si todos los resultados elementales son equiprobables,

$$p_i = \frac{1}{N},$$

y se obtiene

$$P(A) = \frac{|A|}{|\Omega|}.$$

La equiprobabilidad es una hipótesis adicional del modelo, no un axioma de probabilidad.

4.16. Ejemplo formal

Sea

$$\Omega = \{1, 2, 3, 4\}$$

y supongamos

$$P(\{1\}) = 0.1, \quad P(\{2\}) = 0.2, \quad P(\{3\}) = 0.3, \quad P(\{4\}) = 0.4.$$

Definimos

$$A = \{1, 2, 4\}, \quad B = \{3, 4\}.$$

Entonces

$$P(A) = 0.7,$$

$$P(B) = 0.7,$$

$$P(A \cap B) = 0.4,$$

y

$$P(A \cup B) = 0.7 + 0.7 - 0.4 = 1.$$

En efecto,

$$A \cup B = \Omega.$$

4.17. Observación conceptual: probabilidad cero e imposibilidad

El axioma establece

$$P(\emptyset) = 0,$$

pero el recíproco no es válido en general. Puede existir un evento no vacío con probabilidad cero.

En modelos continuos, por ejemplo, un resultado individual puede tener probabilidad cero aunque pertenezca al espacio muestral. Esta distinción será esencial cuando estudiemos distribuciones continuas.

4.18. Errores conceptuales frecuentes

- Tratar $P(A) = |A|/|\Omega|$ como una definición universal de probabilidad.
- Confundir aditividad para eventos disjuntos con la regla general de la unión.
- Suponer que $P(A) = 0$ implica necesariamente $A = \emptyset$.
- Utilizar propiedades derivadas como si fueran axiomas independientes.
- Proponer probabilidades marginales e intersecciones que violan las cotas de Fréchet.

4.19. Ejercicios

1. Demuestre que si $A \subseteq B$, entonces

$$P(B \setminus A) = P(B) - P(A).$$

2. Demuestre que

$$P(A \triangle B) = P(A) + P(B) - 2P(A \cap B).$$

3. Si $P(A) = 0.65$ y $P(B) = 0.50$, determine todos los valores posibles de $P(A \cap B)$.
4. Demuestre que

$$P(A \cap B) \geq P(A) + P(B) - 1.$$

5. Pruebe la desigualdad

$$P(A \cap B) \leq \min\{P(A), P(B)\}.$$

6. Derive la fórmula de inclusión-exclusión para tres eventos a partir de la fórmula de dos eventos.

7. Pruebe que

$$P(A \cup B \cup C) \leq P(A) + P(B) + P(C).$$

8. Sea $A_1 \subseteq A_2 \subseteq \dots$. Demuestre la continuidad desde abajo descomponiendo la unión en eventos disjuntos.

9. Explique por qué la equiprobabilidad no puede deducirse únicamente del hecho de que Ω sea finito.

10. **Reto** . Sea (A_n) una sucesión de eventos. Demuestre la desigualdad de Boole:

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} P(A_n).$$

4.20. Referencias del capítulo

La formulación axiomática y las propiedades derivadas siguen el tratamiento estándar de probabilidad matemática y de textos para ingeniería y ciencias, con apoyo en Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). La presentación se ha reescrito de forma original para esta obra.

5 Probabilidad condicional e independencia

5.1. Propósitos del capítulo

Este capítulo formaliza dos ideas centrales de la teoría de la probabilidad: la actualización de probabilidades ante información adicional y la independencia entre eventos. Se desarrollan la definición de probabilidad condicional, la regla del producto, la regla de la cadena y criterios equivalentes de independencia.

5.2. Probabilidad condicional

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y sean $A, B \in \mathcal{F}$ con $P(B) > 0$. La probabilidad condicional de A dado B se define por

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

Esta definición puede interpretarse como una renormalización de la medida de probabilidad al restringir el espacio al evento B .

5.2.1. Propiedad de normalización

Para $P(B) > 0$,

$$P(B | B) = 1.$$

En efecto,

$$P(B | B) = \frac{P(B \cap B)}{P(B)} = 1.$$

5.2.2. Probabilidad condicional como medida

Fijado un evento B con $P(B) > 0$, la aplicación

$$P_B(A) = P(A \mid B)$$

define una nueva medida de probabilidad sobre $(\Omega, \mathcal{F})$.

Se verifica:

1. $P_B(A) \geq 0$;
2. $P_B(\Omega) = 1$;
3. si $A_1, A_2, \dots$ son disjuntos,

$$P_B\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P_B(A_i).$$

Por tanto, al condicionar por B no abandonamos la estructura axiomática de la probabilidad.

5.3. Regla del producto

A partir de la definición de probabilidad condicional,

$$P(A \cap B) = P(B)P(A \mid B).$$

Si además $P(A) > 0$,

$$P(A \cap B) = P(A)P(B \mid A).$$

Por tanto,

$$P(A)P(B \mid A) = P(B)P(A \mid B).$$

Esta igualdad es la identidad algebraica que posteriormente conduce al teorema de Bayes.

5.4. Regla de la cadena

Para eventos $A_1, \dots, A_n$ tales que las probabilidades condicionales involucradas estén definidas,

$$P\left(\bigcap_{i=1}^n A_i\right) = P(A_1) \prod_{k=2}^n P\left(A_k \mid \bigcap_{j=1}^{k-1} A_j\right).$$

Para $n = 3$,

$$P(A \cap B \cap C) = P(A)P(B \mid A)P(C \mid A \cap B).$$

5.4.1. Demostración para tres eventos

Por la regla del producto,

$$P(A \cap B \cap C) = P(A \cap B)P(C \mid A \cap B).$$

Además,

$$P(A \cap B) = P(A)P(B \mid A).$$

Sustituyendo se obtiene el resultado.

5.5. Independencia de dos eventos

Dos eventos A y B son independientes si

$$\boxed{P(A \cap B) = P(A)P(B)}.$$

Esta definición no requiere que $P(A)$ ni $P(B)$ sean positivas.

5.5.1. Equivalencia con probabilidad condicional

Si $P(B) > 0$, entonces A y B son independientes si y sólo si

$$P(A \mid B) = P(A).$$

De manera análoga, si $P(A) > 0$,

$$P(B \mid A) = P(B).$$

5.5.2. Demostración

Si A y B son independientes,

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B)}{P(B)} = P(A).$$

El recíproco se obtiene multiplicando por $P(B)$.

5.6. Independencia y complementos

Si A y B son independientes, también lo son:

$$A^c \text{ y } B,$$

$$A \text{ y } B^c,$$

y

$$A^c \text{ y } B^c.$$

5.6.1. Demostración para A^c y B

Como

$$B = (A \cap B) \cup (A^c \cap B)$$

y la unión es disjunta,

$$P(A^c \cap B) = P(B) - P(A \cap B).$$

Usando independencia,

$$P(A^c \cap B) = P(B) - P(A)P(B) = (1 - P(A))P(B) = P(A^c)P(B).$$

5.7. Exclusión mutua e independencia

Si A y B son mutuamente excluyentes,

$$P(A \cap B) = 0.$$

Si además $P(A) > 0$ y $P(B) > 0$, entonces

$$P(A)P(B) > 0,$$

por lo que no pueden ser independientes.

Así, para eventos de probabilidad positiva, exclusión mutua e independencia son conceptos incompatibles.

5.8. Independencia de varios eventos

Para tres eventos A, B, C , la independencia por pares significa

$$P(A \cap B) = P(A)P(B),$$

$$P(A \cap C) = P(A)P(C),$$

$$P(B \cap C) = P(B)P(C).$$

Sin embargo, esto no basta para garantizar independencia conjunta. Para independencia mutua se requiere además

$$P(A \cap B \cap C) = P(A)P(B)P(C).$$

En general, una familia $A_1, \dots, A_n$ es mutuamente independiente si para todo subconjunto no vacío de índices $I \subseteq \{1, \dots, n\}$,

$$P\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} P(A_i).$$

5.9. Ejemplo clásico: independencia por pares sin independencia mutua

Considérese el espacio equiprobable

$$\Omega = \{1, 2, 3, 4\}$$

y los eventos

$$A = \{1, 2\}, \quad B = \{1, 3\}, \quad C = \{1, 4\}.$$

Cada evento tiene probabilidad $1/2$. Además,

$$P(A \cap B) = P(A \cap C) = P(B \cap C) = \frac{1}{4},$$

por lo que son independientes por pares.

Sin embargo,

$$A \cap B \cap C = \{1\},$$

de modo que

$$P(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = P(A)P(B)P(C).$$

Por tanto, no son mutuamente independientes.

5.10. Dependencia inducida por muestreo sin reemplazo

Sea una urna con N objetos, de los cuales K poseen cierta propiedad. Si se extraen dos objetos sin reemplazo y definimos

- A = “el primero posee la propiedad”;
- B = “el segundo posee la propiedad”,

entonces

$$P(A) = \frac{K}{N},$$

pero

$$P(B \mid A) = \frac{K-1}{N-1}.$$

En general,

$$\frac{K-1}{N-1} \neq \frac{K}{N},$$

por lo que A y B no son independientes.

5.11. Observación sobre eventos de probabilidad cero

La igualdad

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

sólo está definida mediante esta fórmula cuando $P(B) > 0$.

En cursos más avanzados se introduce la probabilidad condicional respecto de sigma-álgebras y variables aleatorias mediante esperanza condicional, lo que permite tratar situaciones más generales. Ese desarrollo queda fuera del alcance de este volumen introductorio.

5.12. Proposición: criterio de independencia mediante complementos

Sean A y B eventos. Son equivalentes:

1. A y B son independientes;
2. A^c y B son independientes;
3. A y B^c son independientes;
4. A^c y B^c son independientes.

La demostración se obtiene aplicando repetidamente las identidades del complemento y la aditividad.

5.13. Ejercicios conceptuales y de demostración

1. Demuestra que, para $P(B) > 0$, la aplicación $P_B(A) = P(A | B)$ satisface los axiomas de probabilidad.
2. Prueba la regla de la cadena para cuatro eventos.
3. Sean A y B independientes. Demuestra que A^c y B^c son independientes.
4. Demuestra que si $A \subseteq B$, $P(A) > 0$ y A es independiente de B , entonces $P(B) = 1$.
5. Sean A y B mutuamente excluyentes. Determina todas las condiciones bajo las cuales también pueden ser independientes.
6. Construye un ejemplo de tres eventos independientes por pares que no sean mutuamente independientes.

7. Si A y B son independientes y $P(A) = 0.4$, $P(B) = 0.7$, calcula la probabilidad de cada una de las cuatro regiones $A \cap B$, $A \cap B^c$, $A^c \cap B$ y $A^c \cap B^c$.
8. Demuestra que si A y B son independientes, entonces

$$P(A \cup B) = P(A) + P(B) - P(A)P(B).$$

9. **Reto** . Sea $A_1, \dots, A_n$ una familia mutuamente independiente. Demuestra que sustituir cualquiera de los eventos por su complemento conserva la independencia mutua.

5.14. Referencias del capítulo

La presentación de probabilidad condicional, regla del producto e independencia sigue la formulación estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018), adaptada a la organización formal de este libro.

6 Particiones, probabilidad total y teorema de Bayes

6.1. Objetivos

En este capítulo se formalizan las particiones del espacio muestral, la ley de la probabilidad total y el teorema de Bayes. Se estudian sus demostraciones, su interpretación y sus consecuencias algebraicas.

6.2. Particiones del espacio muestral

Una familia finita de eventos

$$\{B_1, \dots, B_k\} \subseteq \mathcal{F}$$

es una **partición** de Ω si

$$B_i \cap B_j = \emptyset \quad (i \neq j),$$

y

$$\bigcup_{i=1}^k B_i = \Omega.$$

Si además $P(B_i) > 0$ para todo i , entonces cada B_i puede utilizarse como evento condicional.

6.2.1. Propiedad fundamental

Para cualquier evento $A \in \mathcal{F}$,

$$A = A \cap \Omega = A \cap \left(\bigcup_{i=1}^k B_i \right) = \bigcup_{i=1}^k (A \cap B_i).$$

Las intersecciones $A \cap B_i$ son mutuamente excluyentes.

6.3. Ley de la probabilidad total

6.3.1. Teorema

Sea $B_1, \dots, B_k$ una partición de Ω con $P(B_i) > 0$. Entonces para todo evento A ,

$$P(A) = \sum_{i=1}^k P(B_i)P(A \mid B_i).$$

6.3.2. Demostración

Como

$$A = \bigcup_{i=1}^k (A \cap B_i)$$

y las uniones son disjuntas,

$$P(A) = \sum_{i=1}^k P(A \cap B_i).$$

Por la definición de probabilidad condicional,

$$P(A \cap B_i) = P(B_i)P(A \mid B_i).$$

Sustituyendo,

$$P(A) = \sum_{i=1}^k P(B_i)P(A | B_i).$$

Queda demostrado.

6.4. Caso binario

Si B y B^c forman una partición y $0 < P(B) < 1$, entonces

$$P(A) = P(B)P(A | B) + P(B^c)P(A | B^c).$$

Esta forma aparece constantemente en confiabilidad, diagnóstico y clasificación.

6.5. Teorema de Bayes

6.5.1. Teorema

Sea $B_1, \dots, B_k$ una partición con $P(B_i) > 0$ y sea A un evento con $P(A) > 0$. Entonces

$$P(B_i | A) = \frac{P(B_i)P(A | B_i)}{\sum_{j=1}^k P(B_j)P(A | B_j)}.$$

6.5.2. Demostración

Por definición,

$$P(B_i | A) = \frac{P(B_i \cap A)}{P(A)}.$$

La regla del producto da

$$P(B_i \cap A) = P(B_i)P(A | B_i).$$

La ley de la probabilidad total produce

$$P(A) = \sum_{j=1}^k P(B_j)P(A | B_j).$$

Al sustituir ambas expresiones se obtiene la fórmula de Bayes.

6.6. Forma proporcional

La identidad anterior puede escribirse como

$$P(B_i | A) \propto P(B_i)P(A | B_i).$$

El denominador

$$P(A)$$

actúa como constante de normalización común a todas las hipótesis B_i .

Esta forma permite separar tres componentes conceptuales:

- $P(B_i)$: probabilidad previa;
- $P(A | B_i)$: verosimilitud de la evidencia bajo B_i ;
- $P(B_i | A)$: probabilidad posterior.

6.7. Normalización de las probabilidades posteriores

Como los B_i forman una partición,

$$\sum_{i=1}^k P(B_i | A) = 1.$$

6.7.1. Demostración

Usando Bayes,

$$\sum_{i=1}^k P(B_i | A) = \frac{\sum_{i=1}^k P(B_i)P(A | B_i)}{P(A)}.$$

El numerador es precisamente $P(A)$ por la ley de probabilidad total, de modo que la razón vale 1.

6.8. Odds y forma de Bayes para dos hipótesis

Para una hipótesis H y su complemento H^c , Bayes puede expresarse mediante **odds**.

Las odds previas son

$$\frac{P(H)}{P(H^c)}.$$

Después de observar evidencia E ,

$$\frac{P(H | E)}{P(H^c | E)} = \frac{P(H)}{P(H^c)} \cdot \frac{P(E | H)}{P(E | H^c)}.$$

La razón

$$\frac{P(E | H)}{P(E | H^c)}$$

se denomina **razón de verosimilitudes**.

Esta formulación muestra que Bayes actualiza multiplicativamente las odds previas.

6.9. Ejemplo algebraico

Sea

$$P(H) = 0.10,$$

$$P(E \mid H) = 0.80,$$

y

$$P(E \mid H^c) = 0.20.$$

Entonces

$$P(E) = 0.10(0.80) + 0.90(0.20) = 0.26.$$

Por Bayes,

$$P(H \mid E) = \frac{0.10(0.80)}{0.26} = \frac{4}{13} \approx 0.3077.$$

En términos de odds:

$$\frac{P(H)}{P(H^c)} = \frac{1}{9},$$

mientras que la razón de verosimilitudes es

$$\frac{0.80}{0.20} = 4.$$

Por tanto, las odds posteriores son

$$\frac{4}{9}.$$

De ahí se recupera

$$P(H \mid E) = \frac{4/9}{1 + 4/9} = \frac{4}{13}.$$

6.10. Particiones numerables

La formulación se extiende a una partición numerable $B_1, B_2, \dots$ siempre que las sumas estén bien definidas.

Si

$$\Omega = \bigcup_{i=1}^{\infty} B_i$$

con eventos dos a dos disjuntos y $P(B_i) > 0$, entonces

$$P(A) = \sum_{i=1}^{\infty} P(B_i)P(A | B_i).$$

Y, si $P(A) > 0$,

$$P(B_i | A) = \frac{P(B_i)P(A | B_i)}{\sum_{j=1}^{\infty} P(B_j)P(A | B_j)}.$$

6.11. Actualización secuencial

Sean E_1 y E_2 dos evidencias. Entonces

$$P(H | E_1, E_2) = \frac{P(H | E_1)P(E_2 | H, E_1)}{P(E_2 | E_1)}.$$

La distribución posterior tras observar E_1 puede utilizarse como distribución previa en la actualización con E_2 .

Esto formaliza la idea de aprendizaje secuencial.

6.12. Evidencia condicionalmente independiente

Si E_1 y E_2 son condicionalmente independientes dado H , entonces

$$P(E_1 \cap E_2 \mid H) = P(E_1 \mid H)P(E_2 \mid H).$$

Bajo esta hipótesis, la actualización con múltiples evidencias se simplifica.

No debe confundirse independencia ordinaria con independencia condicional.

6.13. Tasa base y posterior

El teorema de Bayes muestra que una gran verosimilitud no garantiza una gran probabilidad posterior. El valor de $P(B_i)$ influye necesariamente en la respuesta.

Por ello, en problemas de clasificación o diagnóstico, ignorar las probabilidades previas puede producir inferencias seriamente engañosas.

6.14. Relación con la probabilidad condicional

Bayes no introduce una nueva noción de probabilidad. Es una consecuencia algebraica directa de

$$P(A \cap B) = P(A)P(B \mid A) = P(B)P(A \mid B).$$

Siempre que $P(A) > 0$ y $P(B) > 0$,

$$P(B \mid A) = \frac{P(B)P(A \mid B)}{P(A)}.$$

La ley de la probabilidad total aparece cuando el denominador $P(A)$ debe expresarse en términos de una partición.

6.15. Ejercicios

1. Demuestra la ley de la probabilidad total para una partición de cuatro eventos.
2. Prueba el teorema de Bayes a partir de la definición de probabilidad condicional y la ley de probabilidad total.
3. Si B_1, B_2, B_3 forman una partición con probabilidades 0.2, 0.5, 0.3 y $P(A | B_i) = 0.1, 0.4, 0.7$, calcula $P(A)$ y las tres probabilidades posteriores.
4. Demuestra que las probabilidades posteriores obtenidas en el ejercicio anterior suman 1.
5. Deriva la forma de Bayes en términos de odds para dos hipótesis complementarias.
6. Sea $P(H) = p$, $P(E | H) = s$ y $P(E | H^c) = f$. Demuestra que

$$P(H | E) = \frac{ps}{ps + (1 - p)f}.$$

7. Analiza el límite de la expresión anterior cuando $p \rightarrow 0$ y cuando $p \rightarrow 1$.
8. Si $P(E | H) = P(E | H^c)$, demuestra que $P(H | E) = P(H)$.
9. Si una evidencia tiene razón de verosimilitudes igual a 1, interpreta su efecto sobre las odds previas.
10. **Reto** . Supón que E_1 y E_2 son condicionalmente independientes dado H y dado H^c . Deriva una expresión para las odds posteriores tras observar ambas evidencias.

6.16. Referencias del capítulo

El desarrollo teórico de particiones, ley de probabilidad total y teorema de Bayes sigue la formulación estándar de Devore (2016), Montgomery y Runger (2018), Walpole et al. (2012) y Johnson (2018). La notación se adapta al enfoque formal adoptado en este libro.

7 Variable aleatoria y función de distribución acumulada

7.1. Objetivos

En este capítulo se formaliza el concepto de variable aleatoria como función medible y se estudia la función de distribución acumulada como objeto fundamental asociado a cualquier variable aleatoria real.

7.2. Variable aleatoria

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Una **variable aleatoria real** es una función

$$X : \Omega \longrightarrow \mathbb{R}$$

tal que, para todo $x \in \mathbb{R}$,

$$\{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F}.$$

Esta condición garantiza que los eventos definidos mediante desigualdades de X tienen probabilidad bien definida.

7.3. Interpretación mediante preimágenes

Para un conjunto $B \subseteq \mathbb{R}$, el evento asociado es la preimagen

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}.$$

Por ejemplo,

$$\{X \leq x\} = X^{-1}((-\infty, x]).$$

La aleatoriedad reside en el resultado ω ; la función X es determinista una vez definida.

7.4. Variables discretas

Una variable aleatoria es discreta cuando su imagen

$$X(\Omega)$$

es finita o numerable. Si sus valores son $x_1, x_2, \dots$, entonces

$$P(X = x_i)$$

determina su distribución.

7.5. Variables continuas

Una variable aleatoria se denomina continua cuando su distribución puede describirse mediante una densidad respecto de la medida de Lebesgue. Este concepto se formalizará posteriormente. Por ahora basta señalar que para variables continuas típicas,

$$P(X = x) = 0$$

para cada punto individual x .

7.6. Función de distribución acumulada

La **función de distribución acumulada** de X es

$$\boxed{F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.}$$

Toda variable aleatoria real induce una CDF y, recíprocamente, toda función que satisfaga las propiedades características de una CDF determina una distribución de probabilidad sobre $\mathbb{R}$.

7.7. Monotonía

Si $x < y$, entonces

$$\{X \leq x\} \subseteq \{X \leq y\}.$$

Por monotonía de la probabilidad,

$$F_X(x) \leq F_X(y).$$

Por tanto, F_X es no decreciente.

7.8. Límites en los extremos

Como los eventos

$$\{X \leq x\}$$

disminuyen hacia el evento vacío cuando $x \rightarrow -\infty$,

$$\lim_{x \rightarrow -\infty} F_X(x) = 0.$$

Análogamente, al crecer x los eventos $\{X \leq x\}$ aumentan hacia Ω , por lo que

$$\lim_{x \rightarrow \infty} F_X(x) = 1.$$

Estas conclusiones se apoyan en la continuidad de la medida de probabilidad demostrada en capítulos anteriores.

7.9. Continuidad por la derecha

7.9.1. Teorema

Toda función de distribución acumulada es continua por la derecha:

$$\lim_{h \downarrow 0} F_X(x+h) = F_X(x).$$

7.9.2. Demostración

Sea $x_n \downarrow x$. Los eventos

$$A_n = \{X \leq x_n\}$$

forman una sucesión decreciente y

$$\bigcap_{n=1}^{\infty} A_n = \{X \leq x\}.$$

Por continuidad desde arriba de la probabilidad,

$$P(A_n) \rightarrow P(X \leq x).$$

Por tanto,

$$F_X(x_n) \rightarrow F_X(x).$$

7.10. Límite por la izquierda y masa puntual

Definimos

$$F_X(x^-) = \lim_{t \uparrow x} F_X(t).$$

Entonces

$$P(X < x) = F_X(x^-).$$

Además,

$$P(X = x) = F_X(x) - F_X(x^-).$$

Por ello, los saltos de la CDF corresponden exactamente a masas puntuales de probabilidad.

7.11. Probabilidades de intervalos

Para $a < b$,

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

También,

$$P(X > b) = 1 - F_X(b),$$

$$P(a \leq X \leq b) = F_X(b) - F_X(a^-),$$

y

$$P(a < X < b) = F_X(b^-) - F_X(a).$$

Estas identidades muestran que la CDF contiene toda la información de la distribución.

7.12. Distribución inducida por una variable aleatoria

La variable X induce una medida de probabilidad P_X sobre $\mathbb{R}$ definida por

$$P_X(B) = P(X \in B)$$

para conjuntos borelianos B .

Esta medida se denomina **distribución** o **ley** de X .

La CDF puede escribirse como

$$F_X(x) = P_X((-\infty, x]).$$

7.13. Variables con la misma distribución

Dos variables aleatorias X y Y , incluso definidas sobre espacios muestrales diferentes, tienen la misma distribución si

$$F_X(x) = F_Y(x)$$

para todo $x \in \mathbb{R}$.

Se escribe habitualmente

$$X \stackrel{d}{=} Y.$$

Tener la misma distribución no significa que $X(\omega) = Y(\omega)$ punto por punto.

7.14. Ejemplo discreto

Sea

$$P(X = 0) = \frac{1}{4}, \quad P(X = 1) = \frac{1}{2}, \quad P(X = 2) = \frac{1}{4}.$$

Entonces

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1/4, & 0 \leq x < 1, \\ 3/4, & 1 \leq x < 2, \\ 1, & x \geq 2. \end{cases}$$

Los saltos en 0, 1, 2 tienen magnitudes $1/4, 1/2, 1/4$, respectivamente.

7.15. Caracterización de una función de distribución

Una función $F : \mathbb{R} \rightarrow [0, 1]$ es una función de distribución si satisface:

1. F es no decreciente;
2. F es continua por la derecha;
3. $\lim_{x \rightarrow -\infty} F(x) = 0$;
4. $\lim_{x \rightarrow \infty} F(x) = 1$.

Estas condiciones constituyen una caracterización fundamental de las distribuciones sobre la recta real.

7.16. Átomos y continuidad

Un punto x se denomina átomo de la distribución si

$$P(X = x) > 0.$$

Equivalente:

$$F_X(x) > F_X(x^-).$$

Una distribución sin átomos tiene una CDF continua. No toda CDF continua posee necesariamente una densidad, aunque las distribuciones continuas elementales que estudiaremos más adelante sí la tendrán.

7.17. Transformaciones y eventos

Para una función $g : \mathbb{R} \rightarrow \mathbb{R}$, podemos definir

$$Y = g(X).$$

Entonces

$$\{Y \leq y\} = \{g(X) \leq y\}.$$

El cálculo de la distribución de Y mediante preimágenes será el tema central del capítulo sobre funciones de una variable aleatoria.

7.18. Referencias del capítulo

El desarrollo formal de variables aleatorias, distribuciones inducidas y funciones de distribución acumulada sigue la formulación estándar de Devore (2016), Montgomery y Runger (2018), Walpole et al. (2012) y Johnson (2018).

8 Variables aleatorias discretas y función de masa de probabilidad

8.1. Objetivos

En este capítulo se formaliza el concepto de variable aleatoria discreta, su función de masa de probabilidad, el soporte de la distribución y la relación exacta entre la PMF y la función de distribución acumulada.

8.2. Variable aleatoria discreta

Sea

$$X : (\Omega, \mathcal{F}) \rightarrow \mathbb{R}$$

una variable aleatoria. Diremos que X es **discreta** si existe un conjunto finito o numerable

$$S_X = \{x_1, x_2, \dots\} \subseteq \mathbb{R}$$

tal que

$$P(X \in S_X) = 1.$$

El conjunto

$$\mathcal{S}_X = \{x \in \mathbb{R} : P(X = x) > 0\}$$

se denomina **soporte efectivo** de la distribución.

8.3. Función de masa de probabilidad

La función de masa de probabilidad de X es

$$p_X(x) = P(X = x).$$

8.3.1. Proposición

Una función $p : \mathbb{R} \rightarrow [0, 1]$ es la PMF de alguna variable aleatoria discreta con soporte numerable S si y sólo si

$$p(x) \geq 0$$

para todo x y

$$\sum_{x \in S} p(x) = 1,$$

con $p(x) = 0$ fuera de S .

8.3.2. Demostración

Si $p = p_X$, la no negatividad se sigue de los axiomas de probabilidad. Como los eventos

$$\{X = x\}, \quad x \in S,$$

son mutuamente excluyentes y su unión tiene probabilidad 1,

$$1 = P(X \in S) = \sum_{x \in S} P(X = x) = \sum_{x \in S} p_X(x).$$

Recíprocamente, dada una sucesión de masas no negativas que suma 1, puede construirse un espacio muestral discreto con probabilidades puntuales iguales a esas masas y definir X como la aplicación identidad sobre el soporte.

8.4. Probabilidad de eventos definidos por X

Sea $A \subseteq \mathbb{R}$. Entonces

$$P(X \in A) = \sum_{x \in A \cap \mathcal{S}_X} p_X(x).$$

En particular,

$$P(a < X \leq b) = \sum_{a < x \leq b} p_X(x).$$

Esta identidad es la versión discreta de la regla de integración que aparecerá en variables continuas.

8.5. Distribución inducida por una variable discreta

La variable X induce una medida de probabilidad sobre $\mathbb{R}$ dada por

$$\mu_X(A) = P(X \in A).$$

En el caso discreto,

$$\mu_X(A) = \sum_{x \in A \cap \mathcal{S}_X} p_X(x).$$

Por tanto, la distribución completa queda determinada por las masas puntuales $p_X(x)$.

8.6. Relación con la función de distribución acumulada

La CDF es

$$F_X(t) = P(X \leq t).$$

Para una variable discreta,

$$F_X(t) = \sum_{x \leq t} p_X(x).$$

8.6.1. Proposición: saltos de la CDF

Para todo $x \in \mathbb{R}$,

$$P(X = x) = F_X(x) - F_X(x^-),$$

donde

$$F_X(x^-) = \lim_{t \uparrow x} F_X(t).$$

8.6.2. Demostración

Como

$$\{X \leq x\} = \{X < x\} \cup \{X = x\},$$

y los dos eventos son disjuntos,

$$F_X(x) = P(X < x) + P(X = x).$$

Además,

$$P(X < x) = F_X(x^-).$$

Por tanto,

$$P(X = x) = F_X(x) - F_X(x^-).$$

Así, los átomos de la distribución coinciden exactamente con los puntos de salto de la CDF.

8.7. Átomos y distribuciones discretas

Un punto x es un **átomo** de la distribución de X si

$$P(X = x) > 0.$$

Una distribución discreta está concentrada en un conjunto numerable de átomos.

Si el soporte es finito,

$$\mathcal{S}_X = \{x_1, \dots, x_n\},$$

entonces

$$\sum_{i=1}^n p_X(x_i) = 1.$$

Si el soporte es infinito numerable,

$$\sum_{i=1}^{\infty} p_X(x_i) = 1.$$

La convergencia de esta serie es parte esencial de la definición de la distribución.

8.8. Soporte y representación no única

Puede ocurrir que una función se describa sobre un conjunto más grande que el soporte efectivo. Por ejemplo, si se declara

$$p(0) = 0, \quad p(1) = 0.4, \quad p(2) = 0.6,$$

el soporte efectivo es

$$\{1, 2\},$$

no $\{0, 1, 2\}$.

Esta distinción resulta útil en formulaciones paramétricas.

8.9. Construcción mediante transformación

Sea Y una variable aleatoria discreta con PMF p_Y y sea

$$X = g(Y).$$

Entonces

$$P(X = x) = P(g(Y) = x)$$

y, por tanto,

$$p_X(x) = \sum_{y:g(y)=x} p_Y(y).$$

Esta fórmula agrega las masas de todos los valores de Y que son enviados al mismo valor x .

8.9.1. Ejemplo

Sea Y uniforme sobre

$$\{-2, -1, 0, 1, 2\}$$

y defina

$$X = Y^2.$$

Entonces

$$\mathcal{S}_X = \{0, 1, 4\}$$

y

$$p_X(0) = \frac{1}{5},$$

$$p_X(1) = \frac{2}{5},$$

$$p_X(4) = \frac{2}{5}.$$

Las probabilidades de $Y = 1$ y $Y = -1$ se suman porque ambas preimágenes producen $X = 1$.

8.10. PMF a partir de una CDF escalonada

Si una CDF tiene saltos en puntos

$$x_1 < x_2 < \cdots,$$

entonces

$$p_X(x_i) = F_X(x_i) - F_X(x_i^-).$$

Por tanto, para distribuciones discretas, PMF y CDF contienen exactamente la misma información.

8.11. Variables con soporte infinito numerable

Considere

$$p_X(k) = \frac{1}{2^k}, \quad k = 1, 2, 3, \dots$$

Como

$$\sum_{k=1}^{\infty} \frac{1}{2^k} = 1,$$

la función define una PMF válida.

La CDF para $n \in \mathbb{N}$ es

$$F_X(n) = \sum_{k=1}^n \frac{1}{2^k} = 1 - \frac{1}{2^n}.$$

Y para t no entero,

$$F_X(t) = F_X(\lfloor t \rfloor)$$

si $t \geq 1$.

8.12. Unicidad de la PMF

Si dos variables aleatorias discretas X y Y tienen la misma PMF,

$$p_X(x) = p_Y(x)$$

para todo x , entonces tienen la misma distribución:

$$P(X \in A) = P(Y \in A)$$

para todo conjunto boreliano A .

No es necesario que X y Y estén definidas sobre el mismo espacio muestral ni que sean la misma función.

8.13. Distribución conjunta de valores discretos y eventos

Para cualquier subconjunto A del soporte,

$$P(X \in A) = \sum_{x \in A} p_X(x).$$

Esta propiedad expresa que la medida inducida por X es completamente atómica.

8.14. Comparación conceptual con el caso continuo

En el caso discreto puede existir

$$P(X = x) > 0.$$

En el caso continuo típico,

$$P(X = x) = 0$$

para todo x .

Por ello, una PMF asigna masa a puntos, mientras que una densidad continua asignará probabilidad a intervalos mediante integrales.

8.15. Ejercicios

1. Sea $p(0) = 0.2$, $p(1) = 0.5$ y $p(2) = 0.3$. Verifica que define una PMF y construye la CDF completa.
2. Sea $p_X(k) = c/3^k$ para $k = 1, 2, \dots$. Determina c .
3. Demuestra que si X es discreta, entonces el conjunto de puntos x tales que $P(X = x) > 0$ es a lo sumo numerable.
4. Sea X con soporte $\{-1, 0, 1\}$ y masas $0.25, 0.5, 0.25$. Define $Y = X^2$ y determina la PMF de Y .
5. Prueba la fórmula

$$p_X(x) = F_X(x) - F_X(x^-).$$

6. Si una CDF tiene saltos de tamaño $0.1, 0.2, 0.3$ y 0.4 en $x = 0, 1, 3, 7$, determina la PMF.
7. Construye una variable aleatoria discreta con soporte infinito numerable cuya PMF sea proporcional a $1/k^2$.
8. Explica por qué no puede existir una variable discreta con un número no numerable de puntos con masa estrictamente positiva.
9. Si X y Y tienen la misma PMF, demuestra que tienen la misma CDF.
10. **Reto** . Sea X discreta y g una función cualquiera. Demuestra que

$$p_{g(X)}(y) = \sum_{x:g(x)=y} p_X(x).$$

8.16. Referencias del capítulo

El desarrollo formal de variables aleatorias discretas, distribuciones atómicas, PMF y su relación con la CDF sigue la formulación estándar de Devore (2016), Montgomery y Runger (2018), Walpole et al. (2012) y Johnson (2018), adaptada al nivel teórico de este volumen.

9 Variables aleatorias continuas y función de densidad

9.1. Objetivos

En este capítulo se formalizan las variables aleatorias absolutamente continuas, sus funciones de densidad y su relación con la función de distribución acumulada. Se enfatizan las propiedades analíticas que distinguen el caso continuo del discreto.

9.2. Variables aleatorias absolutamente continuas

Sea X una variable aleatoria definida sobre $(\Omega, \mathcal{F}, P)$. Decimos que X es **absolutamente continua** si existe una función integrable

$$f_X : \mathbb{R} \rightarrow [0, \infty)$$

tal que, para todo conjunto boreliano $A \subseteq \mathbb{R}$,

$$P(X \in A) = \int_A f_X(x) dx.$$

La función f_X se denomina **densidad de probabilidad** de X .

9.3. Condiciones básicas de una densidad

Toda densidad satisface

$$f_X(x) \geq 0$$

para casi todo x , y

$$\int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Recíprocamente, toda función medible no negativa con integral total 1 define una distribución absolutamente continua.

9.4. Probabilidad de intervalos

Para $a < b$,

$$P(a < X \leq b) = \int_a^b f_X(x) dx.$$

Como los conjuntos de un solo punto tienen medida de Lebesgue cero,

$$P(X = x) = 0$$

para todo $x \in \mathbb{R}$.

Por ello,

$$P(a < X < b) = P(a \leq X \leq b) = P(a < X \leq b).$$

9.5. La densidad no es una probabilidad puntual

En general,

$$f_X(x) \neq P(X = x).$$

La densidad describe cómo se distribuye localmente la probabilidad respecto de la medida de Lebesgue. Su valor puntual puede ser mayor que 1 sin contradicción, siempre que la integral total permanezca igual a 1.

9.6. Función de distribución acumulada

La CDF de X es

$$F_X(x) = P(X \leq x).$$

Si X es absolutamente continua,

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

En consecuencia, F_X es absolutamente continua y

$$F'_X(x) = f_X(x)$$

para casi todo x .

9.7. Recuperación de probabilidades desde la CDF

Para $a < b$,

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

Como $P(X = a) = 0$,

$$P(a < X < b) = F_X(b) - F_X(a).$$

También

$$P(X > x) = 1 - F_X(x).$$

9.8. Densidad a partir de una CDF

Si una CDF F es absolutamente continua, entonces existe una función integrable f tal que

$$F(x) = \int_{-\infty}^x f(t) dt.$$

Además,

$$f(x) = F'(x)$$

casi en todas partes.

No toda CDF continua posee necesariamente una densidad; la continuidad por sí sola es una condición más débil que la absoluta continuidad.

9.9. Ejemplo normalizado

Sea

$$f(x) = \begin{cases} cx, & 0 \leq x \leq 2, \\ 0, & \text{en otro caso.} \end{cases}$$

La condición

$$\int_0^2 cx dx = 1$$

produce

$$c = \frac{1}{2}.$$

Por tanto,

$$f(x) = \frac{x}{2}, \quad 0 \leq x \leq 2.$$

La CDF es

$$F(x) = \begin{cases} 0, & x < 0, \\ \frac{x^2}{4}, & 0 \leq x \leq 2, \\ 1, & x > 2. \end{cases}$$

9.10. Propiedad de conjuntos de medida cero

Si $N \subseteq \mathbb{R}$ tiene medida de Lebesgue cero y X es absolutamente continua, entonces

$$P(X \in N) = 0.$$

Esto incluye todos los conjuntos finitos y numerables. Así, una variable absolutamente continua asigna probabilidad cero a cualquier conjunto numerable de valores.

9.11. Comparación formal con el caso discreto

En el caso discreto,

$$P(X = x) = p_X(x)$$

puede ser positivo.

En el caso absolutamente continuo,

$$P(X = x) = 0$$

para todo x .

La suma

$$\sum_x p_X(x)$$

del caso discreto es reemplazada por la integral

$$\int f_X(x) dx.$$

9.12. Soporte de una distribución continua

Una noción útil de soporte es el cierre del conjunto donde la densidad es positiva. Si

$$f_X(x) > 0$$

sólo para $x \in (a, b)$, entonces el soporte puede identificarse con $[a, b]$ bajo condiciones regulares.

9.13. Unicidad casi en todas partes

Si dos densidades f y g generan la misma distribución, entonces

$$f(x) = g(x)$$

para casi todo x .

Es decir, pueden diferir en un conjunto de medida cero sin alterar ninguna probabilidad.

9.14. Transformaciones monótonas

Sea $Y = g(X)$, donde g es estrictamente monótona, diferenciable y con inversa diferenciable. Si X tiene densidad f_X , entonces

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|.$$

Esta fórmula se estudiará con mayor detalle al abordar funciones de variables aleatorias.

9.15. Ejemplo de transformación

Si X tiene densidad

$$f_X(x) = 2x, \quad 0 < x < 1,$$

y definimos

$$Y = X^2,$$

entonces

$$g^{-1}(y) = \sqrt{y},$$

y

$$\frac{d}{dy}g^{-1}(y) = \frac{1}{2\sqrt{y}}.$$

Por tanto,

$$f_Y(y) = 2\sqrt{y} \cdot \frac{1}{2\sqrt{y}} = 1,$$

para $0 < y < 1$.

Así, Y tiene densidad uniforme sobre $(0, 1)$.

9.16. Ejercicios

1. Demuestra que si $f \geq 0$ y $\int_{-\infty}^{\infty} f(x)dx = 1$, entonces $P(A) = \int_A f(x)dx$ define una medida de probabilidad sobre los borelianos.
2. Prueba que una variable absolutamente continua satisface $P(X = x) = 0$ para todo x .
3. Sea $f(x) = c(1 + x)$ para $0 \leq x \leq 1$. Determina c y la CDF correspondiente.
4. Demuestra que, para una variable absolutamente continua, incluir o excluir los extremos de un intervalo no cambia su probabilidad.

5. Sea $F(x) = x^3$ para $0 \leq x \leq 1$, con las extensiones usuales fuera del intervalo. Determina la densidad.
6. Explica por qué modificar una densidad en un solo punto no cambia la distribución.
7. Si X tiene densidad $2x$ en $(0, 1)$ y $Y = X^2$, deriva formalmente la densidad de Y .
8. Prueba que si N es numerable y X es absolutamente continua, entonces $P(X \in N) = 0$.
9. Da un ejemplo de una CDF continua que no sea absolutamente continua y explica por qué no admite una densidad ordinaria.
10. **Reto** . Demuestra que dos densidades que generan la misma CDF son iguales casi en todas partes.

9.17. Referencias del capítulo

El desarrollo teórico de variables absolutamente continuas, densidades y funciones de distribución sigue la formulación estándar de Devore (2016), Montgomery y Runger (2018), Walpole et al. (2012) y Johnson (2018), adaptada al nivel formal de este volumen.

10 Esperanza matemática, momentos, varianza y desigualdades probabilísticas

10.1. Objetivos

Este capítulo formaliza la esperanza matemática y la varianza para variables aleatorias discretas y absolutamente continuas, desarrolla sus propiedades fundamentales y establece las desigualdades de Markov y Chebyshev como consecuencias directas de la estructura de integración probabilística.

10.2. Esperanza de una variable aleatoria

Sea X una variable aleatoria definida sobre $(\Omega, \mathcal{F}, P)$. La esperanza de X , cuando existe, se interpreta como la integral de X respecto de la medida de probabilidad P :

$$E[X] = \int_{\Omega} X(\omega) dP(\omega).$$

En los casos elementales estudiados hasta ahora, esta definición adopta formas concretas.

10.2.1. Caso discreto

Si X tiene soporte numerable $\mathcal{S}_X$, entonces

$$E[X] = \sum_{x \in \mathcal{S}_X} x P(X = x).$$

Esta suma debe converger absolutamente para que $E[X]$ exista como número real finito:

$$\sum_x |x| P(X = x) < \infty.$$

10.2.2. Caso absolutamente continuo

Si X tiene densidad f_X , entonces

$$E[X] = \int_{-\infty}^{\infty} x f_X(x) dx,$$

si

$$\int_{-\infty}^{\infty} |x| f_X(x) dx < \infty.$$

10.3. Esperanza de funciones de una variable

Sea $g : \mathbb{R} \rightarrow \mathbb{R}$ medible. Si $g(X)$ es integrable, entonces

$$E[g(X)] = \int_{\Omega} g(X(\omega)) dP(\omega).$$

En el caso discreto,

$$E[g(X)] = \sum_x g(x) p_X(x),$$

y en el caso absolutamente continuo,

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

Esta identidad evita construir explícitamente la distribución inducida de $g(X)$.

10.4. Linealidad de la esperanza

Si X y Y son integrables y $a, b \in \mathbb{R}$, entonces

$$E[aX + bY] = aE[X] + bE[Y].$$

10.4.1. Demostración

Por linealidad de la integral,

$$E[aX + bY] = \int_{\Omega} (aX + bY) dP = a \int_{\Omega} X dP + b \int_{\Omega} Y dP.$$

Por tanto,

$$E[aX + bY] = aE[X] + bE[Y].$$

La independencia no interviene en este resultado.

10.5. Variables indicadoras

Para un evento $A \in \mathcal{F}$, definimos

$$I_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A. \end{cases}$$

Entonces

$$\boxed{E[I_A] = P(A)}.$$

10.5.1. Demostración

Como I_A sólo toma los valores 0 y 1,

$$E[I_A] = 0 P(A^c) + 1 P(A) = P(A).$$

Esta identidad permite convertir problemas de conteo en sumas de esperanzas.

Si

$$N = \sum_{i=1}^n I_{A_i},$$

entonces

$$E[N] = \sum_{i=1}^n P(A_i),$$

sin requerir independencia entre los eventos A_i .

10.6. Momentos

El momento ordinario de orden r se define por

$$\mu'_r = E[X^r],$$

si existe.

El momento central de orden r se define por

$$\mu_r = E[(X - \mu)^r],$$

donde

$$\mu = E[X].$$

El segundo momento central es especialmente importante.

10.7. Varianza

Si $E[X^2] < \infty$, la varianza de X es

$$\boxed{\text{Var}(X) = E[(X - E[X])^2]}.$$

Por construcción,

$$\text{Var}(X) \geq 0.$$

La desviación estándar se define por

$$\sigma_X = \sqrt{\text{Var}(X)}.$$

10.8. Fórmula alternativa de la varianza

Si $E[X^2] < \infty$, entonces

$$\boxed{\text{Var}(X) = E[X^2] - E[X]^2}.$$

10.8.1. Demostración

Sea $\mu = E[X]$. Entonces

$$\begin{aligned} \text{Var}(X) &= E[(X - \mu)^2] \\ &= E[X^2 - 2\mu X + \mu^2] \\ &= E[X^2] - 2\mu E[X] + \mu^2 \\ &= E[X^2] - 2\mu^2 + \mu^2 \\ &= E[X^2] - \mu^2. \end{aligned}$$

10.9. Caracterización de varianza nula

Si $E[X^2] < \infty$, entonces

$$\text{Var}(X) = 0$$

si y sólo si

$$P(X = E[X]) = 1.$$

Es decir, una variable tiene varianza cero exactamente cuando es constante casi seguramente.

10.10. Transformaciones afines

Sean $a, b \in \mathbb{R}$. Entonces

$$E[aX + b] = aE[X] + b,$$

y

$$\boxed{\text{Var}(aX + b) = a^2 \text{Var}(X)}.$$

10.10.1. Demostración

Sea $\mu = E[X]$. Entonces

$$E[aX + b] = a\mu + b.$$

Por tanto,

$$\begin{aligned}\text{Var}(aX + b) &= E[(aX + b - (a\mu + b))^2] \\ &= E[a^2(X - \mu)^2] \\ &= a^2 \text{Var}(X).\end{aligned}$$

10.11. Covarianza y varianza de una suma

Aunque el estudio detallado de variables conjuntas se realizará más adelante, conviene anticipar una identidad fundamental.

La covarianza se define por

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])].$$

Siempre que existan los segundos momentos,

$$\boxed{\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)}.$$

Si X y Y son independientes, entonces

$$\text{Cov}(X, Y) = 0,$$

y por tanto

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

La implicación recíproca no es válida en general: covarianza cero no implica independencia.

10.12. Desigualdad de Markov

Sea $X \geq 0$ casi seguramente y sea $a > 0$. Entonces

$$P(X \geq a) \leq \frac{E[X]}{a}.$$

10.12.1. Demostración

La desigualdad puntual

$$X \geq aI_{\{X \geq a\}}$$

implica, por monotonía de la esperanza,

$$E[X] \geq aE[I_{\{X \geq a\}}].$$

Como

$$E[I_{\{X \geq a\}}] = P(X \geq a),$$

se obtiene

$$E[X] \geq aP(X \geq a),$$

y por tanto

$$P(X \geq a) \leq \frac{E[X]}{a}.$$

10.13. Desigualdad de Chebyshev

Sea X una variable aleatoria con media finita μ y varianza finita σ^2 . Para todo $t > 0$,

$$P(|X - \mu| \geq t) \leq \frac{\sigma^2}{t^2}.$$

Tomando

$$t = k\sigma,$$

con $k > 0$, resulta

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

Equivalentemente,

$$P(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2}.$$

10.13.1. Demostración a partir de Markov

La variable

$$Y = (X - \mu)^2$$

es no negativa. Aplicando Markov con umbral t^2 ,

$$P((X - \mu)^2 \geq t^2) \leq \frac{E[(X - \mu)^2]}{t^2}.$$

Como

$$\{(X - \mu)^2 \geq t^2\} = \{|X - \mu| \geq t\}$$

y

$$E[(X - \mu)^2] = \sigma^2,$$

se obtiene el resultado.

10.14. Consecuencia: concentración alrededor de la media

Chebyshev muestra que cualquier distribución con varianza finita debe concentrar una proporción mínima de su masa alrededor de la media.

Para $k = 2$,

$$P(|X - \mu| < 2\sigma) \geq \frac{3}{4}.$$

Para $k = 3$,

$$P(|X - \mu| < 3\sigma) \geq \frac{8}{9}.$$

No se supone normalidad, simetría ni unimodalidad.

10.15. Relación entre Markov y Chebyshev

Markov requiere:

- no negatividad;
- existencia de $E[X]$.

Chebyshev se obtiene aplicando Markov a $(X - \mu)^2$ y requiere:

- existencia de $E[X]$;
- existencia de $E[X^2]$.

En este sentido, Chebyshev es una desigualdad de segundo momento.

10.16. Ejemplo teórico: variable de Bernoulli

Sea X una variable Bernoulli con

$$P(X = 1) = p, \quad P(X = 0) = 1 - p.$$

Entonces

$$E[X] = p,$$

$$E[X^2] = p,$$

porque $X^2 = X$. Por tanto,

$$\boxed{\text{Var}(X) = p(1 - p)}.$$

Este resultado será fundamental al estudiar distribuciones binomiales.

10.17. Ejemplo teórico: variable uniforme continua

Sea X uniforme en $[a, b]$ con densidad

$$f_X(x) = \frac{1}{b - a}, \quad a \leq x \leq b.$$

Entonces

$$E[X] = \frac{1}{b - a} \int_a^b x \, dx = \frac{a + b}{2}.$$

Además,

$$E[X^2] = \frac{1}{b - a} \int_a^b x^2 \, dx = \frac{a^2 + ab + b^2}{3}.$$

Por tanto,

$$\boxed{\text{Var}(X) = \frac{(b-a)^2}{12}}.$$

10.18. Existencia de momentos

No toda variable aleatoria posee esperanza o varianza finitas.

Puede ocurrir que

$$E[|X|] = \infty,$$

por lo que $E[X]$ no existe como número real finito.

Incluso puede existir $E[X]$ pero no $E[X^2]$. En ese caso la media existe, pero la varianza es infinita o no está definida como cantidad finita.

Por ello, antes de utilizar fórmulas de momentos es necesario verificar su existencia.

10.19. Momentos y forma de una distribución

Los primeros momentos tienen interpretaciones habituales:

- primer momento: centro;
- segundo momento central: dispersión;
- tercer momento central normalizado: asimetría;
- cuarto momento central normalizado: comportamiento de colas y apuntamiento.

El estudio detallado de asimetría y curtosis se reservará para capítulos posteriores.

10.20. Referencias del capítulo

El tratamiento formal de esperanza, momentos, varianza, variables indicadoras y desigualdades de Markov y Chebyshev sigue la presentación clásica de teoría de probabilidad desarrollada en Devore (2016), Johnson (2018), Walpole et al. (2012) y Montgomery y Runger (2018), con apoyo computacional complementario basado en Kerns (2010).

11 Distribuciones discretas especiales I: Bernoulli, binomial, geométrica y binomial negativa

11.1. Objetivos

Este capítulo presenta formalmente cuatro familias discretas construidas a partir de ensayos de Bernoulli. Se estudiarán sus funciones de masa, soportes, momentos, relaciones estructurales y propiedades características.

11.2. Variable de Bernoulli

Sea X una variable con soporte $\{0, 1\}$ tal que

$$P(X = 1) = p, \quad P(X = 0) = 1 - p,$$

con $0 \leq p \leq 1$. Entonces

$$X \sim \text{Bernoulli}(p).$$

Su PMF puede escribirse como

$$p_X(x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}.$$

La esperanza es

$$E[X] = 0(1 - p) + 1(p) = p,$$

y

$$E[X^2] = p.$$

Por tanto,

$$\text{Var}(X) = p - p^2 = p(1 - p).$$

11.3. La binomial como suma de Bernoulli

Sean

$$X_1, \dots, X_n$$

variables Bernoulli independientes con parámetro común p , y defina

$$S_n = X_1 + \dots + X_n.$$

Entonces S_n cuenta el número de éxitos y

$$\boxed{S_n \sim \text{Binomial}(n, p)}.$$

Para $x = 0, 1, \dots, n$,

$$P(S_n = x) = \binom{n}{x} p^x (1 - p)^{n-x}.$$

La normalización se verifica mediante el teorema binomial:

$$\sum_{x=0}^n \binom{n}{x} p^x (1 - p)^{n-x} = (p + 1 - p)^n = 1.$$

11.4. Momentos de la binomial

Por linealidad,

$$E[S_n] = \sum_{i=1}^n E[X_i] = np.$$

Como las variables son independientes,

$$\text{Var}(S_n) = \sum_{i=1}^n \text{Var}(X_i) = np(1-p).$$

La representación como suma de Bernoulli es más estructural que una derivación puramente algebraica de los momentos.

11.5. Cociente entre masas consecutivas

Para una binomial,

$$\frac{P(X = x + 1)}{P(X = x)} = \frac{n - x}{x + 1} \frac{p}{1 - p}.$$

Esta relación permite estudiar la forma de la PMF y localizar sus modos.

11.6. Distribución geométrica

Considere una sucesión de ensayos de Bernoulli independientes con parámetro p . Sea

$$T = \inf\{n \geq 1 : X_n = 1\},$$

el tiempo discreto hasta el primer éxito.

Entonces

$$T \sim \text{Geométrica}(p)$$

con soporte $\{1, 2, \dots\}$ y

$$P(T = t) = (1 - p)^{t-1}p.$$

La normalización se obtiene de la serie geométrica:

$$\sum_{t=1}^{\infty} (1 - p)^{t-1}p = p \sum_{j=0}^{\infty} (1 - p)^j = 1.$$

11.7. Función de supervivencia geométrica

Para $t = 0, 1, 2, \dots$,

$$P(T > t) = (1 - p)^t.$$

Por tanto,

$$F_T(t) = 1 - (1 - p)^{\lfloor t \rfloor}$$

para $t \geq 1$, interpretando adecuadamente la función escalonada.

11.8. Propiedad sin memoria

La geométrica satisface

$$P(T > s + t \mid T > s) = P(T > t),$$

para $s, t \geq 0$ enteros.

Demostración:

$$P(T > s + t \mid T > s) = \frac{P(T > s + t)}{P(T > s)} = \frac{(1 - p)^{s+t}}{(1 - p)^s} = (1 - p)^t.$$

La distribución geométrica es la única distribución discreta sobre enteros positivos con esta propiedad, bajo condiciones naturales de no degeneración.

11.9. Esperanza de la geométrica

Usando la identidad para variables enteras positivas

$$E[T] = \sum_{t=0}^{\infty} P(T > t),$$

obtenemos

$$E[T] = \sum_{t=0}^{\infty} (1-p)^t = \frac{1}{p}.$$

Además,

$$\text{Var}(T) = \frac{1-p}{p^2}.$$

11.10. Distribución binomial negativa

Sea T_r el número total de ensayos necesarios para observar el r -ésimo éxito, con $r \in \mathbb{N}$.

Entonces

$$T_r \sim \text{BinomialNegativa}(r, p)$$

bajo la parametrización de número total de ensayos, con soporte

$$\{r, r+1, r+2, \dots\}.$$

La PMF es

$$P(T_r = t) = \binom{t-1}{r-1} p^r (1-p)^{t-r},$$

para $t \geq r$.

11.11. Derivación de la PMF binomial negativa

El evento $\{T_r = t\}$ exige dos condiciones:

1. en los primeros $t - 1$ ensayos ocurren exactamente $r - 1$ éxitos;
2. el ensayo t es éxito.

Por independencia,

$$P(T_r = t) = \binom{t-1}{r-1} p^{r-1} (1-p)^{t-r} p,$$

que conduce a la fórmula anterior.

11.12. Representación como suma de geométricas

Sean $G_1, \dots, G_r$ independientes y geométricas con parámetro p , cada una contando ensayos desde un éxito hasta el siguiente. Entonces

$$T_r = G_1 + \dots + G_r.$$

De aquí se obtiene inmediatamente

$$E[T_r] = \frac{r}{p}$$

y

$$\text{Var}(T_r) = \frac{r(1-p)}{p^2}.$$

11.13. Relación con el conteo de fracasos

Otra parametrización define

$$Y = T_r - r,$$

que cuenta el número de fracasos antes del r -ésimo éxito. Entonces

$$P(Y = y) = \binom{y + r - 1}{r - 1} p^r (1 - p)^y,$$

para $y = 0, 1, 2, \dots$

Esta es la convención empleada por las funciones `dnbinom`, `pnbinom` y `rnbinom` de R.

11.14. Relaciones entre las cuatro familias

- Bernoulli es Binomial($1, p$).
- Una binomial es suma de Bernoulli independientes.
- Una geométrica es BinomialNegativa($1, p$) bajo la parametrización de tiempo hasta el éxito.
- Una binomial negativa es suma de geométricas independientes con el mismo p .

Estas relaciones permiten derivar propiedades de una familia a partir de otra.

11.15. Selección estructural del modelo

La pregunta matemática central es qué variable se está definiendo:

- indicador de un solo ensayo $\rightarrow$ Bernoulli;
- número de éxitos en un número fijo de ensayos $\rightarrow$ binomial;
- tiempo hasta el primer éxito $\rightarrow$ geométrica;
- tiempo hasta el r -ésimo éxito $\rightarrow$ binomial negativa.

11.16. Ejercicios teóricos

1. Verifica directamente que la PMF Bernoulli suma 1.
2. Deriva la PMF binomial a partir de una suma de Bernoulli independientes.
3. Demuestra la normalización binomial mediante el teorema binomial.
4. Obtén $E[X]$ y $\text{Var}(X)$ de una binomial usando indicadores.
5. Demuestra la fórmula $P(T > t) = (1 - p)^t$ para una geométrica.
6. Demuestra formalmente la propiedad sin memoria.
7. Obtén $E[T] = 1/p$ usando probabilidades de cola.
8. Deriva la PMF binomial negativa a partir del evento de que el último ensayo sea el r -ésimo éxito.
9. Usa la representación como suma de geométricas para obtener media y varianza de la binomial negativa.
10. **Reto** . Demuestra que si una distribución sobre los enteros positivos satisface la propiedad sin memoria y $P(T > 1) > 0$, entonces su cola debe ser geométrica.

11.17. Referencias del capítulo

El desarrollo de Bernoulli, binomial, geométrica y binomial negativa sigue la formulación estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

12 Distribuciones discretas especiales II: hipergeométrica y Poisson

12.1. Objetivos

Este capítulo desarrolla formalmente dos familias discretas fundamentales: la distribución hipergeométrica, asociada al muestreo sin reposición en poblaciones finitas, y la distribución de Poisson, asociada al conteo de eventos raros o dispersos en intervalos.

12.2. Distribución hipergeométrica

Sea una población finita de tamaño N con K elementos clasificados como éxitos y $N - K$ como fracasos. Se extrae una muestra de tamaño n sin reposición y se define X como el número de éxitos observados.

Entonces

$$P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}},$$

para

$$\max(0, n - N + K) \leq x \leq \min(n, K).$$

12.2.1. Normalización

La identidad de Vandermonde

$$\sum_x \binom{K}{x} \binom{N-K}{n-x} = \binom{N}{n}$$

implica inmediatamente que

$$\sum_x P(X = x) = 1.$$

12.3. Media de la hipergeométrica

Escribamos

$$X = I_1 + \cdots + I_n,$$

donde I_j indica que la extracción j corresponde a uno de los K elementos de interés. Por simetría,

$$E[I_j] = \frac{K}{N}.$$

Por linealidad,

$$E[X] = n \frac{K}{N}.$$

La independencia no es necesaria para este argumento.

12.4. Varianza de la hipergeométrica

Las variables indicadoras de distintas extracciones no son independientes. Para $i \neq j$,

$$E[I_i I_j] = \frac{K}{N} \frac{K-1}{N-1}.$$

De aquí se obtiene

$$\text{Cov}(I_i, I_j) = -\frac{K(N-K)}{N^2(N-1)}.$$

Al sumar varianzas y covarianzas,

$$\text{Var}(X) = n \frac{K}{N} \left(1 - \frac{K}{N}\right) \frac{N-n}{N-1}.$$

El factor

$$\frac{N-n}{N-1}$$

expresa la reducción de variabilidad debida al muestreo sin reemplazo.

12.5. Aproximación binomial de la hipergeométrica

Si N es grande respecto de n y

$$p = \frac{K}{N},$$

la dependencia inducida por no reemplazar es débil. En este régimen,

$$\text{Hipergeométrica}(N, K, n) \approx \text{Binomial}(n, p).$$

La convergencia puede verse comparando los factores sucesivos de ambas PMF cuando $N \rightarrow \infty$, $K/N \rightarrow p$ y n permanece fijo.

12.6. Distribución de Poisson

Para $\lambda > 0$, una variable X tiene distribución de Poisson si

$$P(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

Escribimos

$$X \sim \text{Poisson}(\lambda).$$

12.7. Normalización

Por la serie exponencial,

$$e^\lambda = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}.$$

Por tanto,

$$\sum_{x=0}^{\infty} e^{-\lambda} \frac{\lambda^x}{x!} = 1.$$

12.8. Media y varianza de Poisson

Para la media,

$$E[X] = \sum_{x=1}^{\infty} x e^{-\lambda} \frac{\lambda^x}{x!} = \lambda e^{-\lambda} \sum_{x=1}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} = \lambda.$$

Asimismo,

$$E[X(X-1)] = \lambda^2.$$

Como

$$X^2 = X(X-1) + X,$$

se sigue que

$$E[X^2] = \lambda^2 + \lambda$$

y entonces

$$\boxed{\text{Var}(X) = \lambda}.$$

12.9. Función generadora de probabilidades

La función generadora de probabilidades es

$$G_X(s) = E[s^X].$$

Para una Poisson,

$$G_X(s) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda s)^x}{x!} = \exp\{\lambda(s-1)\}.$$

Esta expresión permite obtener momentos y estudiar sumas de variables independientes.

12.10. Suma de Poisson independientes

Si

$$X \sim \text{Poisson}(\lambda_1), \quad Y \sim \text{Poisson}(\lambda_2)$$

son independientes, entonces

$$G_{X+Y}(s) = G_X(s)G_Y(s) = \exp\{(\lambda_1 + \lambda_2)(s-1)\}.$$

Por unicidad de la función generadora,

$$\boxed{X + Y \sim \text{Poisson}(\lambda_1 + \lambda_2)}.$$

El resultado se extiende a cualquier suma finita de variables Poisson independientes.

12.11. Límite de Poisson de la binomial

Sea

$$X_n \sim \text{Binomial}(n, p_n),$$

y supongamos

$$np_n \rightarrow \lambda > 0.$$

Para x fijo,

$$P(X_n = x) = \binom{n}{x} p_n^x (1 - p_n)^{n-x}.$$

Tomando, por simplicidad, $p_n = \lambda/n$,

$$P(X_n = x) = \frac{n(n-1)\cdots(n-x+1)}{x!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x}.$$

Cuando $n \rightarrow \infty$,

$$\frac{n(n-1)\cdots(n-x+1)}{n^x} \rightarrow 1$$

y

$$\left(1 - \frac{\lambda}{n}\right)^n \rightarrow e^{-\lambda}.$$

Por tanto,

$$\boxed{P(X_n = x) \rightarrow e^{-\lambda} \frac{\lambda^x}{x!}}.$$

Éste es el teorema límite de Poisson para eventos raros.

12.12. Interpretación de λ

El parámetro λ representa el número esperado de eventos en el intervalo considerado. Si existe una tasa r por unidad y el intervalo tiene longitud t , se modela habitualmente con

$$\lambda = rt.$$

Esta interpretación anticipa el proceso de Poisson, que requiere una teoría adicional sobre conteos en intervalos disjuntos y tiempos de llegada.

12.13. Diferencias estructurales

La hipergeométrica surge de un espacio finito con muestreo sin reemplazo. La Poisson posee soporte infinito y suele aparecer como límite de conteos binomiales de eventos raros. La primera exhibe dependencia negativa entre extracciones; la segunda se caracteriza por igualdad entre media y varianza.

12.14. Ejercicios

1. Demuestra la normalización hipergeométrica usando la identidad de Vandermonde.
2. Obtén $E[X]$ de la hipergeométrica mediante variables indicadoras.
3. Deriva la covarianza entre dos indicadores de extracciones sin reemplazo.
4. A partir del ejercicio anterior, demuestra la fórmula de la varianza hipergeométrica.
5. Demuestra la normalización de la distribución Poisson mediante la serie de e^λ .
6. Obtén $E[X(X-1)]$ para $X \sim \text{Poisson}(\lambda)$.
7. Usa el resultado anterior para demostrar que $\text{Var}(X) = \lambda$.
8. Demuestra el resultado de suma de Poisson independientes usando funciones generadoras.
9. Demuestra el límite binomial–Poisson para $p_n = \lambda/n$.
10. **Reto.** Discute por qué la varianza hipergeométrica tiende a la binomial cuando $N \rightarrow \infty$ con $K/N \rightarrow p$ y n fijo.

12.15. Referencias del capítulo

El desarrollo teórico de las distribuciones hipergeométrica y de Poisson, sus momentos y resultados límite sigue el tratamiento estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

13 Distribuciones continuas especiales I: uniforme, exponencial y normal

13.1. Objetivos

En este capítulo se establecen formalmente las distribuciones uniforme, exponencial y normal, sus densidades, funciones de distribución, momentos y propiedades estructurales fundamentales.

13.2. Distribución uniforme

Sea $a < b$. Decimos que

$$X \sim U(a, b)$$

si su densidad es

$$f_X(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x).$$

La normalización es inmediata:

$$\int_{-\infty}^{\infty} f_X(x) dx = \int_a^b \frac{1}{b-a} dx = 1.$$

La función de distribución es

$$F_X(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x \leq b, \\ 1, & x > b. \end{cases}$$

Por integración directa,

$$E[X] = \frac{a+b}{2}$$

y

$$E[X^2] = \frac{a^2 + ab + b^2}{3}.$$

Por tanto,

$$\text{Var}(X) = E[X^2] - E[X]^2 = \frac{(b-a)^2}{12}.$$

13.3. Transformación afín de una uniforme

Si $X \sim U(a, b)$ y

$$Y = \frac{X-a}{b-a},$$

entonces

$$Y \sim U(0, 1).$$

Este resultado permite reducir propiedades de cualquier uniforme al caso estándar.

13.4. Distribución exponencial

Sea $\lambda > 0$. Decimos que

$$X \sim \text{Exp}(\lambda)$$

si

$$f_X(x) = \lambda e^{-\lambda x} \mathbf{1}_{[0, \infty)}(x).$$

La función de distribución es

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1 - e^{-\lambda x}, & x \geq 0. \end{cases}$$

Su función de supervivencia es

$$\bar{F}_X(x) = P(X > x) = e^{-\lambda x}, \quad x \geq 0.$$

Mediante integración por partes,

$$E[X] = \frac{1}{\lambda}$$

y

$$E[X^2] = \frac{2}{\lambda^2}.$$

Por tanto,

$$\text{Var}(X) = \frac{1}{\lambda^2}.$$

13.5. Propiedad sin memoria

Para $s, t \geq 0$,

$$P(X > s + t \mid X > s) = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t}.$$

Luego

$$\boxed{P(X > s + t \mid X > s) = P(X > t)}.$$

La distribución exponencial es la única distribución continua no degenerada sobre $[0, \infty)$ con esta propiedad.

13.6. Distribución normal

Decimos que

$$X \sim N(\mu, \sigma^2), \quad \sigma > 0,$$

si su densidad es

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x-\mu)^2}{2\sigma^2} \right].$$

La normalización se reduce a la integral gaussiana

$$\int_{-\infty}^{\infty} e^{-z^2/2} dz = \sqrt{2\pi}.$$

La densidad es simétrica respecto de μ .

13.7. Normal estándar

La variable

$$Z \sim N(0, 1)$$

se denomina normal estándar y tiene densidad

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}.$$

Su función de distribución se denota por

$$\Phi(z) = \int_{-\infty}^z \phi(t) dt.$$

No existe una expresión elemental cerrada para Φ .

13.8. Estandarización

Si

$$X \sim N(\mu, \sigma^2),$$

entonces

$$Z = \frac{X - \mu}{\sigma}$$

satisface

$$Z \sim N(0, 1).$$

En consecuencia,

$$P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right).$$

13.9. Media y varianza de la normal

Por simetría,

$$E[Z] = 0.$$

Además,

$$E[Z^2] = 1.$$

Por tanto,

$$\text{Var}(Z) = 1.$$

Como

$$X = \mu + \sigma Z,$$

se obtiene

$$E[X] = \mu$$

y

$$\text{Var}(X) = \sigma^2.$$

13.10. Transformaciones afines

Si

$$X \sim N(\mu, \sigma^2)$$

y

$$Y = aX + b,$$

entonces

$$Y \sim N(a\mu + b, a^2\sigma^2).$$

Este resultado se obtiene mediante cambio de variable o mediante funciones generadoras.

13.11. Cuantiles

Para $0 < p < 1$, el cuantil z_p de la normal estándar se define mediante

$$\Phi(z_p) = p.$$

Para una normal general,

$$x_p = \mu + \sigma z_p.$$

13.12. Simetría de la CDF normal

La simetría de ϕ implica

$$\Phi(-z) = 1 - \Phi(z).$$

Por tanto,

$$P(|Z| \leq z) = 2\Phi(z) - 1,$$

para $z \geq 0$.

13.13. Comparación estructural

Distribución	Soporte	Parámetros	Media	Varianza	Propiedad destacada
Uniforme	$[a, b]$	a, b	$(a + b)/2$	$(b - a)^2/12$	densidad constante
Exponencial	$[0, \infty)$	λ	$1/\lambda$	$1/\lambda^2$	sin memoria
Normal	$\mathbb{R}$	μ, σ^2	μ	σ^2	cierre afín

13.14. Ejercicios

1. Demuestra la expresión de $E[X]$ para $X \sim U(a, b)$.
2. Deduce $\text{Var}(X)$ para la distribución uniforme.
3. Demuestra que $(X - a)/(b - a) \sim U(0, 1)$.
4. Deriva F_X para $X \sim \text{Exp}(\lambda)$.
5. Demuestra la propiedad sin memoria de la exponencial.
6. Calcula $E[X^2]$ para una exponencial mediante integración por partes.
7. Prueba que la densidad normal es simétrica respecto de μ .
8. Demuestra que la estandarización de una normal produce una normal estándar.
9. Deduce $E[X]$ y $\text{Var}(X)$ a partir de $X = \mu + \sigma Z$.
10. Demuestra que $\Phi(-z) = 1 - \Phi(z)$.
11. Obtén la relación entre cuantiles de $N(\mu, \sigma^2)$ y los cuantiles de $N(0, 1)$.
12. **Reto** . Demuestra mediante cambio de variable que $aX + b$ es normal cuando X es normal.

13.15. Referencias del capítulo

El desarrollo teórico de las distribuciones uniforme, exponencial y normal sigue tratamientos estándar de teoría de probabilidad en Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

14 Distribuciones continuas especiales II: Gamma, Weibull y Beta

14.1. Objetivos

Este capítulo desarrolla con mayor profundidad matemática tres familias continuas: Gamma, Weibull y Beta. Se estudian normalización, momentos, casos particulares, funciones de supervivencia, tasas de falla y relaciones estructurales entre familias.

15 Distribución Gamma

Para $\alpha > 0$ y $\lambda > 0$, definimos

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x > 0.$$

15.1. Función Gamma

La función Gamma se define por

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt,$$

para $\alpha > 0$.

Mediante integración por partes se obtiene

$$\Gamma(\alpha + 1) = \alpha \Gamma(\alpha).$$

Si n es entero positivo,

$$\Gamma(n) = (n-1)!.$$

15.2. Normalización

Haciendo el cambio $t = \lambda x$,

$$\int_0^\infty \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} dx = \frac{1}{\Gamma(\alpha)} \int_0^\infty t^{\alpha-1} e^{-t} dt = 1.$$

15.3. Momentos

Para $r > -\alpha$,

$$E[X^r] = \frac{\Gamma(\alpha + r)}{\lambda^r \Gamma(\alpha)}.$$

En particular,

$$E[X] = \frac{\alpha}{\lambda},$$

$$E[X^2] = \frac{\alpha(\alpha + 1)}{\lambda^2},$$

y por tanto

$$\text{Var}(X) = \frac{\alpha}{\lambda^2}.$$

15.4. Caso exponencial

Para $\alpha = 1$,

$$f(x) = \lambda e^{-\lambda x},$$

por lo que

$$\text{Gamma}(1, \lambda) = \text{Exp}(\lambda).$$

15.5. Suma de variables Gamma

Si $X_i \sim \text{Gamma}(\alpha_i, \lambda)$ son independientes con tasa común λ , entonces

$$\sum_{i=1}^n X_i \sim \text{Gamma}\left(\sum_{i=1}^n \alpha_i, \lambda\right).$$

En particular, la suma de r exponenciales independientes de tasa λ tiene distribución $\text{Gamma}(r, \lambda)$.

16 Distribución Weibull

Para $k > 0$ y $\eta > 0$,

$$f(x) = \frac{k}{\eta} \left(\frac{x}{\eta}\right)^{k-1} \exp \left[- \left(\frac{x}{\eta}\right)^k \right], \quad x \geq 0.$$

16.1. Función de distribución

Integrando la densidad,

$$F(x) = 1 - \exp \left[- \left(\frac{x}{\eta}\right)^k \right].$$

La función de supervivencia es

$$S(x) = \exp \left[- \left(\frac{x}{\eta}\right)^k \right].$$

16.2. Tasa de riesgo

La tasa de riesgo o hazard es

$$h(x) = \frac{f(x)}{S(x)} = \frac{k}{\eta} \left(\frac{x}{\eta}\right)^{k-1}.$$

De aquí se deduce:

- $k < 1$: riesgo decreciente;
- $k = 1$: riesgo constante;
- $k > 1$: riesgo creciente.

16.3. Relación con la exponencial

Si $k = 1$,

$$f(x) = \frac{1}{\eta} e^{-x/\eta},$$

que corresponde a una exponencial con tasa $1/\eta$.

16.4. Momentos de Weibull

Para $r > -k$,

$$E[X^r] = \eta^r \Gamma\left(1 + \frac{r}{k}\right).$$

En particular,

$$E[X] = \eta \Gamma\left(1 + \frac{1}{k}\right),$$

y

$$\text{Var}(X) = \eta^2 \left[\Gamma\left(1 + \frac{2}{k}\right) - \Gamma^2\left(1 + \frac{1}{k}\right) \right].$$

16.5. Transformación exponencial

Si $X \sim \text{Weibull}(k, \eta)$, entonces

$$Y = \left(\frac{X}{\eta}\right)^k$$

tiene distribución exponencial estándar:

$$Y \sim \text{Exp}(1).$$

Esta transformación permite derivar directamente la CDF y los momentos.

17 Distribución Beta

Para $\alpha > 0$ y $\beta > 0$,

$$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < x < 1,$$

donde

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1}(1-x)^{\beta-1} dx.$$

17.1. Relación Beta-Gamma

Se cumple

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

Esta identidad conecta de manera profunda las familias Beta y Gamma.

17.2. Normalización

Por definición de $B(\alpha, \beta)$,

$$\int_0^1 f(x) dx = 1.$$

17.3. Momentos

Para $r > -\alpha$,

$$E[X^r] = \frac{B(\alpha + r, \beta)}{B(\alpha, \beta)}.$$

En particular,

$$E[X] = \frac{\alpha}{\alpha + \beta}.$$

Además,

$$E[X^2] = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)},$$

y por tanto

$$\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

17.4. Simetría

Si

$$X \sim \text{Beta}(\alpha, \beta),$$

entonces

$$1 - X \sim \text{Beta}(\beta, \alpha).$$

En particular, cuando $\alpha = \beta$, la distribución es simétrica respecto de $1/2$.

17.5. Caso uniforme

Para

$$\alpha = \beta = 1,$$

$$f(x) = 1, \quad 0 < x < 1,$$

por lo que

$$\text{Beta}(1, 1) = U(0, 1).$$

17.6. Construcción Beta mediante variables Gamma

Si

$$U \sim \text{Gamma}(\alpha, 1), \quad V \sim \text{Gamma}(\beta, 1)$$

son independientes, entonces

$$\boxed{\frac{U}{U+V} \sim \text{Beta}(\alpha, \beta)}.$$

Esta representación es fundamental para entender la relación entre ambas familias.

17.7. Comparación estructural

Gamma y Weibull tienen soporte positivo no acotado, pero su estructura es distinta. Gamma aparece naturalmente en sumas de tiempos exponenciales, mientras Weibull permite tasas de riesgo crecientes o decrecientes. Beta, en cambio, vive en un intervalo acotado y resulta especialmente apropiada para proporciones.

17.8. Ejercicios teóricos

1. Demuestra que $\Gamma(n) = (n-1)!$ para entero positivo n .
2. Verifica la normalización de la densidad Gamma mediante el cambio $t = \lambda x$.
3. Deriva $E[X^r]$ para una variable Gamma.
4. Deduce media y varianza de Gamma a partir de los momentos.
5. Demuestra que $\text{Gamma}(1, \lambda)$ coincide con $\text{Exp}(\lambda)$.
6. Deriva la CDF de Weibull a partir de su densidad.
7. Obtén la tasa de riesgo de Weibull y analiza su monotonía según k .
8. Demuestra que $(X/\eta)^k \sim \text{Exp}(1)$ cuando X es Weibull.
9. Deriva los momentos de Weibull a partir de la transformación anterior.
10. Demuestra la identidad $B(\alpha, \beta) = \Gamma(\alpha)\Gamma(\beta)/\Gamma(\alpha + \beta)$.
11. Deriva media y varianza de Beta.
12. Demuestra que si $X \sim \text{Beta}(\alpha, \beta)$, entonces $1 - X \sim \text{Beta}(\beta, \alpha)$.
13. Demuestra que $\text{Beta}(1, 1)$ es uniforme estándar.
14. **Reto** . Demuestra que si U y V son Gamma independientes con tasa común 1, entonces $U/(U + V)$ tiene distribución Beta.

17.9. Referencias del capítulo

La exposición teórica sigue tratamientos clásicos de distribuciones continuas y funciones especiales en Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

18 Variables aleatorias conjuntas, distribuciones marginales y condicionales

18.1. Objetivos

Al finalizar este capítulo, el lector podrá formular distribuciones conjuntas discretas y continuas, obtener distribuciones marginales y condicionales, caracterizar independencia mediante factorización y trabajar formalmente con funciones de distribución y densidades conjuntas.

18.2. Vectores aleatorios

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Un vector aleatorio bidimensional es una aplicación

$$(X, Y) : \Omega \rightarrow \mathbb{R}^2$$

tal que las preimágenes de conjuntos borelianos de $\mathbb{R}^2$ son eventos de $\mathcal{F}$.

La ley conjunta de (X, Y) es la medida de probabilidad inducida sobre $\mathbb{R}^2$:

$$P_{(X,Y)}(A) = P((X, Y) \in A),$$

para A boreliano.

18.3. Función de distribución conjunta

Definimos

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y).$$

Esta función es no decreciente en cada coordenada, continua por la derecha en el sentido correspondiente y satisface

$$\lim_{x \rightarrow -\infty} F_{X,Y}(x, y) = 0,$$

$$\lim_{y \rightarrow -\infty} F_{X,Y}(x, y) = 0,$$

y

$$\lim_{x, y \rightarrow \infty} F_{X,Y}(x, y) = 1.$$

Además, para $a < b$ y $c < d$,

$$P(a < X \leq b, c < Y \leq d)$$

se obtiene por la fórmula rectangular

$$F(b, d) - F(a, d) - F(b, c) + F(a, c).$$

18.4. Distribuciones marginales

Las funciones de distribución marginales se recuperan mediante

$$F_X(x) = \lim_{y \rightarrow \infty} F_{X,Y}(x, y)$$

y

$$F_Y(y) = \lim_{x \rightarrow \infty} F_{X,Y}(x, y).$$

Esta operación se denomina marginalización.

19 Caso discreto

Si (X, Y) toma valores en un conjunto numerable, definimos

$$p_{X,Y}(x, y) = P(X = x, Y = y).$$

La función de masa conjunta satisface

$$p_{X,Y}(x, y) \geq 0$$

y

$$\sum_x \sum_y p_{X,Y}(x, y) = 1.$$

Las marginales son

$$p_X(x) = \sum_y p_{X,Y}(x, y)$$

y

$$p_Y(y) = \sum_x p_{X,Y}(x, y).$$

19.1. Probabilidades sobre subconjuntos

Para cualquier conjunto A contenido en el soporte conjunto,

$$P((X, Y) \in A) = \sum_{(x,y) \in A} p_{X,Y}(x, y).$$

19.2. Distribución condicional discreta

Si $p_Y(y) > 0$,

$$p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Para cada y fijo con probabilidad positiva,

$$\sum_x p_{X|Y}(x | y) = 1.$$

Análogamente,

$$p_{Y|X}(y | x) = \frac{p_{X,Y}(x, y)}{p_X(x)}.$$

20 Caso absolutamente continuo

Un vector aleatorio (X, Y) es absolutamente continuo si existe una función no negativa $f_{X,Y}$ tal que

$$P((X, Y) \in A) = \iint_A f_{X,Y}(x, y) \, dx \, dy$$

para todo boreliano A .

En particular,

$$\iint_{\mathbb{R}^2} f_{X,Y}(x, y) \, dx \, dy = 1 .$$

La CDF conjunta puede expresarse como

$$F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) \, dv \, du .$$

20.1. Densidades marginales

Las marginales se obtienen por integración:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dy$$

y

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dx .$$

Estas integrales existen en el sentido apropiado y satisfacen

$$\int f_X(x) dx = 1,$$

$$\int f_Y(y) dy = 1.$$

20.2. Densidades condicionales

Si $f_Y(y) > 0$, definimos

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

Para casi todo y con densidad marginal positiva,

$$\int_{-\infty}^{\infty} f_{X|Y}(x | y) dx = 1.$$

Análogamente,

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)}.$$

21 Ejemplo triangular

Considere

$$f_{X,Y}(x,y) = 2$$

sobre

$$0 < y < x < 1,$$

y cero fuera de esa región.

La normalización es

$$\int_0^1 \int_0^x 2 \, dy \, dx = 1.$$

Las marginales son

$$f_X(x) = 2x, \quad 0 < x < 1$$

y

$$f_Y(y) = 2(1-y), \quad 0 < y < 1.$$

La densidad condicional de Y dado $X = x$ es

$$f_{Y|X}(y | x) = \frac{1}{x}, \quad 0 < y < x.$$

Por tanto, para cada x fijo, la condicional es uniforme en $(0, x)$.

22 Independencia

Las variables X y Y son independientes si

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

para todos los borelianos $A, B \subset \mathbb{R}$.

Una caracterización equivalente mediante CDF es

$$F_{X,Y}(x, y) = F_X(x)F_Y(y)$$

para todo x, y .

22.1. Caso discreto

Si X y Y son discretas, la independencia equivale a

$$p_{X,Y}(x, y) = p_X(x)p_Y(y)$$

para todos los valores del soporte.

22.2. Caso continuo

Si existe densidad conjunta, la independencia equivale a

$$f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

casi en todas partes.

22.3. Demostración de la factorización condicional

Si X y Y son independientes y $f_Y(y) > 0$, entonces

$$f_{X|Y}(x | y) = \frac{f_X(x)f_Y(y)}{f_Y(y)} = f_X(x).$$

Esto formaliza la idea de que el conocimiento de Y no altera la distribución de X .

23 El soporte conjunto y la independencia

Si una densidad conjunta positiva tiene soporte que no puede escribirse como producto cartesiano de dos conjuntos marginales, ello suele ser una señal inmediata de dependencia.

En el ejemplo triangular,

$$0 < y < x < 1$$

no es un conjunto de la forma $A \times B$. Por tanto, el soporte ya revela que no puede existir una factorización global de la densidad en producto de marginales positivas.

24 Teorema de Tonelli y Fubini

La marginalización se apoya en resultados fundamentales de integración.

Como $f_{X,Y} \geq 0$, el teorema de Tonelli permite intercambiar el orden de integración:

$$\int \left(\int f_{X,Y}(x,y) dy \right) dx = \int \left(\int f_{X,Y}(x,y) dx \right) dy = 1.$$

Cuando una función integrable no es necesariamente no negativa, el teorema de Fubini permite intercambiar integrales bajo condiciones de integrabilidad absoluta.

25 Una misma pareja de marginales, distintas conjuntas

Las distribuciones marginales no determinan en general la distribución conjunta.

Considere dos variables Bernoulli con

$$P(X = 1) = P(Y = 1) = \frac{1}{2}.$$

Podemos construir:

1. un modelo independiente, donde cada una de las cuatro parejas tiene probabilidad $1/4$;
2. un modelo perfectamente asociado, donde

$$P(X = 0, Y = 0) = \frac{1}{2},$$

$$P(X = 1, Y = 1) = \frac{1}{2},$$

y las otras dos parejas tienen probabilidad cero.

Ambos modelos tienen las mismas marginales, pero distribuciones conjuntas completamente diferentes.

26 Probabilidades condicionales como familia de leyes

Para cada valor y admisible, la expresión

$$p_{X|Y}(\cdot | y)$$

o

$$f_{X|Y}(\cdot | y)$$

es una distribución de probabilidad sobre X .

El parámetro y indexa una familia de distribuciones condicionales. Esta idea será fundamental al estudiar esperanza condicional, regresión y modelos jerárquicos.

27 Extensión a más dimensiones

Para un vector

$$(X_1, \dots, X_n),$$

la distribución conjunta se define de forma análoga. Las marginales se obtienen eliminando variables mediante sumas o integrales y las distribuciones condicionales se obtienen normalizando apropiadamente respecto de las marginales condicionantes.

Las ideas esenciales de este capítulo se generalizan directamente al caso multivariado.

28 Resumen teórico

Distribución conjunta discreta:

$$p_{X,Y}(x, y) = P(X = x, Y = y).$$

Marginalización:

$$p_X(x) = \sum_y p_{X,Y}(x, y).$$

Condicionamiento:

$$p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Densidad conjunta continua:

$$P((X, Y) \in A) = \iint_A f_{X,Y}(x, y) \, dx \, dy.$$

Marginalización continua:

$$f_X(x) = \int f_{X,Y}(x, y) \, dy.$$

Independencia:

$$F_{X,Y} = F_X F_Y,$$

o equivalentemente mediante masas o densidades cuando existen.

29 Ejercicios teóricos

1. Demuestra que las marginales de una PMF conjunta están normalizadas.
2. Demuestra que una PMF condicional suma 1.
3. Prueba que si $p_{X,Y}(x,y) = p_X(x)p_Y(y)$, entonces $F_{X,Y}(x,y) = F_X(x)F_Y(y)$.
4. Demuestra la recíproca para variables discretas.
5. Para $f(x,y) = 2$ en $0 < y < x < 1$, obtiene rigurosamente las marginales.
6. Obtén $f_{X|Y}(x|y)$ en el ejemplo triangular.
7. Verifica que cada densidad condicional del ejemplo se normaliza.
8. Construye dos distribuciones conjuntas discretas distintas con las mismas marginales.
9. Demuestra que si X y Y son independientes, entonces $P(X \in A | Y \in B) = P(X \in A)$ cuando $P(Y \in B) > 0$.
10. **Reto.** Demuestra que si $f_{X,Y} = f_X f_Y$ casi en todas partes, entonces X y Y son independientes.
11. **Reto.** Justifica la fórmula rectangular para probabilidades a partir de la CDF conjunta.
12. **Reto.** Explica por qué la marginalización puede interpretarse como una proyección de la ley conjunta sobre cada eje.

29.1. Referencias del capítulo

La teoría de distribuciones conjuntas, marginalización, condicionamiento e independencia sigue el desarrollo estándar de textos de probabilidad y estadística matemática, incluyendo Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018).

30 Esperanza conjunta, covarianza y correlación

30.1. Planteamiento

Sea (X, Y) un vector aleatorio definido sobre un espacio de probabilidad. El conocimiento de su ley conjunta permite estudiar no sólo las distribuciones marginales, sino también funciones de ambas variables y medidas de dependencia lineal.

En este capítulo se formalizan la esperanza de funciones bivariadas, la covarianza, la correlación y la varianza de combinaciones lineales.

30.2. Esperanza de funciones de dos variables

Si (X, Y) es discreto con función de masa conjunta $p_{X,Y}$ y $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ es integrable, entonces

$$E[g(X, Y)] = \sum_x \sum_y g(x, y) p_{X,Y}(x, y).$$

Si (X, Y) posee densidad conjunta $f_{X,Y}$,

$$E[g(X, Y)] = \iint_{\mathbb{R}^2} g(x, y) f_{X,Y}(x, y) dx dy.$$

Estas expresiones son la versión bidimensional de la ley del estadístico inconsciente.

30.3. Teorema de linealidad

Si X y Y son integrables y $a, b, c \in \mathbb{R}$, entonces

$$E[aX + bY + c] = aE[X] + bE[Y] + c.$$

La independencia no es necesaria.

30.3.1. Demostración

Por linealidad de la integral respecto de la medida conjunta,

$$E[aX + bY + c] = \int (aX + bY + c) dP = aE[X] + bE[Y] + c.$$

30.4. El momento mixto $E[XY]$

Cuando XY es integrable,

$$E[XY]$$

se denomina momento mixto de orden $(1, 1)$.

Si X y Y son independientes e integrables, entonces

$$E[XY] = E[X]E[Y].$$

30.4.1. Demostración en el caso con densidades

La independencia implica

$$f_{X,Y}(x,y) = f_X(x)f_Y(y).$$

Por Fubini,

$$\begin{aligned} E[XY] &= \iint xy f_X(x) f_Y(y) dx dy \\ &= \left(\int x f_X(x) dx \right) \left(\int y f_Y(y) dy \right) \\ &= E[X]E[Y]. \end{aligned}$$

La demostración discreta es análoga sustituyendo integrales por sumas.

30.5. Definición de covarianza

Sean $X, Y \in L^2$. Se define

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])].$$

Expandiendo el producto,

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y].$$

30.6. Propiedades de la covarianza

Para variables con segundos momentos finitos y constantes a, b, c, d :

$$\text{Cov}(X, Y) = \text{Cov}(Y, X),$$

$$\text{Cov}(X, X) = \text{Var}(X),$$

$$\text{Cov}(X, c) = 0,$$

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y).$$

Más generalmente, la covarianza es bilineal:

$$\text{Cov}(aX + bY, Z) = a \text{Cov}(X, Z) + b \text{Cov}(Y, Z).$$

30.7. Varianza de una suma

Para $X, Y \in L^2$,

$$\boxed{\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).}$$

30.7.1. Demostración

Sea

$$\widetilde{X} = X - E[X], \quad \widetilde{Y} = Y - E[Y].$$

Entonces

$$\begin{aligned} \text{Var}(X + Y) &= E[(\widetilde{X} + \widetilde{Y})^2] \\ &= E[\widetilde{X}^2] + E[\widetilde{Y}^2] + 2E[\widetilde{X}\widetilde{Y}] \\ &= \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y). \end{aligned}$$

Por tanto,

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

30.8. Sumas de muchas variables

Para $X_1, \dots, X_n \in L^2$,

$$\text{Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j).$$

Si las variables son independientes, todas las covarianzas cruzadas son cero.

30.9. Independencia e incorrelación

30.9.1. Teorema

Si X y Y son independientes y tienen segundos momentos finitos, entonces

$$\text{Cov}(X, Y) = 0.$$

30.9.2. Demostración

Por independencia,

$$E[XY] = E[X]E[Y].$$

Sustituyendo en la identidad de covarianza,

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = 0.$$

El recíproco es falso en general.

30.10. Contraejemplo: incorrelación sin independencia

Sea

$$X \sim U(-1, 1), \quad Y = X^2.$$

Entonces Y es una función determinista de X , de modo que existe dependencia completa. Sin embargo,

$$E[X] = 0,$$

$$E[XY] = E[X^3] = 0$$

por simetría, y por tanto

$$\text{Cov}(X, Y) = 0.$$

Este ejemplo muestra que la covarianza sólo captura un tipo particular de dependencia: la componente lineal.

30.11. Coeficiente de correlación

Si

$$0 < \text{Var}(X) < \infty, \quad 0 < \text{Var}(Y) < \infty,$$

se define

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}.$$

30.12. Cota de correlación

Se cumple

$$|\rho_{X,Y}| \leq 1.$$

30.12.1. Demostración mediante Cauchy–Schwarz

Sean

$$U = X - E[X], \quad V = Y - E[Y].$$

La desigualdad de Cauchy–Schwarz da

$$|E[UV]|^2 \leq E[U^2]E[V^2].$$

Por tanto,

$$|\text{Cov}(X, Y)|^2 \leq \text{Var}(X) \text{Var}(Y).$$

Dividiendo por el producto positivo de las varianzas,

$$|\rho_{X,Y}| \leq 1.$$

30.13. Caso de igualdad

La igualdad en Cauchy–Schwarz ocurre si y sólo si las variables centradas son linealmente dependientes casi seguramente. En consecuencia,

$$|\rho_{X,Y}| = 1$$

si y sólo si existen constantes $a \neq 0$ y b tales que

$$Y = aX + b$$

casi seguramente.

El signo de a determina si $\rho = 1$ o $\rho = -1$.

30.14. Invariancia frente a transformaciones afines

Sean

$$U = aX + b, \quad V = cY + d,$$

con $a, c \neq 0$. Entonces

$$\rho_{U,V} = \text{sign}(ac)\rho_{X,Y}.$$

Por tanto, cambios positivos de unidades no alteran la correlación.

30.15. Matriz de covarianzas

Para el vector

$$\mathbf{X} = (X_1, \dots, X_n)^T,$$

su matriz de covarianzas es

$$\Sigma_{ij} = \text{Cov}(X_i, X_j).$$

En dimensión dos,

$$\Sigma = \begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \text{Var}(Y) \end{pmatrix}.$$

30.16. Positividad semidefinida

Para todo vector $a \in \mathbb{R}^n$,

$$a^T \Sigma a = \text{Var}(a^T \mathbf{X}) \geq 0.$$

Por ello, toda matriz de covarianzas es simétrica y positiva semidefinida.

30.17. Ejemplo continuo triangular

Sea

$$f_{X,Y}(x,y) = 2, \quad 0 < y < x < 1.$$

Las marginales son

$$f_X(x) = 2x, \quad f_Y(y) = 2(1-y).$$

Se obtiene

$$E[X] = \frac{2}{3}, \quad E[Y] = \frac{1}{3},$$

$$E[XY] = \frac{1}{4},$$

y por tanto

$$\text{Cov}(X,Y) = \frac{1}{4} - \frac{2}{9} = \frac{1}{36}.$$

Este ejemplo combina dependencia geométrica del soporte con una covarianza positiva.

30.18. Mapa conceptual

La cadena lógica principal es

$$\text{ley conjunta} \implies E[g(X, Y)] \implies E[XY] \implies \text{Cov}(X, Y) \implies \rho_{X, Y}.$$

La implicación

$$X \perp Y \implies \text{Cov}(X, Y) = 0$$

es válida, pero

$$\text{Cov}(X, Y) = 0 \not\Rightarrow X \perp Y$$

en general.

30.19. Ejercicios teóricos

1. Demuestre la bilinealidad de la covarianza.
2. Demuestre la fórmula de $\text{Var}(aX + bY)$.
3. Extienda la fórmula anterior a una suma de n variables.
4. Demuestre que independencia implica incorrelación bajo segundos momentos finitos.
5. Verifique rigurosamente el contraejemplo $X \sim U(-1, 1)$, $Y = X^2$.
6. Demuestre $|\rho| \leq 1$ mediante Cauchy-Schwarz.
7. Caracterice el caso $|\rho| = 1$.
8. Demuestre la invariancia de $|\rho|$ frente a transformaciones afines no degeneradas.
9. Demuestre que una matriz de covarianzas es positiva semidefinida.
10. Para la densidad triangular del capítulo, calcule las dos varianzas y la correlación exacta.

30.20. Referencias del capítulo

El tratamiento formal de momentos conjuntos, covarianza y correlación sigue textos clásicos de probabilidad y estadística matemática citados en la bibliografía general del libro.

31 Transformaciones de variables aleatorias

31.1. Planteamiento general

Sea X una variable aleatoria y sea g una función medible. La variable

$$Y = g(X)$$

es nuevamente una variable aleatoria. El problema fundamental consiste en obtener la ley inducida de Y a partir de la ley de X .

La transformación puede estudiarse mediante la medida imagen, la función de distribución, el cambio de variable o, en dimensiones superiores, el determinante Jacobiano.

31.2. Ley inducida

Si P_X es la ley de X , la ley de $Y = g(X)$ satisface

$$P_Y(B) = P_X(g^{-1}(B))$$

para todo conjunto boreliano B .

Esta identidad es la formulación abstracta del problema de transformación.

31.3. Caso discreto

Si X es discreta,

$$P(Y = y) = \sum_{x: g(x)=y} P(X = x).$$

Cuando g no es inyectiva, todas las preimágenes de y deben contribuir a la probabilidad.

31.4. Método de la función de distribución

Para cualquier transformación real,

$$F_Y(y) = P(g(X) \leq y).$$

Si F_Y es absolutamente continua, entonces

$$f_Y(y) = F'_Y(y)$$

casi en todas partes.

Este método no requiere que g sea uno a uno y constituye una herramienta general.

31.5. Transformación monótona creciente

Suponga que g es estrictamente creciente y diferenciable. Entonces

$$F_Y(y) = P(X \leq g^{-1}(y)) = F_X(g^{-1}(y)).$$

Derivando,

$$f_Y(y) = f_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y).$$

31.6. Transformación monótona decreciente

Si g es estrictamente decreciente,

$$F_Y(y) = P(X \geq g^{-1}(y)).$$

La derivación conduce a la fórmula unificada

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|.$$

31.7. Transformación afín

Sea

$$Y = aX + b, \quad a \neq 0.$$

Entonces

$$f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right).$$

La transformación del soporte debe realizarse simultáneamente.

31.8. Transformación no inyectiva

Suponga que para cada y regular la ecuación

$$g(x) = y$$

posee un número finito de soluciones $x_1(y), \dots, x_k(y)$ con derivadas inversas bien definidas.

Entonces

$$f_Y(y) = \sum_{j=1}^k f_X(x_j(y)) \left| \frac{dx_j}{dy} \right|.$$

La fórmula expresa la suma de la masa infinitesimal proveniente de cada rama inversa.

31.9. Ejemplo: cuadrado de una variable uniforme simétrica

Sea

$$X \sim U(-1, 1), \quad Y = X^2.$$

Para $0 < y < 1$,

$$F_Y(y) = P(-\sqrt{y} \leq X \leq \sqrt{y}) = \sqrt{y}.$$

Así,

$$\boxed{f_Y(y) = \frac{1}{2\sqrt{y}}}, \quad 0 < y < 1.$$

Las dos ramas $\pm\sqrt{y}$ explican el factor total obtenido.

31.10. Transformada inversa

Si F es una CDF continua y estrictamente creciente y

$$U \sim U(0, 1),$$

entonces

$$X = F^{-1}(U)$$

tiene CDF F .

31.10.1. Demostración

Para x en el soporte,

$$P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x),$$

pues U es uniforme estándar.

Este resultado fundamenta uno de los métodos básicos de generación de variables aleatorias.

31.11. Ejemplo exponencial

Para una exponencial de tasa λ ,

$$F(x) = 1 - e^{-\lambda x}.$$

Resolviendo $u = F(x)$,

$$x = -\frac{1}{\lambda} \log(1 - u).$$

Como $1 - U$ también es uniforme estándar, puede escribirse

$$X = -\frac{1}{\lambda} \log U.$$

31.12. Convolución discreta

Sean X y Y independientes y discretas. Para

$$S = X + Y,$$

$$P(S = s) = \sum_x P(X = x, Y = s - x).$$

Por independencia,

$$p_S(s) = \sum_x p_X(x)p_Y(s-x).$$

31.13. Convolución continua

Si X y Y son independientes con densidades,

$$f_{X+Y}(s) = \int_{-\infty}^{\infty} f_X(x)f_Y(s-x) dx.$$

31.13.1. Derivación mediante transformación

Defina

$$U = X + Y, \quad V = X.$$

La inversa es

$$X = V, \quad Y = U - V.$$

El Jacobiano inverso es

$$\left| \frac{\partial(x,y)}{\partial(u,v)} \right| = 1.$$

Entonces

$$f_{U,V}(u,v) = f_{X,Y}(v,u-v).$$

Bajo independencia,

$$f_{U,V}(u,v) = f_X(v)f_Y(u-v).$$

Integrando en v se obtiene la convolución.

31.14. Transformaciones bidimensionales

Sea

$$T(x, y) = (g_1(x, y), g_2(x, y)) = (u, v)$$

una transformación uno a uno y diferenciable sobre una región adecuada. Si su inversa es

$$(x, y) = T^{-1}(u, v),$$

entonces

$$f_{U,V}(u, v) = f_{X,Y}(T^{-1}(u, v)) |\det DT^{-1}(u, v)|.$$

31.15. El Jacobiano

En dos dimensiones,

$$\frac{\partial(x, y)}{\partial(u, v)} = \begin{vmatrix} \partial x / \partial u & \partial x / \partial v \\ \partial y / \partial u & \partial y / \partial v \end{vmatrix}.$$

Su valor absoluto representa el factor local de cambio de área.

La presencia del Jacobiano garantiza la conservación de probabilidad:

$$f_{X,Y}(x, y) dx dy = f_{U,V}(u, v) du dv.$$

31.16. Transformación del soporte

No basta transformar la fórmula de la densidad. También debe determinarse la imagen del soporte original bajo T .

En muchos problemas, la mayor dificultad matemática consiste precisamente en describir correctamente esa nueva región.

31.17. Caso de transformaciones múltiples

Cuando T no es globalmente uno a uno, el dominio puede dividirse en regiones donde sí lo sea. Las contribuciones de las distintas ramas deben sumarse, de manera análoga al caso unidimensional.

31.18. Convolución y normalización

Si f_X y f_Y son densidades,

$$f_S(s) = \int f_X(x)f_Y(s-x) dx$$

es no negativa. Además, por Tonelli y cambio de variable,

$$\begin{aligned} \int f_S(s) ds &= \iint f_X(x)f_Y(s-x) dx ds \\ &= \int f_X(x) \left[\int f_Y(u) du \right] dx \\ &= 1. \end{aligned}$$

Por tanto, la convolución de dos densidades es nuevamente una densidad.

31.19. Momentos bajo transformaciones

Si $Y = g(X)$ y la esperanza existe,

$$E[Y] = E[g(X)].$$

No es necesario obtener primero la densidad de Y para calcular esta esperanza. Puede utilizarse directamente

$$E[g(X)] = \int g(x)f_X(x) dx$$

o la suma correspondiente en el caso discreto.

Esta observación distingue dos problemas diferentes:

- obtener la **distribución completa** de una transformación;
- obtener únicamente alguno de sus **momentos**.

31.20. Mapa conceptual

$$X \xrightarrow{g} Y$$

puede estudiarse mediante

CDF o cambio de variable.

Para sumas independientes,

$X + Y \implies$ convolución.

Para vectores,

$$(X, Y) \xrightarrow{T} (U, V) \implies \text{Jacobiano}.$$

31.21. Ejercicios teóricos

1. Demuestre la fórmula de cambio de variable para una transformación monótona creciente mediante CDF.
2. Repita la demostración para una transformación decreciente.
3. Derive la fórmula para una transformación con un número finito de ramas inversas.
4. Obtenga rigurosamente la densidad de X^2 para $X \sim U(-1, 1)$.
5. Demuestre el método de la transformada inversa.
6. Derive la distribución exponencial a partir de una uniforme mediante transformada inversa.
7. Demuestre la fórmula de convolución discreta.
8. Derive la convolución continua mediante la transformación $(X, Y) \mapsto (X + Y, X)$.
9. Demuestre que la convolución de dos densidades integra 1.
10. Para una transformación bidimensional lineal no singular, relacione el Jacobiano inverso con el determinante de la matriz de transformación.
11. Analice por qué debe transformarse también el soporte.
12. Obtenga la densidad de $|X|$ cuando X posee una densidad simétrica respecto de cero.

31.22. Referencias del capítulo

El desarrollo formal de transformaciones, medida imagen, convolución y cambio de variables sigue los textos principales de probabilidad citados en la bibliografía general del libro.

Referencias

Devore, Jay L. 2016. *Probability and Statistics for Engineering and the Sciences*. 9.^a ed. Cengage Learning.

Johnson, Richard A. 2018. *Miller & Freund's Probability and Statistics for Engineers*. 9.^a ed. Pearson.

Kerns, G. Jay. 2010. *Introduction to Probability and Statistics Using R*. 1.^a ed.

Montgomery, Douglas C., y George C. Runger. 2018. *Applied Statistics and Probability for Engineers*. 7.^a ed. Wiley.

Walpole, Ronald E., Raymond H. Myers, Sharon L. Myers, y Keying Ye. 2012. *Probabilidad y estadística para ingeniería y ciencias*. 9.^a ed. Pearson.